

Genética y genómica: genes, cromatina y variación

BC-CH02 – Biología Computacional

Edición 2 · 2026-09-09

Pregunta del tema. Solo alrededor del dos por ciento del genoma humano codifica proteínas. ¿Qué hace el resto, cómo controla qué genes se expresan y cómo se estudia una diferencia entre individuos?

Producto final. Un mapa razonado que conecte elementos reguladores, estados de cromatina y clases de variación sin confundir asociación estadística con causalidad biológica.

Mapa del tema

1. El flujo de información que organiza el tema	1
2. La arquitectura física y funcional del genoma eucariota	2
3. Estructura de la cromatina: Nucleosomas y empaquetamiento	3
4. Epigenética: memoria reguladora sin cambiar la secuencia	4
5. Polimorfismos de un solo nucleótido	6
6. La localización de un SNP condiciona su consecuencia	7
7. Del SNP asociado a la hipótesis causal: qué muestra un GWAS	7
8. Variantes estructurales y firmas mutacionales	8
9. Dos cálculos auxiliares: CpG y clase química de una SNV	8
10. Peligros computacionales y actividad de depuración	9
11. Síntesis operativa y tablas de diagnóstico	10
12. Glosario conceptual	10
13. Compruebe las conexiones antes de continuar	11
14. Conexiones y mapa del curso	11
15. Fuentes y reproducibilidad	11

Cómo usar este tema

Este capítulo retoma brevemente el Dogma Central, define el gen eucariota y sus elementos reguladores, explica la fracción no codificante y los transposones, asciende por los niveles de cromatina y termina con SNP, estudios de asociación, variantes en el número de copias y firmas mutacionales. Puede leerse sin ningún material externo: cada concepto necesario se define antes de utilizarse.

Al terminar sabrá: describir un gen sin reducirlo a sus exones codificantes; distinguir promotores, potenciadores, silenciadores y aisladores; explicar cómo transposones y marcas epigenéticas modifican la regulación; relacionar la localización de un SNP con sus posibles consecuencias; interpretar el esquema de un GWAS; y no confundir «asociado» con «causal».

La ruta **esencial** recorre genes y elementos reguladores, ADN no codificante, transposones, estados de cromatina, epigenética, SNP, GWAS, CNV y firmas mutacionales. La ruta de **estudio** añade la paradoja del valor C, la definición computacional de islas CpG y la clasificación química de sustituciones. Antes de avanzar, prediga qué consecuencia tendría cerrar la cromatina o cambiar una base en cada localización considerada.

1 El flujo de información que organiza el tema

ESENCIAL El capítulo anterior presentó el Dogma Central; aquí funciona como mapa de entrada. La **replicación** copia ADN en ADN; la **transcripción** copia un gen en ARN; y la **traducción** hace que el ribosoma lea el ARNm en codones de tres nucleótidos, cada uno asociado a un aminoácido o a una señal de terminación.

El flujo no es una cadena rígida. La transcripción inversa devuelve información de ARN a ADN; algunos virus replican ARN; las ribozimas muestran que un ARN puede ser catalítico; y los priones transmiten un estado conformacional sin cambiar la secuencia de un ácido nucleico. Aquí basta esta recapitulación; el desarrollo químico completo permanece en BC-CH01.

2 La arquitectura física y funcional del genoma eucariota

ESENCIAL En el capítulo precedente establecimos los principios bioquímicos para representar una secuencia. El genoma eucariota, sin embargo, no es un texto plano de genes contiguos. El genoma humano (con sus $\approx 3.2 \times 10^9$ pares de bases por genoma haploide) presenta una arquitectura modular discontinua, tridimensionalmente organizada y densamente regulada en el espacio y en el tiempo:

1. **Estructura génica discontinua (mosaico exón-intrón):** Descubierta en 1977 por Phillip Sharp y Richard Roberts (Premio Nobel en 1993), los genes eucariotas están fragmentados en segmentos retenidos en el ARN maduro (**exones**) separados por regiones intercaladas no codificantes (**intrones**). Estos intrones son reconocidos y escindidos con precisión de un solo nucleótido por la maquinaria del espliceosoma (*spliceosome*) durante el procesamiento del pre-ARN mensajero.
2. **Promotores:** Secuencias reguladoras situadas junto al sitio de inicio de la transcripción (TSS), normalmente aguas arriba en el sentido 5'. En muchos promotores eucariotas aparece una caja TATA, cuyo consenso se representa como TATAAAA; la proteína TBP del complejo TFIID la reconoce y ayuda a reclutar los factores generales y la ARN polimerasa II. Ni todos los promotores contienen caja TATA ni el consenso exige una coincidencia perfecta.
3. **Potenciadores (enhancers):** Módulos en *cis* que reclutan activadores y elevan la transcripción. Pueden encontrarse miles o cientos de miles de pares de bases aguas arriba, aguas abajo o dentro de intrones, y suelen funcionar con relativa independencia de la orientación. Los bucles tridimensionales acercan el potenciador al promotor que regula.
4. **Silenciadores (silencers):** Elementos distales análogos en alcance a los potenciadores, pero unidos a represores que reducen o bloquean la transcripción de su gen diana.
5. **Aisladores de frontera (Insulators) y factores CTCF:** Secuencias fijadoras de la proteína con dedos de zinc CTCF que, junto con el complejo molecular de la cohesina, delimitan los **dominios de asociación topológica (TADs)**, impidiendo que los potenciadores de un dominio activen de manera inapropiada promotores de regiones vecinas.

Atención. Un gen no se define únicamente como «los exones que codifican una proteína». Incluye la unidad que se transcribe y las regiones que gobiernan su uso; además, un exón es la parte retenida tras el *splicing*, pero puede contener una región no traducida. «Exónico» y «codificante» no son sinónimos.

La arquitectura génica eucariota comprende exones codificantes, intrones no codificantes, promotores basales, potenciadores distales, silenciadores y elementos aisladores de frontera CTCF.

2.1 La fracción no codificante no es una categoría funcional única

En el genoma humano, solo alrededor del 1.5–2.0% de la secuencia codifica directamente cadenas polipeptídicas. El resto se denomina **ADN no codificante**, pero esa etiqueta agrupa elementos con funciones y orígenes muy distintos:

- promotores, potenciadores, silenciadores y aisladores que regulan genes;
- genes que producen ARN funcional sin traducirse, como ARNt, ARNr, microARN y ARN largos no codificantes;
- intrones, que pueden alojar regulación y permiten generar isoformas por *splicing* alternativo;
- télómeros y centrómeros, necesarios para la estabilidad, protección y segregación de los cromosomas;
- secuencias repetitivas, entre ellas numerosos elementos transponibles.

Que una región no codifique una proteína no implica que tenga una función conocida, y tampoco que carezca de ella: «no codificante» describe lo que no hace, no demuestra para qué sirve.

2.2 La paradoja del valor C

El **valor C** es la cantidad de ADN por genoma haploide. No crece de forma lineal con la complejidad anatómica: la planta *Paris japonica*, con unos 150 Gb, tiene cerca de cincuenta veces más ADN que el ser humano. Esta

discordancia, explicada en gran parte por expansiones de repeticiones y elementos móviles, se conoce como paradoja del valor C.

Atención. Circulan cifras aún más extremas, como los 670 Gb atribuidos a *Polychaos dubium*. Proceden de estimaciones antiguas no confirmadas con métodos actuales. La conclusión sobre el valor C no depende de ese dato dudoso; *Paris japonica* basta para establecerla.

2.3 Elementos transponibles: copiar, cortar y reutilizar

Los elementos transponibles son secuencias capaces de cambiar de localización y constituyen, junto con sus restos, una fracción cercana a la mitad del genoma humano. Se agrupan por su mecanismo:

- **Clase I, retrotransposones:** se transcriben a ARN y una transcriptasa inversa genera una nueva copia de ADN que se inserta en otra posición; es un mecanismo de «copiar y pegar». Incluyen los LINE, como L1, que codifican la maquinaria necesaria; los SINE, como Alu, que dependen de ella; y los retrotransposones LTR relacionados con retrovirus endógenos.
- **Clase II, transposones de ADN:** una transposasa reconoce el elemento, lo corta y lo inserta en otro sitio; el mecanismo clásico es «cortar y pegar». En el genoma humano actual predominan copias inactivas, aunque sus huellas evolutivas permanecen.

Su impacto no se limita a ocupar espacio. Las inserciones crean variación; sus promotores y potenciadores pueden incorporarse a redes reguladoras; la recombinación entre copias favorece deleciones, duplicaciones e inversiones; y algunos genes móviles han sido domesticados. Las **sincitinas**, derivadas de envolturas de retrovirus endógenos, participan en el desarrollo de la placenta de mamíferos y ejemplifican esa cooptación.

Atención. Para el análisis computacional, las numerosas copias parecidas producen lecturas que se alinean igual de bien en varios lugares. La calidad de mapeo y las regiones no resueltas de un ensamblaje no son detalles del programa: son consecuencias directas de la biología repetitiva del genoma.

El ADN no codificante incluye regulación, genes de ARN, intrones, secuencias estructurales y repeticiones; los elementos transponibles generan variación, reorganización y nuevo material regulador o génico.

3 Estructura de la cromatina: Nucleosomas y empaquetamiento

ESENCIAL

En el núcleo de una sola célula humana diploide, el ADN extendido alcanzaría una longitud física de ≈ 2 metros lineales. Este polímero debe organizarse en un volumen nuclear microscópico de apenas 5–10 μm de diámetro, garantizando al mismo tiempo que regiones génicas específicas permanezcan dinámicamente accesibles para la replicación y la transcripción. Este prodigio biofísico de compactación se logra mediante la **cromatina**, un complejo supramolecular de ADN y proteínas estructurales especializadas denominadas **histonas**.

3.1 El nucleosoma: unidad fundamental de empaquetamiento

La unidad estructural básica y repetitiva de la cromatina es el **nucleosoma**. Está constituido por un núcleo proteico globular o **octámero de histonas** integrado por dos copias estequiométricas de cada una de las cuatro histonas nucleares centrales:

$$\text{Octámero central} = 2 \times (\text{H2A} + \text{H2B} + \text{H3} + \text{H4})$$

Alrededor de este octámero globular, densamente poblado por aminoácidos básicos cargados positivamente (Lisina y Arginina), la doble hélice de ADN (cargada negativamente por sus grupos fosfato en el esqueleto) se enrolla dando exactamente 1.65 **vueltas de superhélice levógira, abarcando 146 pares de bases**. Los nucleosomas contiguos se conectan mediante segmentos de **ADN espaciador** (*linker DNA*) de 20–80 pb, asociados a la histona de unión **H1**, originando la clásica fibra conformacional de 10 nm («collar de cuentas» o *beads-on-a-string*).

El nucleosoma consiste en un octámero de histonas (2 copias de H2A, H2B, H3 y H4) alrededor del cual el ADN da aproximadamente 1,65 vueltas de superhélice levógira, abarcando entre 146 y 147 pares de bases según la estructura de referencia que se tome.



Figura 1: Estructura supramolecular del nucleosoma (octámero central y 146 pb de ADN) y modificación postraduccional de colas de histonas. Figura original generada por `verification/make_figures.py`.

3.2 De los nucleosomas al cromosoma metafásico

El modelo jerárquico clásico ordena la compactación en nucleosomas, **fibra de 30 nm o solenoide**, dominios en bucle de 20–100 kb anclados a un andamio nuclear mediante regiones SAR/MAR, y finalmente el cromosoma metafásico necesario para segregar el ADN entre las células hijas. Esa secuencia es útil como modelo clásico, pero no debe interpretarse como cuatro piezas rígidas que existan siempre de la misma forma.

Atención. La fibra regular de 30 nm se observa en determinadas condiciones *in vitro*, pero la cromatina de muchas células intactas se comporta como una cadena irregular y dinámica de nucleosomas, sin un solenoide uniforme. Los bucles, los contactos entre regiones y la asociación con proteínas estructurales sí son esenciales; lo discutido es que toda la cromatina atravesase una fibra regular de 30 nm como nivel universal [3].

3.3 Eucromatina y heterocromatina son estados funcionales

La fibra de cromatina transita de forma dinámica entre dos estados funcionales:

- **Eucromatina:** Estado descondensado y espacialmente accesible, caracterizado por nucleosomas espaciados, alta acetilación de histonas y transcripción permisiva. Suele concentrar genes y regiones reguladoras, aunque «abierta» no significa que todos sus genes estén transcribiéndose a la vez.
- **Heterocromatina:** Estado densamente compactado e inaccesible a factores de transcripción, pobre en genes y enriquecido en repeticiones:
 - **Heterocromatina constitutiva:** Permanentemente silenciada en todos los tipos celulares (centrómeros, télómeros y repeticiones LINEs), enriquecida en trimetilación de lisina 9 en histona H3 (**H3K9me3**) y proteína HP1.
 - **Heterocromatina facultativa:** Regiones que se silencian de forma reversible durante la diferenciación celular y el desarrollo (como la inactivación del cromosoma X en hembras de mamíferos), mediada por el complejo represor Polycomb (PRC2) y la marca **H3K27me3**.

La cromatina se organiza en unidades nucleosomales repetitivas (146 pb alrededor de un octámero de histonas), dividiéndose funcionalmente en eucromatina permisiva y heterocromatina condensada.

4 Epigenética: memoria reguladora sin cambiar la secuencia

ESTUDIO La epigenética estudia cambios de estado funcional que no alteran la secuencia de ADN y que pueden mantenerse a través de divisiones celulares. Es una capa dinámica de regulación que contribuye a que células con el mismo genoma adopten identidades distintas durante la diferenciación y respondan al ambiente. Algunas marcas se transmiten por mitosis y ciertos estados pueden alcanzar la línea germinal, pero no toda respuesta ambiental es heredable ni toda marca epigenética persiste entre generaciones.

4.1 El código de histonas y la tríada escritor–borrador–lector

Las colas N-terminales de las histonas emergen hacia el exterior del núcleo del nucleosoma, expuestas al solvente nuclear. Estas colas sufren un rico abanico de **modificaciones postraduccionales reversibles (PTMs)**, entre ellas acetilación, metilación, fosforilación y ubiquitinación. En el paradigma **escritor–borrador–lector**, unas enzimas depositan marcas, otras las retiran y proteínas con dominios especializados interpretan el estado local. El resultado es un equilibrio dinámico, no un código de equivalencias rígidas:

1. **Acetilación de lisinas (por HATs / HDACs)**: La adición de un grupo acetilo por las histona acetiltransferasas (HATs) neutraliza la carga positiva del grupo ϵ -amino de la lisina, debilitando su atracción electrostática hacia el esqueleto de ADN. Esto relaja la estructura cromatínica y permite el reclutamiento de complejos basales de transcripción.
 - **H3K27ac**: Marca canónica de **potenciadores (*enhancers*) activos** y promotores abiertos.
 - **H3K9ac**: Asociada a inicio de transcripción activa.
2. **Metilación de lisinas y argininas (por HMTs / KDMs)**: La adición de uno, dos o tres grupos metilo por histona metiltransferasas (HMTs) no altera la carga neta del residuo, pero crea sitios de anclaje estéricos reconocidos específicamente por dominios proteicos (*readers*):
 - **H3K4me3**: Marca universal de **promotores basales activos**.
 - **H3K27me3**: Marca de **silenciamiento facultativo Polycomb**.
 - **H3K9me3**: Marca de **heterocromatina constitutiva densa**.
 - **H3K36me3**: Marca de **elongación transcripcional activa**, localizada a lo largo de los cuerpos génicos (*gene bodies*).

El código de histonas regula la accesibilidad cromatínica: la hiperacetilación (H3K27ac) y metilación activa (H3K4me3) marcan transcripción activa, mientras que H3K9me3 y H3K27me3 imponen silenciamiento.

4.2 Metilación del ADN y dinámica biofísica de las islas CpG

En los genomas de vertebrados, la modificación epigenética covalente directa del ADN más abundante es la **5-metilcitosina (5mC)**, producida por la transferencia de un grupo metilo desde la S-adenosilmetionina (SAM) hacia el carbono 5 de la citosina por acción de las ADN metiltransferasas (DNMT1 para mantenimiento replicativo; DNMT3A y DNMT3B para metilación *de novo*).

La metilación de citosinas ocurre de forma casi exclusiva en el contexto del dinucleótido simétrico **CpG** (5'-C-fosfato-G-3'). La mayoría de los promotores humanos se asocia a regiones ricas en CpG, alrededor del 70%. Cuando una isla CpG promotora se hipermetila, puede bloquear directamente la unión de algunas proteínas y reclutar proteínas con dominios MBD y complejos represores, favoreciendo una cromatina cerrada y una represión estable. No se deduce de ello que toda metilación silencie cualquier región: el efecto depende del contexto genómico.

La metilación del ADN ocurre en dinucleótidos CpG, donde la hipermetilación de islas CpG promotoras (Obs/Exp ≥ 0.6 y GC $\geq 50\%$) causa represión transcripcional estable.

Definición computacional de Gardiner-Garden y Frommer (1987):

Una región genómica se clasifica formalmente como una isla CpG si cumple simultáneamente tres criterios matemáticos:

1. Longitud de secuencia $L \geq 200$ pb (típicamente ≥ 500 pb).
2. Contenido de G+C $\geq 50\%$.
3. Ratio de dinucleótidos CpG Observados respecto a Esperados (Obs/Exp) mayor a **0.60**:

$$\text{Ratio(CpG)} = \frac{\text{Conteo(CG)} \times L}{\text{Conteo(C)} \times \text{Conteo(G)}}$$

Traza manual para la secuencia modelo CGCGCGCGCGCG:

Dada la secuencia sintética $S = \text{"CGCGCGCGCGCG"}$ de longitud $L = 12$ pb:

- Conteo de bases: C : 6, G : 6, A : 0, T : 0.
- Contenido GC: $\frac{6+6}{12} = \frac{12}{12} = 100.0\%$.
- Conteo de dinucleótidos CG solapantes: exactamente 6 dinucleótidos CG.
- Frecuencia esperada: $\text{Esperado}(\text{CG}) = \frac{6 \times 6}{12} = \frac{36}{12} = 3.0$.
- Ratio Obs/Exp:

$$\text{Ratio} = \frac{6 \times 12}{6 \times 6} = \frac{72}{36} = 2.000000$$

Para la secuencia sintética CGCGCGCGCGCG de longitud 12, el ratio CpG Observado/Esperado evalúa exactamente a 2.000000 con un contenido GC del 100 por ciento.

Se reproduce con `verification/chapter_checks.py cpg CGCGCGCGCGCG`.




Figura 2: Distribución bimodal del ratio CpG (Obs/Exp) en el genoma humano: hipometilación protectora en promotores vs deaminación espontánea general. Figura original generada por `verification/make_figures.py`.

5 Polimorfismos de un solo nucleótido

ESENCIAL Una variante de un solo nucleótido (SNV) es una diferencia en una posición del ADN. El término **SNP** se ha reservado históricamente para SNV comunes en una población, aunque en el uso cotidiano a veces se emplea de forma más laxa. Son la clase más abundante de variación humana: dos genomas haploides difieren, como orden de magnitud, en una posición por cada mil bases. Esa densidad es una media; no implica que las diferencias estén repartidas de forma uniforme ni que cada una tenga efecto funcional.

Las variantes de un solo nucleótido (SNVs) se clasifican químicamente según la naturaleza de los anillos de las bases involucradas:

- **Transiciones** (Ti): Sustitución dentro de la misma clase estructural (purina por purina $A \leftrightarrow G$, o pirimidina por pirimidina $C \leftrightarrow T$).
- **Transversiones** (Tv): Sustitución entre clases estructurales distintas (intercambio entre purina y pirimidina, como $A \leftrightarrow C$, $A \leftrightarrow T$, $G \leftrightarrow C$, $G \leftrightarrow T$).

Las variantes de un solo nucleótido (SNVs) se categorizan químicamente en Transiciones (purina-purina o pirimidina-pirimidina) y Transversiones (intercambios purina-pirimidina).

Traza manual de clasificación de SNVs:

`classify_snv` clasifica la mutación A a G como TRANSITION y la mutación A a C como TRANSVERSION.

Se reproduce con `verification/chapter_checks.py snv A G`.

5.1 El ratio Ti/Tv como métrica de calidad en genómica

Para un lote de variantes con 4 transiciones y 2 transversiones:

$$\text{Ratio } Ti/Tv = \frac{4}{2} = 2.000000$$

Para un lote de variantes con 4 transiciones y 2 transversiones, el ratio de calidad Ti/Tv evalúa exactamente a 2.000000.

Se reproduce con `verification/chapter_checks.py titv A:G C:T G:A T:C A:C G:T`.

6 La localización de un SNP condiciona su consecuencia

ESTUDIO

En una región exónica codificante, las sustituciones se clasifican en:

1. **Sinónimas** (*synonymous*): conservan el aminoácido (por ejemplo, GAA → GAG, ambos glutamato), pero pueden afectar estabilidad del ARN, velocidad de traducción o *splicing*; «sinónima» no equivale automáticamente a «sin efecto».
2. **Cambio de sentido** (*Missense*): Sustitución aminoacídica, como la mutación drepanocítica GAG → GTG (Glu → Val) en el gen *HBB*.
3. **Sin sentido** (*Nonsense*): Codón de parada prematuro (CAG → TAG, Gln → Stop).

Fuera de la secuencia codificante, el mecanismo cambia. Un SNP en un promotor o potenciador puede crear o destruir un sitio de unión para un factor de transcripción y alterar cuánto, cuándo o dónde se expresa un gen. Uno intrónico puede modificar señales de *splicing*, elementos reguladores o no tener un efecto detectable. La posición restringe las hipótesis plausibles, pero no basta para demostrar una consecuencia.

Las variantes codificantes se categorizan funcionalmente en mutaciones sinónimas, sustituciones missense (como *HBB* Glu6Val en anemia falciforme) y codones de parada prematuros nonsense.

Traza manual de clasificación funcional de codones:

`classify_mutation` clasifica GAA a GAG como SYNONYMOUS, GAG a GTG como MISSENSE (Glu a Val) y CAG a TAG como NONSENSE (Gln a Stop).

Se reproduce con `verification/chapter_checks.py mutation GAA GAG`.

Control defensivo de codones no canónicos:

`classify_mutation` lanza `ValueError` cuando el codón contiene caracteres nucleotídicos no canónicos como X en 'GAX'.

Se reproduce con `verification/chapter_checks.py mutation GAX GAG`.

7 Del SNP asociado a la hipótesis causal: qué muestra un GWAS

Un estudio de asociación del genoma completo (GWAS) busca relaciones estadísticas entre variantes y un fenotipo a escala genómica. Su recorrido se puede descomponer en seis pasos:

1. se comparan casos y controles —o se mide un rasgo cuantitativo— y se genotipan cientos de miles o millones de variantes;
2. para cada variante se contrasta si la frecuencia alélica difiere entre grupos, corrigiendo la estructura poblacional, la calidad y el gran número de pruebas;

3. el diagrama de Manhattan coloca la posición genómica en el eje horizontal y $-\log_{10}(p)$ en el vertical; un pico localiza una región asociada, no necesariamente la variante ni el gen causal;
4. el desequilibrio de ligamiento hace que variantes vecinas viajen juntas, y el metaanálisis combina cohortes para aumentar precisión y comprobar reproducibilidad;
5. la caracterización funcional integra accesibilidad de cromatina, modificaciones de histonas, metilación del ADN, unión de factores de transcripción, conservación y eQTL;
6. ensayos celulares, edición dirigida y modelos animales prueban cuáles de las variantes candidatas modifican realmente el mecanismo.

Frecuencia alélica y tamaño de efecto tampoco son independientes: las variantes comunes suelen tener efectos pequeños, mientras que los efectos grandes aparecen con más frecuencia entre variantes raras o mutaciones de alta penetrancia. Es una tendencia poblacional, no una regla que permita clasificar una variante individual.

Atención. Una asociación estadística puede señalar la variante causal, una variante correlacionada con ella o incluso un sesgo de población. Pasar del pico del Manhattan al mecanismo exige ajuste fino, anotación funcional y validación experimental [5].

8 Variantes estructurales y firmas mutacionales

ESTUDIO

Las variantes genómicas a gran escala rebasan la resolución de los SNVs individuales, abarcando:

- **Variantes en el número de copias (CNV):** segmentos presentes en más o menos copias que en el genoma de referencia. Una definición histórica usaba el umbral de 1 kb; las convenciones actuales dependen del estudio y pueden incluir eventos menores. Comprenden deleciones y duplicaciones, y una inserción solo es CNV si cambia el número de copias. Al abarcar regiones completas pueden modificar la dosis de uno o varios genes, como las ganancias en el locus *AMY1* o las pérdidas de *CDKN2A*.
- **Reordenamientos cromosómicos complejos:** Inversiones pericéntricas y translocaciones balanceadas o desbalanceadas (como el cromosoma Filadelfia *t(9;22)(q34;q11)* que origina la oncoproteína de fusión *BCR-ABL1*).
- **Firmas mutacionales somáticas:** patrones definidos por la sustitución —por ejemplo C>T— y por las bases inmediatamente vecinas. Pueden revelar exposición a radiación ultravioleta u otros mutágenos, procesos endógenos como la desaminación espontánea de citosina, o defectos en reparación del ADN, como la recombinación homóloga dependiente de *BRCA1/2*. Su utilidad clínica potencial incluye apoyar la etiología y el diagnóstico, estratificar el pronóstico y orientar tratamientos cuando la firma informa de una vulnerabilidad reparadora.

Las variantes en el número de copias (CNVs) y las firmas mutacionales somáticas proporcionan biomarcadores genómicos para trastornos constitucionales y caracterización oncológica.

9 Dos cálculos auxiliares: CpG y clase química de una SNV

ESENCIAL

A continuación se presenta una implementación mínima de dos cálculos utilizados en el capítulo. No introduce un formato de variantes: recibe directamente una secuencia o un par de bases.

```
TRANSITIONS = {
    ('A', 'G'), ('G', 'A'),
    ('C', 'T'), ('T', 'C')
}

TRANSVERSIONS = {
    ('A', 'C'), ('C', 'A'), ('A', 'T'), ('T', 'A'),
    ('G', 'C'), ('C', 'G'), ('G', 'T'), ('T', 'G')
}
```



```

}

def calculate_cpg_ratio(sequence: str) -> float:
    """Calcula el ratio de CpG Observados respecto a Esperados (Obs/Exp)."""
    seq = sequence.strip().upper()
    n = len(seq)
    if n == 0:
        raise ValueError("Secuencia no puede estar vacia")
    count_c = seq.count('C')
    count_g = seq.count('G')
    if count_c == 0 or count_g == 0:
        return 0.0
    count_cg = sum(1 for i in range(n - 1) if seq[i:i+2] == "CG")
    expected = (count_c * count_g) / n
    return round(count_cg / expected, 6)

def calculate_titv_ratio(transitions: int, transversions: int) -> float:
    """Calcula el ratio de transiciones frente a transversiones (Ti/Tv)."""
    if transitions < 0 or transversions < 0:
        raise ValueError("Los conteos de mutaciones no pueden ser negativos")
    if transversions == 0:
        if transitions == 0:
            return 0.0
        raise ZeroDivisionError("Transversiones no pueden ser cero para calcular ratio")
    return round(transitions / transversions, 6)

def classify_snv(ref: str, alt: str) -> str:
    """Clasifica una sustitucion como transicion o transversion."""
    pair = (ref.upper(), alt.upper())
    if pair in TRANSITIONS:
        return "TRANSITION"
    if pair in TRANSVERSIONS:
        return "TRANSVERSION"
    raise ValueError("Se requieren dos bases A, C, G o T diferentes")

```

10 Peligros computacionales y actividad de depuración

Confundir transiciones con transversiones, calcular mal los dinucleótidos o convertir una asociación en causalidad produce conclusiones plausibles pero incorrectas.

10.1 Tres errores críticos en análisis genómico de variantes

Localice y corrija los tres errores en la siguiente función antes de leer el diagnóstico:

```

def interpretar_snv(ref, alt, frecuencia_casos, frecuencia_controles, secuencia):
    es_transicion = (ref, alt) in TRANSVERSIONS
    proporcion_cpg = secuencia.count("CG") / len(secuencia)
    conclusion = "causal" if frecuencia_casos > frecuencia_controles else "sin efecto"
    return es_transicion, proporcion_cpg, conclusion

```

Diagnóstico:

1. **La pertenencia está invertida.** Pregunta por TRANSVERSIONS para decidir si el cambio es una transición. La corrección es usar TRANSITIONS o llamar a classify_snv.
2. **Una proporción no es el enriquecimiento Obs/Exp.** Dividir el número de CG por la longitud ignora cuántas C y G había disponibles. Además, una secuencia de longitud N solo contiene $N - 1$ inicios posibles de dinucleótido.
3. **Diferencia de frecuencia no significa causalidad.** Antes de atribuir un mecanismo hay que cuantificar incertidumbre, controlar confusión y desequilibrio de ligamiento, replicar y validar la función.

11 Síntesis operativa y tablas de diagnóstico

11.1 Tabla de diagnóstico de discrepancias genómicas

Síntoma observado	Causa probable	Comprobación y corrección
El pico de un GWAS cambia entre cohortes	estructura poblacional, lote técnico o fenotipo definido de otro modo	ajustar covariables, inspeccionar componentes principales y replicar
El SNP más significativo no altera ningún elemento conocido	puede marcar por ligamiento otra variante causal	delimitar el bloque de ligamiento y realizar ajuste fino y anotación funcional
Fallo en detección de islas CpG	se aplicó solo uno de los criterios	verificar simultáneamente longitud, %GC y ratio Obs/Exp
La cromatina se dibuja siempre como un solenoide regular	se convirtió un modelo clásico en una estructura universal	distinguir la fibra observada <i>in vitro</i> de la organización dinámica celular
Un cambio A>C aparece como transición	se confundieron las dos clases químicas	comprobar si se conserva la familia purina/pirimidina; A>C es transversión

11.2 Tabla de síntesis: Tipos de variantes y repercusión funcional

Localización o clase	Cambio inmediato	Consecuencia posible	Límite de la inferencia
Sinónima	cambia el codón, no el aminoácido	puede afectar traducción, estabilidad o <i>splicing</i>	puede no tener efecto detectable
<i>Missense</i>	cambia un aminoácido	altera estabilidad, interacción o catálisis	el cambio de residuo no demuestra patogenicidad
<i>Nonsense</i>	introduce una parada prematura	truncamiento o degradación por NMD	depende de la posición y del transcrito
Reguladora	cambia un sitio de unión	modifica nivel, momento o tejido de expresión	requiere demostrar actividad reguladora
Intrónica	cambia una señal o elemento interno	altera <i>splicing</i> o regulación	muchas variantes intrónicas son neutras
CNV	gana o pierde copias de un segmento	cambia dosis de uno o varios genes	tamaño no equivale por sí solo a gravedad

12 Glosario conceptual

- **Nucleosoma:** Octámero de histonas envuelto por 146 pb de ADN.
- **Eucromatina:** Cromatina descondensada accesible para transcripción.
- **Heterocromatina:** Cromatina compactada transcripcionalmente silenciada.
- **H3K4me3:** Marca de histona característica de promotores activos.
- **H3K27ac:** Marca de histona característica de potenciadores activos.
- **Isla CpG:** Región que combina longitud, contenido GC y enriquecimiento CpG; su metilación depende del contexto.
- **SNP:** Variante de un solo nucleótido común en una población, en su sentido histórico estricto.
- **GWAS:** Estudio que contrasta variantes a escala genómica para detectar asociación con un fenotipo.

- **Desequilibrio de ligamiento:** Correlación entre alelos de loci próximos que dificulta identificar la variante causal.
- **CNV:** Ganancia o pérdida del número de copias de un segmento genómico.
- **Firma mutacional:** Patrón de sustituciones y contextos vecinos asociado a un proceso mutagénico.
- **Transición:** Mutación entre bases del mismo anillo ($A \leftrightarrow G, C \leftrightarrow T$).
- **Transversión:** Mutación entre purina y pirimidina.
- **Ratio Ti/Tv:** Métrica de calidad genómica ($\approx 2.0\text{--}3.0$).

13 Compruebe las conexiones antes de continuar

Compruebe. Explique en un párrafo una cadena causal posible que una estos tres conceptos: ADN no codificante, elementos transponibles y regulación génica. La respuesta debe incluir un mecanismo concreto —por ejemplo, la inserción de un promotor o potenciador móvil— y un límite: no toda secuencia no codificante es reguladora ni todo transposón modifica un gen.

Compruebe. Decida si son verdaderas o falsas y justifique cada respuesta. (1) «Un gen se define únicamente como la secuencia de exones que codifica una proteína». (2) «El ADN es químicamente menos estable que el ARN y por eso sirve como mensajero a corto plazo». Ambas son falsas: la primera omite regiones reguladoras, intrones y exones no traducidos; la segunda invierte la diferencia causada por el grupo 2'-OH del ARN.

14 Conexiones y mapa del curso

Este capítulo establece las bases cromatínicas, epigenéticas y de variación genómica requeridas para abordar la expresión génica y el transcriptoma en BC-CH03.

15 Fuentes y reproducibilidad

Los tres criterios que definen una isla CpG siguen a Gardiner-Garden y Frommer [2]; el código de histonas, a Strahl y Allis [4]; la organización no regular de la cromatina, a Nishino y colaboradores [3]; los principios de GWAS, al estudio del Wellcome Trust Case Control Consortium [5]; y la arquitectura del gen eucariota, a Alberts y colaboradores [1].

Todos los cálculos se reproducen con `verification/chapter_checks.py` tal como están impresos, con sus argumentos.

Bibliografía

- [1] Bruce Alberts, Alexander Johnson, Julian Lewis, David Morgan, Martin Raff, Keith Roberts, and Peter Walter. *Molecular Biology of the Cell*. Garland Science, 6th edition, 2014. Tratado de referencia para estructura cromatinica nucleosoma y control epigenetico.
- [2] Margaret Gardiner-Garden and Marianne Frommer. CpG islands in vertebrate genomes. *Journal of Molecular Biology*, 196(2):261–282, 1987. Criterios canonicos para la identificacion de islas CpG en promotores eucariotas.
- [3] Yoshinori Nishino, Mikhail Eltsov, Yasumasa Joti, Kazuhiro Ito, Hideaki Takata, Yoshio Takahashi, Shin-ichi Hihara, Achilleas S. Frangakis, Naoko Imamoto, Takuji Ishikawa, and Kazuhiro Maeshima. Human mitotic chromosomes consist predominantly of irregularly folded nucleosome fibres without a 30-nm chromatin structure. *The EMBO Journal*, 31(7):1644–1653, 2012.
- [4] Brian D. Strahl and C. David Allis. The language of covalent histone modifications. *Nature*, 403(6765):41–45, 2000. Articulo seminal sobre el codigo de histonas y regulacion epigenetica de la cromatina.
- [5] Wellcome Trust Case Control Consortium. Genome-wide association study of 14,000 cases of seven common diseases and 3,000 shared controls. *Nature*, 447(7145):661–678, 2007.