

Contents

1	Genomas, epigenética y variantes	1
1.1	De la biomolécula al genoma integral	1
1.2	Estructura del gen eucariota y regiones no codificantes	1
1.2.1	La fracción no codificante y la paradoja del valor C	2
1.3	Organización de la cromatina y nucleosomas	2
1.3.1	Dicotomía funcional: Eucromatina frente a Heterocromatina	3
1.4	Epigenética: el código de histonas y metilación del ADN	3
1.4.1	El código de histonas	3
1.4.2	Metilación del ADN e islas CpG	4
1.5	Variantes genéticas: taxonomía físico-química y funcional	4
1.5.1	Transiciones frente a Transversiones y el ratio Ti/Tv	5
1.5.2	Consecuencias funcionales en regiones codificantes	5
1.5.3	Validación defensiva de codones	6
1.6	El formato VCF y variantes estructurales	6
1.6.1	Variantes en el número de copias (CNVs) y firmas mutacionales	7
1.7	Diseño computacional en Python	7
1.8	Peligros computacionales en bioinformática genómica	7
1.9	Actividad de depuración: 3 errores en análisis de variantes	8
1.10	Síntesis operativa y tablas de diagnóstico	8
1.10.1	Tabla de diagnóstico de fallos en análisis genómico	8
1.10.2	Tabla de síntesis: mecanismos genómicos y firmas epigenéticas	8
1.11	Glosario conceptual	9
1.12	Cierre y conexiones hacia adelante	9
1.13	Fuentes y reproducibilidad	9
Anexo práctico · Análisis computacional de variantes genómicas y firmas epigenéticas		11

Chapter 1

Genomas, epigenética y variantes

1.1 De la biomolécula al genoma integral

En los capítulos precedentes representamos biomoléculas como polímeros aislados y objetos discretos en memoria. Sin embargo, en el contexto celular real, los genes no existen como entidades desnudas ni flotan de forma independiente: residen empaquetados en cromosomas dentro de un complejo macromolecular dinámico denominado **cromatina**, rodeados por un océano de secuencias reguladoras no codificantes y sujetos a modificaciones químicas reversibles que modulan su expresión sin alterar la secuencia primaria de bases: el nivel **epigenético**.

Esencial

Analizar un genoma computacionalmente exige integrar tres capas de información:

1. La **arquitectura génica y reguladora** (exones, intrones, promotores, potenciadores, silenciadores y aisladores).
2. El **estado epigenético** (compactación cromatínica, marcas covalentes en colas de histonas y metilación del ADN).
3. El **paisaje de variantes genéticas** (polimorfismos de nucleótido único, indels y variantes estructurales), distinguiendo variaciones biológicas genuinas de artefactos o ruido de secuenciación.

La ruta **esencial** aborda la estructura del gen eucariota, la compactación en nucleosomas, el código de histonas y metilación CpG, la clasificación físico-química de variantes (transiciones, transversiones y ratio Ti/Tv) y el impacto funcional en codones codificantes; 120–140 minutos. La ruta de **estudio** profundiza en la paradoja del valor C, elementos transponibles, formato VCF (Variant Call Format), firmas mutacionales somáticas, peligros de desfase de coordenadas 1-based frente a 0-based en Python, actividad de depuración y el anexo práctico; 60–80 minutos adicionales.

Esencial

1.2 Estructura del gen eucariota y regiones no codificantes

A diferencia de los genomas procariotas compactos y continuos, el gen eucariota es discontinuo y modular. Una unidad transcripcional canónica comprende:

- **Exones:** Segmentos de ADN que se conservan en el ARN mensajero maduro tras el proceso de corte y empalme (*splicing*), abarcando secuencias codificantes (CDS) y regiones no traducidas 5' y 3' (UTRs).
- **Intrones:** Secuencias intermedias no codificantes que se transcriben en el pre-ARNm pero son escindidas y eliminadas por el espliceosoma.

- **Promotor basal (*core promoter*):** Región situada inmediatamente aguas arriba (*upstream*, extremo 5') del sitio de inicio de la transcripción (TSS, posición +1), que contiene elementos de reconocimiento como la caja TATA (secuencia consenso TATAWAW) donde se ensambla el complejo de preiniciación de la ARN polimerasa II.
- **Potenciadores (*Enhancers*):** Elementos reguladores distales (situados a miles o decenas de miles de pares de bases aguas arriba o abajo) que reclutan factores de transcripción específicos. Mediante la formación de bucles de cromatina (*chromatin looping*) mediados por el complejo mediador y cohesinas, los *enhancers* entran en contacto físico directo con el promotor para incrementar exponencialmente la tasa de transcripción.
- **Silenciadores (*Silencers*):** Secuencias análogas a los potenciadores pero con efecto represor: reclutan factores represores que inducen la condensación local de la cromatina o impiden la unión del complejo basal.
- **Aisladores (*Insulators*):** Elementos de barrera unidos por la proteína con dedos de zinc **CTCF** que delimitan los dominios de asociación topológica (TADs). Su función es evitar la activación espuria de promotores por parte de *enhancers* adyacentes pertenecientes a dominios vecinos.

La arquitectura del gen eucariota comprende exones codificantes, intrones, promotores basales, potenciadores distales, silenciadores y aisladores CTCF que delimitan dominios topológicos.

1.2.1 La fracción no codificante y la paradoja del valor C

En el genoma humano ($\approx 3.2 \times 10^9$ pb), las secuencias que codifican directamente proteínas (el exoma) representan únicamente aproximadamente el **1.5%-2%** del total. El restante **98%** no codificante alberga elementos reguladores, ARNs no codificantes (microARNs, lncARNs) y una vasta proporción de **elementos transponibles** (transposones de ADN y retrotransposones LINEs y SINEs como los elementos *Alu*), que constituyen más del 45% del genoma humano.

La falta de correlación directa entre el tamaño total del genoma (el valor C) y la complejidad morfológica o fisiológica de un organismo constituye la denominada **paradoja del valor C**: especies morfológicamente simples como algunas amebas o plantas angiospermas poseen genomas órdenes de magnitud más grandes que los mamíferos, debido a la acumulación diferencial de secuencias repetitivas y duplicaciones genómicas.

La fracción no codificante constituye aproximadamente el 98% del genoma humano, enriquecida en elementos transponibles (LINEs, SINEs/*Alu*) y explicando la paradoja del valor C.

1.3 Organización de la cromatina y nucleosomas

En el núcleo celular eucariota, el ADN bicatenario se empaqueta en múltiples niveles jerárquicos de condensación:

1. **El nucleosoma:** Constituye la unidad fundamental y repetitiva de la cromatina. Consta de un octámero de proteínas básicas (**histonas**: dos copias de cada una de H2A, H2B, H3 y H4) alrededor del cual se enrollan **146** pares de bases de ADN en 1.65 vueltas superhelicoidales levógiras. Los nucleosomas adyacentes quedan conectados por ADN espaciador (*linker DNA*, $\approx 20-80$ pb) estabilizado por la histona de unión H1.
2. **Fibra de cromatina y dominios en bucle:** El ensamblaje de nucleosomas en conformación de “cuentas de collar” (10 nm) se pliega en fibras de orden superior (30 nm) y dominios topológicos estructurados (TADs) anclados a la lámina nuclear.

1.3.1 Dicotomía funcional: Eucromatina frente a Heterocromatina

La cromatina oscila dinámicamente entre dos estados conformacionales:

- **Eucromatina:** Estado descondensado y abierto de la cromatina, caracterizado por una alta accesibilidad física para la maquinaria de transcripción. Se asocia con genes activos o transcripcionalmente permisivos.
- **Heterocromatina:** Estado altamente compactado e inaccesible que reprime la transcripción. Se divide en:
 - *Constitutiva:* Permanentemente silenciada y estructural (centrómeros, telómeros y regiones pericentroméricas ricas en repeticiones).
 - *Facultativa:* Regiones que alternan entre condensación y descondensación según el tipo celular, estado de diferenciación o estímulos ambientales (p. ej., la inactivación del cromosoma X en hembras de mamíferos).

La cromatina se organiza en nucleosomas repetitivos (146 pb alrededor de un octámero de histonas) y se bifurca en eucromatina transcripcionalmente permisiva y heterocromatina compactada represiva.

1.4 Epigenética: el código de histonas y metilación del ADN

La **epigenética** estudia los cambios heredables en la expresión génica que ocurren sin alteraciones en la secuencia primaria de nucleótidos del ADN. Los dos mecanismos moleculares centrales son:

1.4.1 El código de histonas

Las colas N-terminales de las histonas proyectan fuera del núcleo del nucleosoma y sufren modificaciones postraduccionales covalentes reversibles:

- **Acetilación de lisinas (p. ej., H3K27ac, H3K9ac):** Catalizada por histona acetiltransferasas (HATs). Neutraliza la carga positiva del grupo amino de la lisina, reduciendo su atracción electrostática hacia el esqueleto de fosfatos del ADN (cargado negativamente), lo que relaja la estructura cromatínica hacia eucromatina y actúa como interruptor de encendido (*ON*) transcripcional.
- **Metilación de lisinas (p. ej., H3K4me3 vs H3K9me3/H3K27me3):** Catalizada por histona metiltransferasas (HMTs). Dependiendo del residuo y del grado de metilación (mono, di o trimetilación):
 - H3K4me3 se localiza típicamente en promotores activos y abiertos.
 - H3K9me3 y H3K27me3 reclutan proteínas represoras como HP1 o complejos Polycomb (PRC2), induciendo heterocromatina y silenciamiento génico (*OFF*).

El código de histonas modula la accesibilidad cromatínica mediante modificaciones covalentes donde la hiperacetilación (H3K27ac) y H3K4me3 promueven la activación génica, mientras que H3K9me3 y H3K27me3 median la represión transcripcional.

1.4.2 Metilación del ADN e islas CpG

La metilación del ADN en vertebrados consiste en la adición covalente de un grupo metilo ($-\text{CH}_3$) en el carbono 5 del anillo de la citosina para formar **5-metilcitosina (5mC)**, catalizada por ADN metiltransferasas (DNMTs). Ocurre casi exclusivamente en dinucleótidos simétricos **CpG** ($5' - \text{C} - \text{fosfato} - \text{G} - 3'$).

En el genoma de mamíferos, la mayoría de los sitios CpG dispersos están metilados de forma basal. Sin embargo, existen regiones densamente pobladas por dinucleótidos CpG denominadas **Islas CpG** (*CpG Islands*), localizadas frecuentemente en promotores génicos:

- En condiciones fisiológicas basales, las islas CpG promotoras se mantienen **hipometiladas** (no metiladas), permitiendo la unión de factores transcripcionales.
- La **hipermetilación aberrante** de una isla CpG promotora (típica en genes supresores de tumores durante la oncogénesis) recluta proteínas de unión a metil-CpG (MeCP2) y de-sacetilasas de histonas (HDACs), provocando el silenciamiento transcripcional permanente del gen.

Métrica bioinformática de Gardiner-Garden & Frommer (1987): Una región se define computacionalmente como isla CpG si cumple:

1. Longitud $L \geq 200$ pb (a menudo $L \geq 500$ pb).
2. Contenido GC% $\geq 50\%$: $\frac{C+G}{N} \times 100 \geq 50\%$.
3. Ratio de CpG observados frente a esperados $\text{Obs/Exp} \geq 0.60$:

$$\text{Obs/Exp} = \frac{\text{Conteo('CG')}}{\frac{\text{Conteo(C)} \times \text{Conteo(G)}}{N}}$$

La metilación del ADN en dinucleótidos CpG silencia promotores génicos; las islas CpG se identifican computacionalmente mediante un ratio $\text{Obs/Exp} \geq 0.60$ y un contenido GC $\geq 50\%$.

Ejemplo computable sobre secuencia modelo: Para la secuencia sintética $S = \text{'CGCGCGCGCGCG'}$ ($N = 12$ pb):

- $C = 6, G = 6 \implies \text{GC\%} = \frac{6+6}{12} \times 100 = \mathbf{100.00\%}$.
- Dinucleótidos CpG observados ('CG' no solapantes): **6**.
- CpG esperados: $\frac{6 \times 6}{12} = \frac{36}{12} = \mathbf{3.0}$.
- Ratio Obs/Exp: $\frac{6.0}{3.0} = \mathbf{2.000000}$.

Para la secuencia modelo **CGCGCGCGCGCG** de longitud 12, el ratio Obs/Exp de CpG evalúa exactamente a 2.000000 con un contenido GC del 100.00%. Se reproduce con `verification/chapter_checks.py` `cpg CGCGCGCGCGCG`.

1.5 Variantes genéticas: taxonomía físico-química y funcional

Una variante genética es una alteración en la secuencia de nucleótidos del ADN respecto a un genoma de referencia de la especie. Distinguimos:

- **Polimorfismo de nucleótido único (SNP):** Variante puntual presente en al menos el 1% de la población general ($\text{MAF} \geq 0.01$).
- **Variante de nucleótido único (SNV):** Término genérico para cualquier cambio de una base individual, incluidas mutaciones raras o mutaciones somáticas en cáncer.

1.5.1 Transiciones frente a Transversiones y el ratio Ti/Tv

Las sustituciones nucleotídicas se clasifican químicamente en:

1. **Transiciones (Ti):** Sustitución entre bases del mismo anillo químico:
 - Purina a Purina: $A \leftrightarrow G$.
 - Pirimidina a Pirimidina: $C \leftrightarrow T$.
 - (Total: 4 posibles pares ordenados).
2. **Transversiones (Tv):** Sustitución entre bases de diferente anillo químico:
 - Purina a Pirimidina o viceversa: $A \leftrightarrow C$, $A \leftrightarrow T$, $G \leftrightarrow C$, $G \leftrightarrow T$.
 - (Total: 8 posibles pares ordenados).

Las variantes puntuales (SNVs) se clasifican químicamente en Transiciones (purina a purina o pirimidina a pirimidina) y Transversiones (intercambio purina-pirimidina).

Aunque puramente al azar cabría esperar el doble de transversiones que de transiciones (ratio estocástico $Ti/Tv = 4/8 = 0.5$), en los genomas biológicos reales las transiciones son mucho más frecuentes debido a mecanismos bioquímicos espontáneos como la desaminación de la 5-metilcitosina a timina. En consecuencia, el ratio de calidad de llamadas de variantes (**ratio** Ti/Tv) constituye una métrica estándar en bioinformática genómica:

- Genoma completo humano (WGS): $Ti/Tv \approx 2.0$ – 2.1 .
- Exoma codificante (WES): $Ti/Tv \approx 2.8$ – 3.2 (debido a la fuerte presión de selección purificadora que tolera mejor transiciones sinónimas).
- Ratios significativamente inferiores a 2.0 denotan una alta tasa de falsos positivos o errores de secuenciación.

`classify_snv` clasifica la mutación A a G como TRANSITION y la mutación A a C como TRANSVERSION. Se reproduce con `verification/chapter_checks.py snv A G y snv A C`.

Cálculo computable de Ti/Tv : Para un lote con 4 transiciones ($A \rightarrow G, G \rightarrow A, C \rightarrow T, T \rightarrow C$) y 2 transversiones ($A \rightarrow C, T \rightarrow G$):

$$\text{Ratio } Ti/Tv = \frac{Ti}{Tv} = \frac{4}{2} = \mathbf{2.000000}$$

Para un lote de 4 transiciones y 2 transversiones, el ratio de calidad Ti/Tv evalúa exactamente a 2.000000. Se reproduce con `verification/chapter_checks.py titv A:G G:A C:T T:C A:C T:G`.

1.5.2 Consecuencias funcionales en regiones codificantes

Cuando una mutación ocurre dentro de un marco abierto de lectura (ORF), su impacto en el código genético determina su categoría funcional:

- **Mutación sinónima o silenciosa (*Synonymous*):** El cambio de base genera un codón sinónimo que codifica el mismo aminoácido debido a la degeneración del código genético (p. ej., $GAA \rightarrow GAG$, ambos codifican Ácido Glutámico, E).

- **Mutación de cambio de sentido (*Missense*):** El codón mutado codifica un aminoácido diferente. Un ejemplo paradigmático es la mutación de la **anemia falciforme o drepanocitosis** en el gen de la β -globina (*HBB*, posición c.20A>T), donde el codón GAG (Glutamato, polar con carga negativa) muta a GTG (Valina, hidrofóbico no polar), alterando la solubilidad de la hemoglobina y provocando su polimerización en fibras desoxigenadas.
- **Mutación sin sentido (*Nonsense*):** La sustitución crea un codón de parada prematuro (UAA, UAG, UGA; p. ej., CAG $\rightarrow$ TAG, pasando de Glutamina a STOP), truncando la proteína y provocando habitualmente la degradación del ARNm por el mecanismo de *Nonsense-Mediated Decay* (NMD).

Las variantes codificantes se categorizan funcionalmente en mutaciones sinónimas, de cambio de sentido (como Glu6Val en anemia falciforme) y sin sentido con codón STOP prematuro.

`classify_mutation` clasifica GAA a GAG como SYNONYMOUS, GAG a GTG como MISSENSE (Glu a Val) y CAG a TAG como NONSENSE (Gln a STOP). Se reproduce con `verification/chapter_checks.py mutation GAG GTG`.

1.5.3 Validación defensiva de codones

`classify_mutation` lanza `ValueError` ante codones que contienen caracteres no canónicos como 'X' en GAX. Se reproduce con `verification/practice_checks.py domain_guard -ref GAX -alt GTG`.

1.6 El formato VCF y variantes estructurales

El formato estándar internacional para el intercambio de variantes genómicas es el **Variant Call Format (VCF)** (Danecek et al., 2011). Un registro VCF contiene 8 columnas obligatorias tabuladas:

1. **#CHROM:** Identificador del cromosoma o contig de referencia (p. ej., `chr11`).
2. **POS:** Posición física genómica 1-based del primer nucleótido de la referencia.
3. **ID:** Identificador único de la variante en bases de datos públicas (p. ej., `rs334` en dbSNP).
4. **REF:** Alelo de referencia observado en el genoma de ensamblaje.
5. **ALT:** Uno o más alelos alternativos observados en las lecturas de secuenciación.
6. **QUAL:** Puntuación Phred de calidad de la llamada de variante ($-10 \log_{10} P(\text{error})$).
7. **FILTER:** Estado del filtro (PASS si superó los umbrales de calidad, o nombre del filtro suspensor).
8. **INFO:** Metadatos adicionales codificados en pares clave-valor estructurados.

El analizador de formato VCF procesa cromosomas, posiciones 1-based, alelos REF y ALT, clasificando la variante de drepanocitosis `rs334` (T a A) como TRANSVERSION. Se reproduce con `verification/chapter_checks.py vcf "chr11 5227002 rs334 T A 100.0 PASS GENE=HBB"`.

1.6.1 Variantes en el número de copias (CNVs) y firmas mutacionales

Más allá de los cambios puntuales, los genomas sufren alteraciones estructurales mayores:

- **CNVs (Copy Number Variants):** Duplicaciones o deleciones de segmentos genómicos grandes (> 1 kb), que alteran la dosis génica y constituyen una fuente primaria de susceptibilidad genética a enfermedades complejas.
- **Firmas mutacionales somáticas (COSMIC):** Patrones matemáticos distintivos de sustituciones en tripletes de nucleótidos (contexto de bases 5' y 3') generados por procesos mutagénicos específicos como la exposición a radiación UV (transiciones $C \rightarrow T$ en dipirimidinas) o la hiperactividad de citidina desaminasas de la familia APOBEC.

Las variantes en el número de copias (CNVs) y las firmas mutacionales somáticas proporcionan biomarcadores genómicos para patologías constitucionales y caracterización oncológica.

1.7 Diseño computacional en Python

Presentamos un módulo reproducible de análisis de variantes:

Listing 1.1: Módulo de clasificación de variantes y cálculo de Ti/Tv en Python.

```
PURINES = {"A", "G"}
PYRIMIDINES = {"C", "T"}

def classify_snv(ref: str, alt: str) -> str:
    """Clasifica una sustitucion puntual en transicion o transversion."""
    r, a = ref.upper(), alt.upper()
    if r not in (PURINES | PYRIMIDINES) or a not in (PURINES | PYRIMIDINES):
        raise ValueError(f"Nucleotido no canonico: ref={ref}, alt={alt}")
    if (r in PURINES and a in PURINES) or (r in PYRIMIDINES and a in PYRIMIDINES):
        return "TRANSITION"
    return "TRANSVERSION"

def titv_ratio(variant_pairs: list[tuple[str, str]]) -> float:
    """Calcula el ratio Ti/Tv para un conjunto de variantes."""
    ti = sum(1 for r, a in variant_pairs if classify_snv(r, a) == "TRANSITION")
    tv = len(variant_pairs) - ti
    if tv == 0:
        return float("inf")
    return ti / tv
```

1.8 Peligros computacionales en bioinformática genómica

1. **Desfase de indexación 1-based frente a 0-based:** El formato VCF, SAM/BAM y GFF utilizan coordenadas **1-based** cerradas ($[1, N]$), mientras que los rangos de Python, el formato BED y las librerías en C operan con indexación **0-based semiabierto** ($[0, N)$). Confundir ambos sistemas provoca desfases de un nucleótido (*off-by-one errors*) que destruyen la anotación de variantes puntuales.
2. **Incompatibilidad de hebras (*Strandedness*):** Los archivos VCF reportan las variantes con respecto a la hebra positiva (+) de referencia del genoma. Si un gen se transcribe en la hebra reversa (−), evaluar el codón directamente en la secuencia del VCF sin computar el complemento reverso asigna erróneamente la consecuencia funcional del aminoácido.

La discrepancia entre coordenadas 1-based de archivos VCF y la indexación 0-based de Python, junto a la orientación de hebra genómica, constituyen fuentes críticas de error computacional.

1.9 Actividad de depuración: 3 errores en análisis de variantes

Localice los tres errores en la siguiente función:

Listing 1.2: Funcion con 3 errores de logica genomica.

```
def analyze_vcf_records(records):
    # Error 1: clasifica C->A como transicion
    transitions = 0
    for r in records:
        ref, alt = r["ref"], r["alt"]
        if (ref == "C" and alt == "A"): # Error: C->A es transversion
            transitions += 1
    # Error 2: division por cero no controlada si tv == 0
    tv = len(records) - transitions
    ratio = transitions / tv
    # Error 3: asume que la posicion 1-based del VCF mapea directamente a indice 0
    return ratio
```

1.10 Síntesis operativa y tablas de diagnóstico

1.10.1 Tabla de diagnóstico de fallos en análisis genómico

Síntoma observado	Causa probable	Comprobación y corrección
El aminoácido anotado no coincide con la referencia del gen	Extracción de secuencia en hebra opuesta sin calcular complemento reverso	Verificar anotación <code>strand='-'</code> y aplicar <code>reverse_complement()</code>
La variante cae fuera del exón por exactamente 1 base	Desfase de coordenadas 1-based de VCF frente a 0-based en Python	Convertir posición VCF restando 1: <code>idx = vcf_pos - 1</code>
Ratio $Ti/Tv \approx 0.5$ en llamada de variantes de exoma	Alta tasa de falsos positivos o ruido de secuenciación	Aplicar filtros de calidad <code>QUAL</code> ≥ 30 y profundidad <code>DP</code> ≥ 10
<code>KeyError</code> en traducción de codón	Presencia de nucleótido degenerado o IUPAC ('N', 'R', 'Y')	Sanitizar secuencia y validar alfabeto canónico estricto

1.10.2 Tabla de síntesis: mecanismos genómicos y firmas epigenéticas

Mecanismo / Elemento	Función molecular	Repercusión computacional
Aislador CTCF	Barrera entre dominios topológicos (TADs)	Delimita el espacio de búsqueda de pares <i>enhancer</i> -promotor
Marca H3K27ac	Marcador de <i>enhancers</i> y promotores activos	Pico de señal en experimentos ChIP-seq de eucromatina
Isla CpG	Región promotora rica en dinucleótidos CG	Clasificación por ratio <code>Obs/Exp</code> ≥ 0.6 y <code>GC</code> $\geq 50\%$

Mecanismo / Elemento	Función molecular	Repercusión computacional
Ratio Ti/Tv	Control de calidad bioinformático de llamadas	Valores esperados: ≈ 2.0 – 2.1 (WGS), ≈ 3.0 (WES)

1.11 Glosario conceptual

- **Exón:** segmento génico conservado en el ARNm maduro.
- **Intrón:** secuencia no codificante eliminada por *splicing*.
- **Potenciador (*Enhancer*):** elemento regulador distal activador.
- **Aislador (*Insulator*):** elemento de barrera unido por CTCF.
- **Nucleosoma:** octámero de histonas envuelto por 146 pb.
- **Eucromatina:** cromatina abierta accesible a transcripción.
- **Heterocromatina:** cromatina compacta transcripcionalmente inactiva.
- **Código de histonas:** modificaciones covalentes reguladoras.
- **5-metilcitosina:** adición epigenética de $-\text{CH}_3$ en citosinas CpG.
- **Isla CpG:** región rica en CG con ratio Obs/Exp ≥ 0.60 .
- **Transición:** mutación purina-purina o pirimidina-pirimidina.
- **Transversión:** intercambio entre purina y pirimidina.
- **Formato VCF:** especificación estándar de variantes genómicas.

1.12 Cierre y conexiones hacia adelante

Este capítulo establece los fundamentos del análisis genómico y epigenético, sirviendo de base directa para el modelado de la expresión génica y la transcriptómica en BC-CH04.

En el siguiente capítulo (**BC-CH04: Expresión génica, transcriptómica y redes de regulación**), analizaremos cómo estas variantes y modificaciones epigenéticas modulan los niveles cuantitativos de ARN mensajero a escala masiva.

1.13 Fuentes y reproducibilidad

Este capítulo se fundamenta en las diapositivas docentes (20250913_gen (1).pptx, Álvaro Serrano Navarro), en la especificación del formato VCF (Danecek et al., 2011), en el código de histonas (Strahl & Allis, 2000) y en Gardiner-Garden & Frommer (1987). Todos los cálculos se reproducen mediante `verification/chapter_checks.py`.

Anexo práctico · Análisis computacional de variantes genómicas y firmas epigenéticas

Pregunta, producto y separación de materiales

¿Puede implementar un módulo en Python que parsee registros de variantes en formato VCF, clasifique sustituciones en transiciones y transversiones, evalúe el impacto funcional de mutaciones codificantes y determine la métrica de islas CpG sin recurrir a paquetes externos opacos? Este laboratorio responde afirmativamente de forma totalmente reproducible.

El producto individual contiene: el análisis de la variante patogénica de drepanocitosis rs334, la clasificación de consecuencias funcionales de codones, el cálculo del ratio de calidad Ti/Tv , la perturbación de lotes, el control de excepciones de la guarda de dominio y la defensa conceptual escrita.

El anexo es autónomo e independiente: no requiere paquetes externos. Emplea `verification/practice_checks` como oráculo determinista.

Mapa de ruta, tiempos y dedicación

Bloque de trabajo	Minutos	Producto entregable
1 · Entorno y diagnóstico	5	Comprobación del intérprete Python 3.9
2 · Cálculo ancla (VCF y Codón)	20–25	Parsing de rs334 , GAG → GTG y Ti/Tv base
3 · Perturbación del ratio Ti/Tv	15–20	Evaluación con transversión adicional
4 · Métricas de islas CpG	15–20	Cálculo de ratio Obs/Exp y GC%
5 · Guarda de dominio	10–15	Captura de ValueError ante codón GAX
6 · Preguntas de control epigenético	5–10	Preguntas sobre código de histonas y VCF
7 · Verificación y empaquetado	5	Comprobación final y empaquetado

La ruta de este anexo suma 75–100 minutos y produce evidencia comprobable y verificable en cada bloque de trabajo sin paquetes externos.

1 · Entorno y diagnóstico

Verifique que su entorno dispone de Python 3.9 o superior:

Listing 1.3: Comprobacion de interprete y oraculo.

```
python3 --version
python3 verification/practice_checks.py --help
```

2 · Cálculo ancla: VCF, mutación codificante y ratio Ti/Tv

Dado el registro VCF de la mutación de la drepanocitosis (**rs334**, gen *HBB*):

1. Parsee los campos cromosómicos: cromosoma **chr11**, posición **5227002**, alelos REF = T y ALT = A (clasificada como **Transversión**).
2. Evalúe el efecto de la mutación codificante en el codón 6: GAG(E) → GTG(V), clasificada como **Missense**.
3. Calcule el ratio Ti/Tv para un lote base de 4 transiciones (A:G, G:A, C:T, T:C) y 2 transversiones (A:C, T:G): $4/2 = \mathbf{2.000000}$.

Listing 1.4: Ejecucion del calculo ancla.

```
python3 verification/practice_checks.py anchor
```

El registro ancla VCF **rs334** produce una mutación de tipo transversión, efecto de codón MISSENSE (Glu a Val) y un ratio base $Ti/Tv = 2.000000$. Se reproduce con `verification/practice_checks.py anchor`.

3 · Perturbación del ratio Ti/Tv

Añada una transversión adicional (G:C) al lote anterior (4 transiciones y 3 transversiones):

Listing 1.5: Perturbacion de variantes y calculo de Ti/Tv .

```
python3 verification/practice_checks.py perturbation
```

La perturbación del lote con una transversión adicional G a C evalúa a 4 transiciones y 3 transversiones, produciendo un ratio $Ti/Tv = 1.333333$. Se reproduce con `verification/practice_checks.py perturbation`.

4 · Guarda de dominio y control de excepciones

Compruebe que el evaluador rechaza codones con nucleótidos no canónicos:

Listing 1.6: Guarda de dominio ante codones invalidos.

```
python3 verification/practice_checks.py domain_guard --ref GAX --alt GTG
```

La guarda de dominio rechaza el codón no válido **GAX** lanzando un **ValueError** que identifica el codón no canónico. Se reproduce con `verification/practice_checks.py domain_guard --ref GAX --alt GTG`.

5 · Verificación y entrega

La verificación de entrega confirma la ejecución autónoma bajo el intérprete estándar de Python 3.9 sin librerías externas opacas.

Rúbrica de calificación ponderada

La evaluación sobre 10 puntos se pondera según:

- **4.0 puntos (40%):** Ejecución correcta y reproducible de los scripts de comprobación (`chapter_checks.py` y `practice_checks.py`).
- **2.0 puntos (20%):** Parsing exacto del registro VCF **rs334** y cálculo del ratio $Ti/Tv = 2.000000$ (Bloque 2).
- **2.0 puntos (20%):** Evaluación de perturbación de variantes y control de excepciones en la guarda de dominio (Bloques 3 y 4).
- **2.0 puntos (20%):** Defensa conceptual escrita (100–150 palabras) sobre el ratio Ti/Tv como indicador de calidad bioinformática y la dicotomía epigenética eucromatina/heterocromatina.

Lista de autocorrección

- Verifiqué que mi versión de Python es ≥ 3.9 .
- Parsee correctamente el registro **rs334** en VCF.
- Clasifiqué T→A como transversión.
- El efecto de GAG→GTG fue MISSENSE.
- El ratio Ti/Tv del lote base fue 2.000000.
- El ratio perturbado fue 1.333333.
- Verifiqué que GAX lanza `ValueError`.
- Redacté la defensa conceptual individual.

Defensa conceptual

En 100–150 palabras, explique por qué el ratio empírico Ti/Tv en exomas humanos ronda valores entre 2.8–3.2 en lugar del ratio estocástico teórico 0.5, y cómo las modificaciones postraduccionales de histonas (acetilación frente a metilación) coordinan la apertura física de la cromatina.

Fuentes y reproducibilidad

Este anexo se fundamenta en las diapositivas docentes de genética y genómica (20250913_gen(1).pptx), en la especificación del formato VCF (Danecek et al., 2011) y en el código de histonas (Strahl & Allis, 2000), y se valida al 100% mediante `verification/practice_checks.py`.