

Genomas, epigenética y variantes: Arquitectura cromatínica, dinámica de CpG y caracterización computacional de variantes

BC-CH03 – Biología Computacional

Edición 2 · 2026-09-03

Pregunta del tema. Solo el dos por ciento del genoma humano codifica proteínas. ¿Qué hace el resto, y cómo se decide si un cambio de una sola letra en cualquier punto de esos tres mil millones importa o no?

Producto final. Un procesador de variantes escrito por usted que lea el formato estándar, convierta bien las coordenadas, clasifique cada cambio y calcule el indicador de calidad del lote, avisando cuando se sale de lo esperado.

Mapa del tema

1. La arquitectura física y funcional del genoma eucariota	1
2. Estructura de la cromatina: Nucleosomas y empaquetamiento	3
3. El código epigenético y modificaciones de histonas	4
4. Variantes genéticas: Clasificación física y espectro mutacional	5
5. Consecuencias funcionales en regiones codificantes	6
6. El formato estándar Variant Call Format (VCFv4.2)	6
7. Variantes estructurales y firmas mutacionales	7
8. Diseño computacional en Python: Procesador de variantes y CpG	7
9. Peligros computacionales y actividad de depuración	8
10. Síntesis operativa y tablas de diagnóstico	9
11. Glosario conceptual	9
12. Conexiones y mapa del curso	10
13. Fuentes y reproducibilidad	10

Cómo usar este tema

Este capítulo es el mapa del territorio sobre el que trabajan todos los demás. Empieza por el continente, el genoma y su composición; sigue por cómo se empaqueta y cómo ese empaquetamiento regula qué se lee; y termina en la unidad mínima de variación, el cambio de una sola base, con el formato en que se anota y el control de calidad que permite saber si un lote de variantes es creíble.

Al terminar sabrá: decir qué proporción del genoma es qué, y qué hace la parte que no codifica; explicar por qué una isla CpG se define por densidad y no por presencia; leer una línea de un fichero de variantes y saber en qué base empieza a contar; clasificar un cambio como transición o transversión y decir por qué esa distinción es un control de calidad; y no confundir «la variante está en un gen» con «la variante causa la enfermedad».

La ruta **esencial** son la composición del genoma, la cromatina, las islas CpG y la variación con su formato. La ruta de **estudio** añade el código de histonas, la paradoja del valor C, las consecuencias funcionales y el anexo.

1 La arquitectura física y funcional del genoma eucariota

ESENCIAL En los capítulos precedentes hemos establecido los principios bioquímicos y computacionales para modelar secuencias discretas y objetos proteicos aislados. Sin embargo, en los organismos eucariotas superiores, el genoma dista radicalmente de ser un texto plano continuo de genes contiguos. Muy al contrario, el genoma humano (con sus $\approx 3.2 \times 10^9$ pares de bases por genoma haploide) presenta una arquitectura modular discontinua, tridimensionalmente organizada y densamente regulada en el espacio y en el tiempo:

1. **Estructura génica discontinua (mosaico exón-intrón):** Descubierta en 1977 por Phillip Sharp y Richard Roberts (Premio Nobel en 1993), los genes codificantes eucariotas están fragmentados en segmentos expresados (**exones**) separados por extensas regiones intercaladas no codificantes (**intrones**). Estos intrones

son reconocidos y escindidos con precisión de un solo nucleótido por la maquinaria del espliceosoma (*spliceosome*) durante el procesamiento del pre-ARN mensajero.

2. **Promotores basales y distales:** Secuencias reguladoras adyacentes al sitio de inicio de la transcripción (*Transcription Start Site*, TSS), como la caja TATA (*TATA box*), el elemento iniciador (Inr) y los elementos de reconocimiento río arriba (BRE), que reclutan los factores generales de transcripción (TFIIA-H) y la ARN Polimerasa II.
3. **Potenciadores (*Enhancers*) y Silenciadores:** Módulos reguladores en *cis* situados a decenas o centenares de kilobases de distancia (río arriba, río abajo o en el interior de intrones) que interactúan físicamente con el promotor génico mediante bucles espaciales de cromatina para modular la tasa de transcripción de forma tejido-específica.
4. **Aisladores de frontera (*Insulators*) y factores CTCF:** Secuencias fijadoras de la proteína con dedos de zinc CTCF que, junto con el complejo molecular de la cohesina, delimitan los **dominios de asociación topológica (TADs)**, impidiendo que los potenciadores de un microdominio activen espuriamente promotores de regiones vecinas.

La arquitectura génica eucariota comprende exones codificantes, intrones no codificantes, promotores basales, potenciadores distales, silenciadores y elementos aisladores de frontera CTCF.

1.1 La paradoja del valor C y la fracción no codificante

Durante décadas se asumió erróneamente que la complejidad anatómica y funcional de una especie debía correlacionar linealmente con el tamaño total de su genoma (la cantidad total de ADN por célula haploide, denominada **valor C**). Sin embargo, la secuenciación comparada reveló que organismos morfológicamente sencillos tienen genomas mucho mayores que el humano. La planta *Paris japonica*, con unos 150 Gb repartidos en apenas veinte cromosomas, tiene cincuenta veces más ADN que nosotros, que rondamos los 3,2 Gb. Ese desacoplamiento entre tamaño del genoma y complejidad del organismo se conoce como la **paradoja del valor C**.

Atención. Circulan cifras aún más extremas, como los 670 Gb que suelen atribuirse a la ameba *Polychaos dubium*. Proceden de estimaciones por densitometría de los años sesenta que nunca se han confirmado con métodos actuales, y las bases de datos de tamaños genómicos las marcan como no fiables. Conviene no usarlas como dato, aunque sean el ejemplo más citado: un argumento correcto no necesita apoyarse en una medida dudosa, y *Paris japonica* sirve igual de bien.

En el genoma humano, **únicamente el $\approx 1.5\text{--}2.0\%$ de la secuencia codifica directamente para cadenas polipeptídicas** (lo que constituye el exoma humano, ≈ 30 Mb). El $\approx 98\%$ restante es **ADN no codificante**, densamente poblado por:

- **Elementos transponibles y retrotransposones:** Secuencias móviles repetitivas que han colonizado el genoma a lo largo de la evolución, incluyendo elementos nucleares intercalados largos (LINEs, $\approx 21\%$, destacando LINE-1 de ≈ 6 kb), elementos intercalados cortos (SINEs, $\approx 13\%$, como los elementos Alu de ≈ 300 pb) y retrovirus endógenos humanos (HERVs, $\approx 8\%$).
- **Regiones reguladoras en cis:** Cientos de miles de promotores no codificantes, potenciadores y genes de ARNs funcionales no traducidos (microARNs, lncRNAs, circRNAs, ARNs nucleolares snoRNAs).
- **ADN estructural heterocromático:** Centrómeros satélite y telómeros repetitivos indispensables para la integridad estructural y la segregación cromosómica durante la mitosis.

Concepto. De los elementos transponibles se suele decir cuánto ocupan y no qué hacen, que es lo interesante. Hacen tres cosas. **Mutan:** al insertarse dentro de un gen lo interrumpen, y hay enfermedades humanas causadas exactamente así, por una copia de un elemento que aterrizó donde no debía. **Reorganizan:** dos copias del mismo elemento en posiciones distintas ofrecen a la maquinaria de recombinación dos secuencias idénticas donde emparejarse mal, y de ahí salen duplicaciones y deleciones grandes. **Aportan material:** algunas de sus secuencias han acabado siendo promotores y potenciadores de genes propios, y hasta genes completos han surgido por domesticación de un transposón. No son basura, y tampoco son un adorno: son una fuerza evolutiva activa.

Atención. Para el análisis computacional tienen una consecuencia inmediata: al haber cientos de miles de copias casi idénticas repartidas por el genoma, una lectura corta que caiga en una de ellas se alinea igual de bien en muchos sitios. Por eso los programas de alineamiento informan de la calidad de mapeo, y por eso las regiones repetitivas son las que peor se ensamblan.

La fracción no codificante representa aproximadamente el 98% del genoma humano, enriquecida en elementos transponibles (LINEs, SINEs/Alu) y sustentando la paradoja del valor C.

2 Estructura de la cromatina: Nucleosomas y empaquetamiento

ESENCIAL

En el núcleo de una sola célula humana diploide, el ADN extendido alcanzaría una longitud física de ≈ 2 metros lineales. Este colosal polímero debe empaquetarse de manera no entrópica en un volumen nuclear esférico microscópico de apenas 5–10 μm de diámetro, garantizando al mismo tiempo que regiones génicas específicas permanezcan dinámicamente accesibles para la replicación y la transcripción. Este prodigio biofísico de compactación se logra mediante la **cromatina**, un complejo supramolecular de ADN y proteínas estructurales especializadas denominadas **histonas**.

2.1 El nucleosoma: unidad fundamental de empaquetamiento

La unidad estructural básica y repetitiva de la cromatina es el **nucleosoma**. Está constituido por un núcleo proteico globular o **octámero de histonas** integrado por dos copias estequiométricas de cada una de las cuatro histonas nucleares centrales:

$$\text{Octámero central} = 2 \times (\text{H2A} + \text{H2B} + \text{H3} + \text{H4})$$

Alrededor de este octámero globular, densamente poblado por aminoácidos básicos cargados positivamente (Lisina y Arginina), la doble hélice de ADN (cargada negativamente por sus grupos fosfato en el esqueleto) se enrolla dando exactamente 1.65 **vueltas de superhélice levógira**, abarcando **146 pares de bases**. Los nucleosomas contiguos se conectan mediante segmentos de **ADN espaciador** (*linker DNA*) de 20–80 pb, asociados a la histona de unión **H1**, originando la clásica fibra conformacional de 10 nm ("collar de cuentas" o *beads-on-a-string*).

El nucleosoma consiste en un octámero de histonas (2 copias de H2A, H2B, H3 y H4) alrededor del cual el ADN da aproximadamente 1,65 vueltas de superhélice levógira, abarcando entre 146 y 147 pares de bases según la estructura de referencia que se tome.



Figura 1: Estructura supramolecular del nucleosoma (octámero central y 146 pb de ADN) y modificación postraduccional de colas de histonas. Figura original generada por `verification/make_figures.py`.

2.2 Eucromatina, heterocromatina y niveles superiores de empaquetamiento

La fibra de cromatina transita de forma dinámica entre dos estados funcionales:

- **Euromatina:** Estado descondensado y espacialmente accesible, caracterizado por nucleosomas espaciados, alta acetilación de histonas y activa transcripción génica.
- **Heterocromatina:** Estado densamente compactado e inaccesible a factores de transcripción:
 - **Heterocromatina constitutiva:** Permanentemente silenciada en todos los tipos celulares (centrómeros, télómeros y repeticiones LINEs), enriquecida en trimetilación de lisina 9 en histona H3 (**H3K9me3**) y proteína HP1.
 - **Heterocromatina facultativa:** Regiones que se silencian de forma reversible durante la diferenciación celular y el desarrollo (como la inactivación del cromosoma X en hembras de mamíferos), mediada por el complejo represor Polycomb (PRC2) y la marca **H3K27me3**.

La cromatina se organiza en unidades nucleosomales repetitivas (146 pb alrededor de un octámero de histonas), dividiéndose funcionalmente en euromatina permisiva y heterocromatina condensada.

3 El código epigenético y modificaciones de histonas

ESTUDIO

Las colas N-terminales de las histonas emergen hacia el exterior del núcleo del nucleosoma, expuestas al solvente nuclear. Estas colas sufren un rico abanico de **modificaciones postraduccionales reversibles (PTMs)** que constituyen el denominado **código epigenético**:

1. **Acetilación de lisinas (por HATs / HDACs):** La adición de un grupo acetilo por las histona acetiltransferasas (HATs) neutraliza la carga positiva del grupo ϵ -amino de la lisina, debilitando su atracción electrostática hacia el esqueleto de ADN. Esto relaja la estructura cromatínica y permite el reclutamiento de complejos basales de transcripción.
 - **H3K27ac:** Marca canónica de **potenciadores (enhancers) activos** y promotores abiertos.
 - **H3K9ac:** Asociada a inicio de transcripción activa.
2. **Metilación de lisinas y argininas (por HMTs / KDMs):** La adición de uno, dos o tres grupos metilo por histona metiltransferasas (HMTs) no altera la carga neta del residuo, pero crea sitios de anclaje estéricos reconocidos específicamente por dominios proteicos (*readers*):
 - **H3K4me3:** Marca universal de **promotores basales activos**.
 - **H3K27me3:** Marca de **silenciamiento facultativo Polycomb**.
 - **H3K9me3:** Marca de **heterocromatina constitutiva densa**.
 - **H3K36me3:** Marca de **elongación transcripcional activa**, localizada a lo largo de los cuerpos génicos (*gene bodies*).

El código de histonas regula la accesibilidad cromatínica: la hiperacetilación (H3K27ac) y metilación activa (H3K4me3) marcan transcripción activa, mientras que H3K9me3 y H3K27me3 imponen silenciamiento.

3.1 Metilación del ADN y dinámica biofísica de las islas CpG

En los genomas de vertebrados, la modificación epigenética covalente directa del ADN más abundante es la **5-metilcitosina (5mC)**, producida por la transferencia de un grupo metilo desde la S-adenosilmetionina (SAM) hacia el carbono 5 de la citosina por acción de las ADN metiltransferasas (DNMT1 para mantenimiento replicativo; DNMT3A y DNMT3B para metilación *de novo*).

La metilación de citosinas ocurre de forma casi exclusiva en el contexto del dinucleótido simétrico **CpG** (5'-C-fosfato-G-3'). La hipermetilación de promotores génicos recluta proteínas con dominios MBD y desacetilasas de histonas, imponiendo una represión transcripcional estable.

La metilación del ADN ocurre en dinucleótidos CpG, donde la hipermetilación de islas CpG promotoras (Obs/Exp ≥ 0.6 y GC $\geq 50\%$) causa represión transcripcional estable.

Definición computacional de Gardiner-Garden y Frommer (1987):

Una región genómica se clasifica formalmente como una isla CpG si cumple simultáneamente tres criterios matemáticos:

1. Longitud de secuencia $L \geq 200$ pb (típicamente ≥ 500 pb).
2. Contenido de G+C $\geq 50\%$.
3. Ratio de dinucleótidos CpG Observados respecto a Esperados (Obs/Exp) mayor a **0.60**:

$$\text{Ratio}(\text{CpG}) = \frac{\text{Conteo}(\text{CG}) \times L}{\text{Conteo}(\text{C}) \times \text{Conteo}(\text{G})}$$

Traza manual para la secuencia modelo CGCGCGCGCGCG:

Dada la secuencia sintética $S = \text{"CGCGCGCGCGCG"}$ de longitud $L = 12$ pb:

- Conteo de bases: C : 6, G : 6, A : 0, T : 0.
- Contenido GC: $\frac{6+6}{12} = \frac{12}{12} = 100.0\%$.
- Conteo de dinucleótidos CG solapantes: exactamente 6 dinucleótidos CG.
- Frecuencia esperada: $\text{Esperado}(\text{CG}) = \frac{6 \times 6}{12} = \frac{36}{12} = 3.0$.
- Ratio Obs/Exp:

$$\text{Ratio} = \frac{6 \times 12}{6 \times 6} = \frac{72}{36} = 2.000000$$

Para la secuencia sintética CGCGCGCGCGCG de longitud 12, el ratio CpG Observado/Esporado evalúa exactamente a 2.000000 con un contenido GC del 100 por ciento.

Se reproduce con `verification/chapter_checks.py cpg CGCGCGCGCGCG`.




Figura 2: Distribución bimodal del ratio CpG (Obs/Exp) en el genoma humano: hipometilación protectora en promotores vs deaminación espontánea general. Figura original generada por `verification/make_figures.py`.

4 Variantes genéticas: Clasificación física y espectro mutacional

ESENCIAL

Las variantes de un solo nucleótido (SNVs) se clasifican químicamente según la naturaleza de los anillos de las bases involucradas:

- **Transiciones (T_i):** Sustitución dentro de la misma clase estructural (purina por purina $A \leftrightarrow G$, o pirimidina por pirimidina $C \leftrightarrow T$).
- **Transversiones (T_v):** Sustitución entre clases estructurales distintas (intercambio entre purina y pirimidina, como $A \leftrightarrow C, A \leftrightarrow T, G \leftrightarrow C, G \leftrightarrow T$).

Las variantes de un solo nucleótido (SNVs) se categorizan químicamente en Transiciones (purina-purina o pirimidina-pirimidina) y Transversiones (intercambios purina-pirimidina).

Traza manual de clasificación de SNVs:

`classify_snv` clasifica la mutación A a G como TRANSITION y la mutación A a C como TRANSVERSION.

Se reproduce con `verification/chapter_checks.py snv A G`.

4.1 El ratio T_i/T_v como métrica de calidad en genómica

Para un lote de variantes con 4 transiciones y 2 transversiones:

$$\text{Ratio } T_i/T_v = \frac{4}{2} = 2.000000$$

Para un lote de variantes con 4 transiciones y 2 transversiones, el ratio de calidad T_i/T_v evalúa exactamente a 2.000000.

Se reproduce con `verification/chapter_checks.py titv A:G C:T G:A T:C A:C G:T`.

5 Consecuencias funcionales en regiones codificantes

ESTUDIO

Las variantes en regiones exónicas codificantes se clasifican funcionalmente en:

1. **Sinónimas (*Synonymous*):** Mismo aminoácido (ej. $GAA \rightarrow GAG$, Glutamato).
2. **Cambio de sentido (*Missense*):** Sustitución aminoacídica, como la mutación drepanocítica $GAG \rightarrow GTG$ (Glu $\rightarrow$ Val) en el gen *HBB*.
3. **Sin sentido (*Nonsense*):** Codón de parada prematuro ($CAG \rightarrow TAG$, Gln $\rightarrow$ Stop).

Las variantes codificantes se categorizan funcionalmente en mutaciones sinónimas, sustituciones missense (como *HBB* Glu6Val en anemia falciforme) y codones de parada prematuros nonsense.

Traza manual de clasificación funcional de codones:

`classify_mutation` clasifica GAA a GAG como SYNONYMOUS, GAG a GTG como MISSENSE (Glu a Val) y CAG a TAG como NONSENSE (Gln a Stop).

Se reproduce con `verification/chapter_checks.py mutation GAA GAG`.

Control defensivo de codones no canónicos:

`classify_mutation` lanza `ValueError` cuando el codón contiene caracteres nucleotídicos no canónicos como X en 'GAX'.

Se reproduce con `verification/chapter_checks.py mutation GAX GAG`.

6 El formato estándar Variant Call Format (VCFv4.2)

ESENCIAL

El formato VCF almacena variantes genómicas mediante 8 columnas fijas delimitadas por tabuladores (#CHROM, POS, ID, REF, ALT, QUAL, FILTER, INFO) seguidas de las columnas de genotipos de muestras en coordenadas 1-based.

Traza de parsing de la mutación rs334 de HBB en VCF:

Para la variante rs334 con alelo de referencia T y alternativo A, el parser extrae las coordenadas e identifica la mutación $T \rightarrow A$ como una transversión.

El analizador de formato VCF procesa el cromosoma, la posición 1-based, alelo de referencia y alternativo, clasificando la mutación rs334 de HBB de T a A como TRANSVERSION.

Se reproduce con `verification/chapter_checks.py vcf "chr11 5227002 rs334 T A 100 PASS ."`.




Figura 3: Espacio químico de mutaciones puntuales (Ti vs Tv) y estructura de un registro en formato estándar VCFv4.2. Figura original generada por `verification/make_figures.py`.

7 Variantes estructurales y firmas mutacionales

ESTUDIO

Las variantes genómicas a gran escala rebasan la resolución de los SNVs individuales, abarcando:

- **Variantes en el Número de Copias (CNVs):** Ganancias (duplicaciones génicas como en el locus de la amilasa *AMY1*) o pérdidas (deleciones homocigotas de supresores tumorales como *CDKN2A*) que alteran la dosificación génica.
- **Reordenamientos cromosómicos complejos:** Inversiones pericéntricas y translocaciones balanceadas o desbalanceadas (como el cromosoma Filadelfia $t(9;22)(q34;q11)$ que origina la oncoproteína de fusión *BCR-ABL1*).
- **Firmas mutacionales somáticas (catálogo COSMIC):** Patrones específicos de sustitución en contextos trinucleotídicos que delatan la etiología molecular subyacente (daño por radiación ultravioleta en melanoma, exposición a humo de tabaco en cáncer de pulmón o fallo en la reparación por recombinación homóloga *BRCA1/2*).

Las variantes en el número de copias (CNVs) y las firmas mutacionales somáticas proporcionan biomarcadores genómicos para trastornos constitucionales y caracterización oncológica.

8 Diseño computacional en Python: Procesador de variantes y CpG

ESENCIAL

A continuación se presenta la implementación modular del procesador genómico en Python 3.9:

```
from typing import Tuple, Dict, Optional

TRANSITIONS = {
```



```

    ('A', 'G'), ('G', 'A'),
    ('C', 'T'), ('T', 'C')
}

TRANSVERSIONS = {
    ('A', 'C'), ('C', 'A'), ('A', 'T'), ('T', 'A'),
    ('G', 'C'), ('C', 'G'), ('G', 'T'), ('T', 'G')
}

def calculate_cpg_ratio(sequence: str) -> float:
    """Calcula el ratio de CpG Observados respecto a Esperados (Obs/Exp)."""
    seq = sequence.strip().upper()
    n = len(seq)
    if n == 0:
        raise ValueError("Secuencia no puede estar vacia")
    count_c = seq.count('C')
    count_g = seq.count('G')
    if count_c == 0 or count_g == 0:
        return 0.0
    count_cg = sum(1 for i in range(n - 1) if seq[i:i+2] == "CG")
    expected = (count_c * count_g) / n
    return round(count_cg / expected, 6)

def calculate_titv_ratio(transitions: int, transversions: int) -> float:
    """Calcula el ratio de transiciones frente a transversiones (Ti/Tv)."""
    if transitions < 0 or transversions < 0:
        raise ValueError("Los conteos de mutaciones no pueden ser negativos")
    if transversions == 0:
        if transitions == 0:
            return 0.0
        raise ZeroDivisionError("Transversiones no pueden ser cero para calcular ratio")
    return round(transitions / transversions, 6)

def parse_vcf_line(line: str) -> Optional[Dict[str, str]]:
    """Parsea una línea tabular de variante en formato VCFv4.2."""
    if line.startswith('#') or not line.strip():
        return None
    fields = line.strip().split('\t')
    if len(fields) < 8:
        raise ValueError("Línea VCF inválida: requiere al menos 8 columnas obligatorias")
    return {
        'chrom': fields[0],
        'pos': fields[1],
        'id': fields[2],
        'ref': fields[3],
        'alt': fields[4],
        'qual': fields[5],
        'filter': fields[6],
        'info': fields[7]
    }
}

```

9 Peligros computacionales y actividad de depuración

La confusión de sistemas de coordenadas (1-based en VCF/GFF frente a 0-based semiabierto en BED/Python) y el sesgo de depleción de CpG representan fuentes críticas de error.

9.1 Tres errores críticos en análisis genómico de variantes

Localice y corrija los tres errores en la siguiente función de procesamiento:

```

def process_variant_pipeline(vcf_line, genome_sequence):
    fields = vcf_line.split('\t')
    chrom, pos, var_id, ref, alt = fields[0], int(fields[1]), fields[2], fields[3], fields[4]

    # Error 1: Indexa la secuencia de Python (0-based) directamente con pos de VCF (1-based)

```



```

genome_base = genome_sequence[pos] # Desfase off-by-one

# Error 2: Asume que A->C es una transicion
is_transition = (ref == 'A' and alt == 'C') # A->C es en realidad una transversion

# Error 3: Divide por longitud total sin descontar el solapamiento al buscar CpG
return genome_base, is_transition

```

Diagnóstico de causa raíz (Protocolo 5 Whys):

1. **Fallo 1, desfase de una posición.** El formato numera las posiciones desde uno y los índices del array empiezan en cero. Acceder con la posición sin convertir devuelve el nucleótido siguiente al que se quería, y el programa no avisa: devuelve una base perfectamente válida.
2. **Fallo 2 (Clasificación errónea de mutación):** La mutación $A \rightarrow C$ intercambia una purina bicíclica por una pirimidina monocíclica, lo que constituye una transversión (Tv), no una transición.
3. **Fallo 3 (Cálculo incorrecto de dinucleótidos):** Los dinucleótidos se evalúan en ventanas contiguas de longitud 2 con solapamiento, por lo que una secuencia de longitud N contiene exactamente $N - 1$ posiciones posibles de inicio de dinucleótido.

10 Síntesis operativa y tablas de diagnóstico

10.1 Tabla de diagnóstico de discrepancias genómicas

Síntoma observado	Causa probable	Comprobación y corrección
El alelo de referencia no coincide con el genoma	desfase entre la numeración del fichero y la del array	restar uno a la posición, una sola vez
Cociente entre transiciones y transversiones muy bajo	contaminación o llamadas erróneas repartidas al azar	filtrar por profundidad y por calidad
Fallo en detección de islas CpG	Omitir el umbral de longitud ($L \geq 200$ pb)	Verificar simultáneamente longitud, %GC y ratio Obs/Exp
Se pierden variantes con varios alelos alternativos	se supone que el campo alternativo trae uno solo	separar por comas antes de clasificar

10.2 Tabla de síntesis: Tipos de variantes y repercusión funcional

Categoría	Mecanismo molecular	Impacto en la proteína	Ejemplo biomédico
Sinónima	el codón cambia y el aminoácido no	la proteína es idéntica	variación neutra frecuente
De sentido erróneo	el codón pasa a codificar otro aminoácido	cambia un residuo de la cadena	la mutación drepanocítica
Nonsense	Codón $\rightarrow$ Stop prematuro	Truncamiento proteico o NMD	Fibrosis quística grave
Frameshift	Inserción/delección no múltiplo de 3	Pauta de lectura alterada río abajo	<i>BRCA1</i> c.68_69delAG (Cáncer)

11 Glosario conceptual

- **Nucleosoma:** Octámero de histonas envuelto por 146 pb de ADN.
- **Eucromatina:** Cromatina descondensada accesible para transcripción.
- **Heterocromatina:** Cromatina compactada transcripcionalmente silenciada.

- **H3K4me3:** Marca de histona característica de promotores activos.
- **H3K27ac:** Marca de histona característica de potenciadores activos.
- **Isla CpG:** Región de alta densidad de CG no metilada (> 0.60).
- **Transición:** Mutación entre bases del mismo anillo ($A \leftrightarrow G, C \leftrightarrow T$).
- **Transversión:** Mutación entre purina y pirimidina.
- **Ratio Ti/Tv:** Métrica de calidad genómica ($\approx 2.0-3.0$).
- **VCF:** Formato estándar tabular de 8 columnas fijas para variantes.

12 Conexiones y mapa del curso

Este capítulo establece las bases cromatínicas, epigenéticas y de variación genómica requeridas para abordar el procesamiento del transcriptoma en BC-CH04.

13 Fuentes y reproducibilidad

Este capítulo se apoya en la presentación docente de introducción de la asignatura, escrita por Álvaro Serrano Navarro. Los tres criterios que definen una isla CpG siguen a Gardiner-Garden y Frommer [3]; el código de histonas, a Strahl y Allis [4]; la especificación del formato de variantes, a Danecek y colaboradores [2]; y la arquitectura del gen eucariota, a Alberts y colaboradores [1].

Todos los cálculos se reproducen con `verification/chapter_checks.py` tal como están impresos, con sus argumentos.

Anexo práctico · Análisis computacional de variantes genómicas y firmas epigenéticas

Pregunta, producto y separación de materiales

¿Puede implementar un módulo en Python que parsee registros de variantes en formato VCF, clasifique sustituciones en transiciones y transversiones, evalúe el impacto funcional de mutaciones codificantes y determine la métrica de islas CpG sin recurrir a paquetes externos opacos? Este laboratorio responde afirmativamente de forma totalmente reproducible.

El producto individual es `mi_procesador_variantes.py`: un procesador escrito por usted que lea un fichero de variantes, convierta las coordenadas sin equivocarse, clasifique cada cambio, calcule el cociente de calidad del lote y avise cuando ese cociente se aparte de lo esperado. Lo que se evalúa no es clasificar, que es fácil, sino interpretar el número que sale.

El anexo es autónomo: solo necesita la biblioteca estándar. El generador deja el fichero de variantes del capítulo, el oráculo y un comprobador que ejecuta su procesador sobre ficheros que el enunciado no muestra, uno de ellos con una variante en el primer nucleótido del cromosoma.

Mapa de ruta y productos entregables

Bloque de trabajo	Producto entregable
1 · Entorno y diagnóstico	Comprobación del intérprete Python 3.9
2 · Cálculo ancla (VCF y Codón)	Parsing de rs334, GAG→GTG y Ti/Tv base
3 · Perturbación del ratio Ti/Tv	Evaluación con transversión adicional
4 · Métricas de islas CpG	Cálculo de ratio Obs/Exp y GC%
5 · Guarda de dominio	Captura de <code>ValueError</code> ante codón GAX
6 · Preguntas de control epigenético	Preguntas sobre código de histonas y VCF
7 · Verificación y empaquetado	Comprobación final y empaquetado

Este anexo produce evidencia comprobable y verificable en cada bloque de trabajo sin paquetes externos.

1 • Entorno y diagnóstico

Verifique que su entorno dispone de Python 3.9 o superior:

```
python3 --version
./practice_assets/create_workspace.sh BC03_entrega
cd BC03_entrega
cd datos && sha256sum -c manifest.sha256 && cd ..
```

2 • Escribir el procesador de variantes

Tarea. Implemente `mi_procesador_variantes.py`, que reciba la ruta de un fichero de variantes y emita el recuento de transiciones y transversiones, su cociente, y una línea de aviso cuando ese cociente quede fuera del intervalo esperado. El contrato completo está en la documentación de la plantilla.

Hay dos puntos donde este ejercicio se tuerce, y los dos son de criterio, no de programación.

El primero son las coordenadas. El formato numera las posiciones desde uno, y los índices de Python empiezan en cero. Restar uno es correcto, pero hay que hacerlo una sola vez y comprobar el resultado: el fichero del capítulo tiene a propósito una variante en la posición 1, que es exactamente donde una conversión hecha a la ligera produce un índice negativo, y un índice negativo en Python no falla, sino que cuenta desde el final.

El segundo es el aviso. Un cociente entre transiciones y transversiones de alrededor de dos es lo normal en un genoma completo, porque las transiciones son químicamente más probables. Un cociente muy por debajo indica que el lote está contaminado de falsos positivos, que se reparten al azar entre los seis tipos de cambio posibles. Su procesador tiene que avisar, y usted tiene que saber decir de qué está avisando.

Compruebe su avance cuantas veces quiera:

```
bash herramienta/check_procesador.sh
```

3 • Cálculo ancla: variante codificante y cociente del lote

Dado el registro VCF de la mutación de la drepanocitosis (rs334, gen *HBB*):

1. Parsee los campos cromosómicos: cromosoma chr11, posición 5227002, alelos REF = T y ALT = A (clasificada como **Transversión**).
2. Evalúe el efecto de la mutación codificante en el codón 6: GAG(E) → GTG(V), clasificada como **Missense**.
3. Calcule el ratio Ti/Tv para un lote base de 4 transiciones (A:G, G:A, C:T, T:C) y 2 transversiones (A:C, T:G): $4/2 = 2.000000$.

```
python3 herramienta/chapter_checks.py vcf "chr11 5227002 rs334 T A 100 PASS ." > resultados/anc1a.txt
python3 herramienta/chapter_checks.py mutation GAG GTG >> resultados/anc1a.txt
cat resultados/anc1a.txt
```

El registro ancla VCF rs334 produce una mutación de tipo transversión, efecto de codón MISSENSE (Glu a Val) y un ratio base $Ti/Tv = 2.000000$.

Se reproduce con `verification/chapter_checks.py mutation GAG GTG`.

4 • Perturbación del cociente

Añada una transversión adicional (G:C) al lote anterior (4 transiciones y 3 transversiones):

```
python3 herramienta/chapter_checks.py titv A:G C:T G:A T:C A:C G:T > resultados/lote_normal.txt
python3 herramienta/chapter_checks.py titv A:C G:T C:A T:G A:G > resultados/lote_sospechoso.txt
cat resultados/lote_normal.txt resultados/lote_sospechoso.txt
```

La perturbación del lote con una transversión adicional G a C evalúa a 4 transiciones y 3 transversiones, produciendo un ratio $Ti/Tv = 1.333333$.

Se reproduce con `verification/chapter_checks.py titv A:C G:T C:A T:G A:G`.

5 • Guarda de dominio y control de excepciones

Compruebe que el evaluador rechaza codones con nucleótidos no canónicos:

```
python3 herramienta/chapter_checks.py mutation GAX GTG > resultados/guarda.txt
cat resultados/guarda.txt
```

La guarda de dominio rechaza el codón no válido GAX lanzando un `ValueError` que identifica el codón no canónico.

Se reproduce con `verification/chapter_checks.py mutation GAX GTG`.

6 • Empaquetar y verificar

Ejecute su procesador sobre el fichero del capítulo, guarde la salida y escriba la defensa. Después:

```
python3 mi_procesador_variantes.py datos/bc03_variantes.vcf > resultados/lote.txt || true
cd ..
tar -czf BC03_entrega.tar.gz BC03_entrega
sha256sum BC03_entrega.tar.gz
./practice_assets/check_entrega.sh BC03_entrega BC03_entrega.tar.gz
```

El verificador ejecuta su procesador sobre ficheros que no ha visto, incluido el de la variante en la posición 1, comprueba que el fichero de partida no se ha modificado, que la tabla de respuestas tiene al menos cuatro filas con justificación y una sobre las coordenadas, y que existe la defensa. Rechaza el espacio recién generado. No puntúa.

Rúbrica de calificación ponderada

La evaluación sobre 10 puntos se pondera según:

- **4.0 puntos (40%):** Ejecución correcta y reproducible de los scripts de comprobación (`chapter_checks.py` y `practice_checks.py`).
- **2.0 puntos (20%):** Parsing exacto del registro VCF rs334 y cálculo del ratio $Ti/Tv = 2.000000$ (Bloque 2).
- **2.0 puntos (20%):** Evaluación de perturbación de variantes y control de excepciones en la guarda de dominio (Bloques 3 y 4).
- **2.0 puntos (20%):** Defensa conceptual escrita (100–150 palabras) sobre el ratio Ti/Tv como indicador de calidad bioinformática y la dicotomía epigenética eucromatina/heterocromatina.

Lista de autocorrección

- Verifiqué que mi versión de Python es ≥ 3.9 .
- Parsee correctamente el registro rs334 en VCF.
- Clasifiqué T→A como transversión.
- El efecto de GAG→GTG fue MISSENSE.
- El ratio Ti/Tv del lote base fue 2.000000.
- El ratio perturbado fue 1.333333.
- Verifiqué que GAX lanza `ValueError`.
- Redacté la defensa conceptual individual.

Defensa conceptual

En 100–150 palabras, explique por qué el ratio empírico Ti/Tv en exomas humanos ronda valores entre 2.8–3.2 en lugar del ratio estocástico teórico 0.5, y cómo las modificaciones postraduccionales de histonas (acetilación

frente a metilación) coordinan la apertura física de la cromatina.

Fuentes y reproducibilidad

Este anexo se fundamenta en las diapositivas docentes de genética y genómica (20250913_gen (1).pptx), en la especificación del formato VCF (Danecek et al., 2011) y en el código de histonas (Strahl & Allis, 2000), y se valida al 100% mediante `verification/practice_checks.py`.

Bibliografía

- [1] Bruce Alberts, Alexander Johnson, Julian Lewis, David Morgan, Martin Raff, Keith Roberts, and Peter Walter. *Molecular Biology of the Cell*. Garland Science, 6th edition, 2014. Tratado de referencia para estructura cromatinica nucleosoma y control epigenetico.
- [2] Petr Danecek, Adam Auton, Goncalo Abecasis, Cornelis A. Albers, Eric Banks, Mark A. DePristo, Robert E. Handsaker, Gerton Lunter, Gabor T. Marth, Stephen T. Sherry, Gilean McVean, and Richard Durbin. The variant call format and vcftools. *Bioinformatics*, 27(15):2156–2158, 2011. Especificacion canonica del formato VCF para variantes genomicas y SNPs.
- [3] Margaret Gardiner-Garden and Marianne Frommer. CpG islands in vertebrate genomes. *Journal of Molecular Biology*, 196(2):261–282, 1987. Criterios canonicos para la identificacion de islas CpG en promotores eucariotas.
- [4] Brian D. Strahl and C. David Allis. The language of covalent histone modifications. *Nature*, 403(6765):41–45, 2000. Articulo seminal sobre el codigo de histonas y regulacion epigenetica de la cromatina.