

Transcripción, procesamiento de ARN y expresión génica: Dinámica del transcriptoma, código genético y cuantificación computacional

BC-CH04 – Biología Computacional

Edición 2 · 2026-09-03

Pregunta del tema. Dos células con el mismo genoma pueden ser una neurona y un hepatocito. La diferencia no está en el texto sino en qué partes se leen y cuántas veces. ¿Cómo se mide eso, y por qué el número bruto de lecturas de un experimento no sirve como medida?

Producto final. Un módulo propio que localice marcos abiertos de lectura en los seis marcos, traduzca el más largo y normalice una tabla de expresión, comprobando la propiedad que hace comparables los valores entre muestras.

Mapa del tema

1. El transcriptoma como estado funcional dinámico	1
2. Mecanismo de la transcripción y complejo de pre-iniciación	2
3. Diversidad funcional del ARN: codificantes y no codificantes	3
4. Procesamiento co-transcripcional del pre-ARNm eucariota	4
5. La traducción: cómo el ribosoma lee el mensaje	4
6. El código genético y sesgo de codones (GC3)	5
7. Marcos abiertos de lectura (ORFs) en seis fases	6
8. Cuantificación transcriptómica: Normalización TPM	7
9. Redes de regulación transcripcional y lógica combinatoria	7
10. Diseño de módulos transcriptómicos en Python	8
11. Peligros computacionales y actividad de depuración	9
12. Síntesis operativa y tablas de diagnóstico	9
13. Glosario conceptual	10
14. Conexiones y mapa del curso	10
15. Fuentes y reproducibilidad	10

Cómo usar este tema

El capítulo anterior describía el genoma, que es el mismo en todas las células de un organismo. Este describe lo que cambia: qué se transcribe, cuánto, y cómo se convierte en proteína. Va en tres tiempos. Primero el mecanismo de la transcripción y el destino del ARN. Después la traducción, que es donde el mensaje se convierte en producto y donde se entiende por qué el marco de lectura importa tanto. Y por último la cuantificación, que es la parte computacional: convertir conteos de lecturas en una medida comparable.

Al terminar sabrá: explicar qué determina que un gen se transcriba y qué se hace con el transcrito antes de que salga del núcleo; seguir el ciclo del ribosoma y decir por qué una inserción de una sola base es más grave que una sustitución; buscar marcos abiertos en las seis lecturas posibles declarando el umbral que usa; y normalizar una tabla de expresión sabiendo qué dos sesgos corrige cada paso.

La ruta **esencial** son la transcripción, la traducción, el código genético, los marcos de lectura y la normalización. La ruta de **estudio** añade la diversidad del ARN no codificante, las redes de regulación y el anexo.

1 El transcriptoma como estado funcional dinámico

ESENCIAL Mientras que el genoma representa el repertorio de información hereditaria, prácticamente idéntica en casi todas las células somáticas de un individuo pluricelular), el **transcriptoma** se define formalmente como el conjunto completo de todas las moléculas de ARN transcritas presentes en una célula, tejido o población celular en un instante espacio-temporal determinado.

A diferencia del genoma estático, el transcriptoma es extraordinariamente dinámico, plástico y sensible al entorno:

1. **Instantánea funcional en tiempo real:** Refleja con fidelidad qué programas genéticos se encuentran encendidos, reprimidos o modulados en respuesta a estímulos hormonales, estrés oxidativo, fármacos o procesos patológicos como la transformación tumoral.
2. **Determinante primario de la identidad celular:** Dos células con genomas idénticos (p. ej., una neurona piramidal de la corteza cerebral y un hepatocito humano) poseen transcriptomas drásticamente divergentes que dictan sus morfologías, proteomas y funciones fisiológicas especializadas.
3. **Complejidad cuantitativa extrema:** Abarca desde transcritos ultra-abundantes presentes en cientos de miles de copias por célula (como los ARN mensajeros de actina o los ARN ribosómicos) hasta especies escasas presentes en menos de una molécula por célula en promedio.

El transcriptoma representa el conjunto completo y dinámico de transcritos de ARN en una célula en un instante específico, capturando la actividad funcional de los genes en tiempo real.

2 Mecanismo de la transcripción y complejo de pre-iniciación

La **transcripción** es el proceso enzimático fundamental mediante el cual se sintetiza una cadena de ARN complementaria y antiparalela a partir de una hebra molde de ADN. En eucariotas, la transcripción de los genes que codifican para proteínas corre a cargo de la **ARN Polimerasa II (Pol II)**, un complejo molecular multimérico de 12 subunidades y ≈ 550 kDa.

2.1 Ensamblaje del Complejo de Pre-Iniciación (PIC)

La ARN Polimerasa II es incapaz de reconocer promotores por sí misma y requiere el ensamblaje secuencial y coordinado de los **factores de transcripción generales o basales (GTFs)** en el promotor central, formando el **Complejo de Pre-Iniciación (PIC)**:

1. **Reconocimiento del promotor basal por TFIID:** El complejo TFIID, a través de su subunidad TBP (**Proteína de Unión a TATA**), se une al surco menor de la caja TATA (secuencia consenso 5'-TATAAA-3', situada $\approx 25-30$ pb río arriba del TSS). La unión de TBP induce una marcada curvatura de $\approx 80^\circ$ en la doble hélice de ADN, creando una plataforma topológica para el reclutamiento de los factores subsiguientes.
2. **Estabilización por TFIIA y TFIIB:** TFIIA estabiliza el complejo TBP-ADN, mientras que TFIIB interactúa con el ADN río arriba y río abajo, contactando directamente con el sitio catalítico para definir la distancia exacta al sitio de inicio de la transcripción (TSS).
3. **Reclutamiento de la ARN Polimerasa II mediante TFIIF:** TFIIF acompaña y posiciona a la ARN Pol II sobre el promotor, evitando interacciones inespecíficas.
4. **Incorporación de TFIIE y TFIIH (Activación y apertura):** TFIIE recluta a TFIIH. TFIIH es un complejo multimérico con dos actividades bioquímicas determinantes:
 - **Actividad helicasa dependiente de ATP (subunidades XPB/XPD):** Desenrolla localmente la doble hélice de ADN en el TSS, fundiendo $\approx 11-15$ pb para abrir la **burbuja de transcripción**.
 - **Actividad quinasa (subunidad CDK7):** Fosforila los residuos de Serina 5 en los heptapéptidos repetidos (YSPTSPS) del dominio C-terminal (**CTD**) de la ARN Pol II, desencadenando la liberación del promotor (*promoter clearance*) y el inicio de la fase de elongación.

El inicio de la transcripción requiere el reclutamiento de la ARN Polimerasa II y el ensamblaje del Complejo de Pre-Iniciación (PIC) mediante TFIID/TBP, TFIIA, TFIIB, TFIIE y la helicasa TFIIH.

2.2 La reacción de transcripción y sustitución de Uracilo

La ARN polimerasa sintetiza ARN en dirección $5' \rightarrow 3'$ leyendo la hebra molde de ADN en sentido $3' \rightarrow 5'$. A nivel informacional, la secuencia del transcrito de ARN sintetizado es idéntica a la **hebra codificante (no molde)** del ADN, con la única diferencia estricta de que cada nucleótido de Timina (T) es reemplazado por **Uracilo (U)**:






Figura 1: Ciclo transcripcional de la ARN Polimerasa II: ensamblaje del PIC, escape del promotor y fosforilación del dominio CTD. Figura original generada por `verification/make_figures.py`.

transcribe ejecuta la sustitución determinista de ADN a ARN, convirtiendo ATGGCCATTGTA en AUGGC-CAUUGUA.

Se reproduce con `verification/chapter_checks.py transcribe ATGGCCATTGTA`.

Validación de alfabeto nucleotídico:

La función de transcripción rechaza caracteres no canónicos: `transcribe` lanza `ValueError` al encontrar caracteres no canónicos de ADN como X y Z en 'ATGGZX'.

Se reproduce con `verification/chapter_checks.py transcribe ATGGZX`.

3 Diversidad funcional del ARN: codificantes y no codificantes

El ARN celular exhibe una notable heterogeneidad estructural y catalítica que trasciende el papel pasivo de intermediario mensajero:

1. **ARN Mensajero (ARNm):** Portador de la información codificante organizada en codones trípticos, leída secuencialmente por el ribosoma.
2. **ARN de Transferencia (ARNt):** Adaptador molecular clave con estructura tridimensional en forma de "L" (plegamiento de trébol secundario), que posee un **bucle anticodón** complementario a los codones del ARNm y un **extremo aceptor 3'-CCA** esterificado covalentemente con el aminoácido correspondiente por una aminoacil-ARNt sintetasa específica.
3. **ARN Ribosómico (ARNr):** Componente estructural mayoritario del ribosoma ($\approx 80\%$ del ARN celular total). En particular, el ARNr 28S (eucariotas) o 23S (procariotas) constituye el centro catalítico de la peptidil transferasa, demostrando que el ribosoma es una **ribozima**.
4. **microARNs (miRNAs):** Pequeños ARN de ≈ 22 nucleótidos que se incorporan al complejo silenciador inducido por ARN (**RISC**) y reconocen secuencias complementarias en la región no traducida 3'-UTR de ARNm diana, bloqueando la traducción o induciendo su degradación.
5. **ARNs largos no codificantes (lncRNAs):** Transcritos de longitud > 200 nucleótidos desprovistos de marcos de lectura largos. Actúan como:
 - **Andamios (Scaffolds):** Reúnen físicamente múltiples complejos proteicos (p. ej., el lncRNA *HOTAIR*).
 - **Guías (Guides):** Dirigen enzimas epigenéticas remodeladoras de cromatina (como el complejo PRC2) a loci genómicos específicos (p. ej., el lncRNA *XIST* en la inactivación del cromosoma X).
 - **Señuelos (Decoys):** Secuestran factores de transcripción impidiendo su unión al ADN.

- **Espojas de miARNs (*Sponges*):** Absorben moléculas de miARN previniendo la represión de sus ARNm diana.
6. **ARNs Circulares (*circRNAs*):** Formados por un empalme reverso covalente (*back-splicing*), extraordinariamente resistentes a la degradación por exonucleasas y abundantes en el tejido nervioso, donde actúan como potentes esponjas de miARN.

La diversidad funcional del ARN abarca el ARNm codificante, el adaptador molecular ARNt (plegamiento en L, aceptor 3' CCA, bucle anticodón), el ARNr catalítico y ARN no codificantes reguladores (miRNAs, lncRNAs, circRNAs).

4 Procesamiento co-transcripcional del pre-ARNm eucariota

En eucariotas, el transcrito primario (**pre-ARNm**) es procesado químicamente de forma co-transcripcional mientras la Pol II elonga la cadena:

1. **Caperuza 5' (*5' Capping*):** Adición temprana de una **7-metilguanosina (m^7G)** mediante un inusual enlace fosfodiéster invertido 5'-5' trifosfato, acoplado a la metilación del grupo 2'-OH del primer nucleótido. Protege al ARNm frente a la degradación por 5'-exonucleasas y actúa como sitio de anclaje para el complejo de unión a la caperuza (CBC) y los factores de inicio de la traducción (eIF4E).
2. **Poliadenilación 3':** Escisión endonucleolítica del extremo 3' guiada por la señal de poliadenilación canónica 5'-AAUAAA-3' (reconocida por CPSF y CstF), seguida por la síntesis dependiente de ATP de una cola de $\approx 200-250$ residuos de adenina (**cola poli-A**) por la poli(A) polimerasa (PAP). Confiere estabilidad citoplasmática y promueve la exportación nuclear.
3. **Splicing alternativo:** Eliminación precisa de intrones catalizada por el **espliceosoma** (complejo ribonucleoproteico de snRNPs U1, U2, U4, U5, U6). La selección combinatoria de sitios de empalme alternativos permite que un único gen primario produzca múltiples **isoformas proteicas** con funciones biológicas divergentes o antagónicas.

El procesamiento del pre-ARNm eucariota comprende el capping 5' de 7-metilguanosina (enlace trifosfato 5'-5'), la poliadenilación 3' y el splicing alternativo generador de isoformas proteicas funcionales distintas.



Figura 2: Mecanismo bioquímico del splicing nuclear: dos reacciones de transesterificación acopladas a la formación del lazo intrónico. Figura original generada por `verification/make_figures.py`.

5 La traducción: cómo el ribosoma lee el mensaje

ESENCIAL Hasta aquí hemos tratado la traducción como una tabla que convierte tripletes en aminoácidos. Esa tabla es el resultado, no el mecanismo. Conviene conocer el mecanismo porque explica dos cosas que ninguna

función de traducción muestra: por qué la lectura es estrictamente secuencial y sin marcha atrás, y por qué un desplazamiento de marco arruina todo lo que viene después.

5.1 Los tres sitios del ribosoma

El ribosoma tiene tres posiciones por las que pasa cada ARN de transferencia:

- **Sitio A**, de aminoacil: entra el ARN de transferencia cargado cuyo anticodón empareja con el codón que toca leer.
- **Sitio P**, de peptidil: sostiene el ARN de transferencia que lleva la cadena construida hasta ese momento.
- **Sitio E**, de salida: por donde abandona el ribosoma el ARN de transferencia ya descargado.

5.2 El ciclo

1. **Iniciación.** La subunidad pequeña localiza el codón de inicio y coloca allí el primer ARN de transferencia, que ocupa directamente el sitio P y no el A, que es la excepción del ciclo. Después se acopla la subunidad grande. En bacterias, la subunidad pequeña reconoce una secuencia corta anterior al inicio; en eucariotas, entra por el extremo del mensajero y recorre la secuencia hasta encontrar el primer codón de inicio en un contexto adecuado.
2. **Elongación.** Llega al sitio A el ARN de transferencia cuyo anticodón empareja con el codón siguiente. El centro peptidil-transferasa, que es ARN ribosómico y no proteína, forma el enlace peptídico. Y el ribosoma avanza exactamente tres nucleótidos, desplazando cada ARN de transferencia una posición: el del sitio A pasa al P, y el del P al E.
3. **Terminación.** Ningún ARN de transferencia reconoce los tres codones de parada. En su lugar entran en el sitio A los **factores de liberación**, proteínas que hidrolizan el enlace con la cadena y la sueltan.

Concepto. Que el ribosoma avance de tres en tres, sin retroceder y sin recalibrarse, es la razón computacional de que el marco de lectura importe tanto. Una inserción de un solo nucleótido no cambia un aminoácido: desplaza el marco y convierte en otra cosa todo lo que queda por leer, hasta el primer codón de parada que aparezca en el marco nuevo. Por eso las variantes de desplazamiento de marco tienen consecuencias tan desproporcionadas respecto a su tamaño, y por eso el buscador de marcos abiertos que escribirá en el anexo tiene que examinar los seis marcos y no uno.

ESTUDIO Tres consecuencias cuantitativas cierran el cuadro. Un mismo ARN mensajero puede estar siendo leído a la vez por varios ribosomas, formando un **polisoma**, lo que multiplica la producción sin necesidad de más transcripción. La síntesis proteica es uno de los procesos que más energía consume la célula, lo que explica por qué compensa regular en el paso anterior: no transcribir sale más barato que traducir de más. Y la fidelidad importa más de lo que sugiere el simple desperdicio: una proteína mal plegada no solo malgasta recursos, puede agregarse y resultar tóxica, que es el nexo con el capítulo de estructura.

6 El código genético y sesgo de codones (GC3)

El **código genético universal** establece el diccionario de correspondencia entre los $4^3 = 64$ tripletes de nucleótidos (**codones**) y los 20 aminoácidos proteinogénicos:

- **Degenerado (o redundante):** Existen 61 codones con sentido (*sense*) para solo 20 aminoácidos. Múltiples codones sinónimos codifican para el mismo aminoácido (p. ej., Leucina y Arginina cuentan con 6 codones cada una).
- **Inambiguo y unívoco:** Cada codón individual codifica exclusivamente para un único aminoácido.
- **No solapante y sin comas:** Se lee de tres en tres nucleótidos de manera continua y lineal sin puntuación intercalada.
- **Codones de parada (Stop):** Tres codones específicos (UAA, UAG, UGA) señalan la terminación de la síntesis proteica al unirse a factores de liberación proteicos (RFs).

El código genético es degenerado (61 codones con sentido y 3 codones stop: UAA, UAG, UGA), inambiguo, no solapante, continuo y casi universal.

6.1 Sesgo en la tercera posición del codón (Contenido GC3)

Debido al fenómeno de **bamboleo** (*wobble hypothesis*) formulado por Francis Crick en 1966, la tercera posición del codón es la más tolerante a sustituciones nucleotídicas sin alterar el aminoácido codificado. El **contenido GC3** mide la proporción de Guaninas y Citosinas exclusivamente en la tercera posición de los codones:

Traza del péptido modelo ATGGCCATTGTA:

Dividiendo la secuencia $S = \text{"ATGGCCATTGTA"}$ en 4 codones:

1. Codón 1: ATG $\Rightarrow$ Tercera base: **G** (GC)
2. Codón 2: GCC $\Rightarrow$ Tercera base: **C** (GC)
3. Codón 3: ATT $\Rightarrow$ Tercera base: **T** (AT)
4. Codón 4: GTA $\Rightarrow$ Tercera base: **A** (AT)

Existen 2 bases G/C sobre 4 terceras posiciones:

$$\text{GC3\%} = \frac{2}{4} \times 100 = 50.00\%$$

`gc3_content` evalúa el contenido GC en la tercera posición de codón de ATGGCCATTGTA exactamente en 50.00 por ciento.

Se reproduce con `verification/chapter_checks.py gc3 ATGGCCATTGTA`.

7 Marcos abiertos de lectura (ORFs) en seis fases

Dado que el ADN genómico es bicatenario y la lectura ribosómica procede en tripletes, cualquier secuencia de ADN bicatenario contiene **seis posibles marcos de lectura** (*reading frames*):

- Hebra directa ($5' \rightarrow 3'$): Marco +1 (desfase 0), Marco +2 (desfase 1), Marco +3 (desfase 2).
- Hebra reversa complementaria ($5' \rightarrow 3'$): Marco -1, Marco -2, Marco -3.

El ADN genómico bicatenario codifica seis posibles marcos de lectura (+1, +2, +3 directos y -1, -2, -3 reverso complementarios) que determinan el producto de traducción proteica.

Traducción de ARN en marco 0:

Para la secuencia AUGGCCAUUGUAUAA, de quince nucleótidos: AUG (M) $\rightarrow$ GCC (A) $\rightarrow$ AUU (I) $\rightarrow$ GUA (V) $\rightarrow$ UAA (*). El péptido generado es "MAIV" finalizando en el codón de parada.

`translate_rna` traduce la secuencia modelo de ARN AUGGCCAUUGUAUAA en el marco 0 rindiendo el péptido MAIV y terminando en el codón de parada UAA.

Se reproduce con `verification/chapter_checks.py translate AUGGCCAUUGUAUAA --frame 0`.

Búsqueda de ORFs canónicos en los 6 marcos:

Un **Marco Abierto de Lectura (ORF)** canónico es un segmento delimitado por un codón de inicio ATG y un codón de parada en el mismo marco de lectura. Al analizar "ATGGCCATTGTAATGTAA" en los seis marcos: con un umbral de longitud mínima de treinta nucleótidos se detecta un único marco abierto canónico, en el marco +1, que codifica **MAIVM** (ATG GCC ATT GTA ATG TAA).

Atención. Ese umbral no es un detalle de implementación: cambia el recuento. Sin él aparecería también el ATG de la posición 12, seguido de inmediato por el codón de parada, que es un marco formalmente válido de un solo residuo. Todo buscador de marcos abiertos aplica un umbral, ninguno lo lleva escrito en la salida, y comparar dos recuentos obtenidos con umbrales distintos es comparar cosas distintas. Declárelo siempre, junto al resultado.

La búsqueda en los seis marcos sobre ATGGCCATTGTAATGTAA, con umbral de treinta nucleótidos, identifica un único marco abierto canónico, en el marco +1, que codifica el péptido MAIVM.

Se reproduce con `verification/chapter_checks.py orfs ATGGCCATTGTAATGTAA`.

8 Cuantificación transcriptómica: Normalización TPM

En los experimentos de secuenciación de ARN masiva (**RNA-seq**), el número bruto de lecturas que alinean contra un gen i (*raw read counts*) no es una medida directa de su abundancia molecular real, puesto que está sesgado por:

1. **La longitud del gen:** Genes más largos generan más fragmentos y reciben más lecturas a igual nivel de expresión molar.
2. **La profundidad de secuenciación de la librería:** Muestras secuenciadas con mayor profundidad generan sistemáticamente más conteos brutos.

8.1 Formulación matemática de Transcripts Per Million (TPM)

La métrica **TPM (Transcripts Per Million)** resuelve este problema normalizando primero por la longitud del gen (obteniendo las lecturas por kilobase, **RPK**) y después normalizando la suma de RPKs por un factor de escala global por millón:

$$\begin{aligned} \text{RPK}_i &= \frac{C_i}{L_i/10^3} \\ \text{Scaling Factor} &= \frac{\sum_{j=1}^G \text{RPK}_j}{10^6} \\ \text{TPM}_i &= \frac{\text{RPK}_i}{\text{Scaling Factor}} \end{aligned}$$

A diferencia de métricas obsoletas como RPKM o FPKM (cuya suma de valores varía arbitrariamente entre muestras), **la suma de los valores de TPM en cualquier muestra es siempre exactamente idéntica e igual a 10^6** , haciendo que los valores de TPM representen fracciones molares estrictamente comparables entre distintas condiciones experimentales y laboratorios.

Transcripts Per Million (TPM) normaliza la expresión de RNA-seq dividiendo primero por la longitud del gen (RPK) y por la profundidad de librería segundo, garantizando comparabilidad entre muestras.

Traza manual del lote modelo de expresión:

Dados tres genes con conteos brutos $C = [100, 200, 50]$ y longitudes en pares de bases $L = [1000, 2000, 500]$ ([1.0, 2.0, 0.5] kb):

1. $\text{RPK}_1 = \frac{100}{1.0} = 100.0$; $\text{RPK}_2 = \frac{200}{2.0} = 100.0$; $\text{RPK}_3 = \frac{50}{0.5} = 100.0$.
2. $\sum \text{RPK} = 100 + 100 + 100 = 300.0$.
3. Factor de escala = $\frac{300.0}{10^6} = 0.0003$.
4. $\text{TPM}_1 = \frac{100.0}{0.0003} = 333333.333333$; $\text{TPM}_2 = 333333.333333$; $\text{TPM}_3 = 333333.333333$.

Para los conteos [100, 200, 50] con longitudes [1000, 2000, 500], TPM normaliza a exactamente 333333.333333 para cada uno de los tres genes.

Se reproduce con `verification/chapter_checks.py tpm --counts 100 200 50 --lengths 1000 2000 500`.

9 Redes de regulación transcripcional y lógica combinatoria

La expresión génica eucariota no se rige por interruptores binarios simples, sino por **redes de regulación transcripcional (TRNs)** que integran múltiples señales mediante **lógica combinatoria**:




Figura 3: Normalización cuantitativa de RNA-seq: Transcripts Per Million (TPM) preserva la propiedad invariante de suma a 10^6 . Figura original generada por `verification/make_figures.py`.

- **Control a dos niveles:** Requiere un estado de cromatina físicamente accesible (eucromatina descondensada) y la unión concertada de la combinación precisa de factores de transcripción activadores en ausencia de represores dominantes.
- **Motivos de red recurrentes:** Circuitos modulares como los bucles de retroalimentación autorreguladora (*autoregulatory loops*) y los bucles de avance coordinado (*feed-forward loops*, FFLs coherentes e incoherentes) que filtran el ruido biológico transitorio y generan respuestas temporales de tipo pulso o memoria epigenética celular estable.

Las redes de regulación transcripcional integran la lógica combinatoria de factores de transcripción activadores, coactivadores y represores específicos de secuencia.

10 Diseño de módulos transcriptómicos en Python

A continuación se detalla la arquitectura modular de procesamiento transcriptómico:

```
from typing import Dict, List, Tuple

RNA_CODON_TABLE = {
    'AUG': 'M', 'GCC': 'A', 'AUU': 'I', 'GUA': 'V',
    'UAA': '*', 'UAG': '*', 'UGA': '*'
}

DNA_TRANS = str.maketrans("ACGT", "UGCA")

def transcribe_dna_to_rna(dna_seq: str) -> str:
    """Realiza la sustitucion de T por U sobre la hebra codificante."""
    clean = dna_seq.strip().upper()
    invalid = set(clean) - set("ACGT")
    if invalid:
        raise ValueError(f"Caracteres invalidos detectados: {sorted(invalid)}")
    return clean.replace('T', 'U')

def calculate_gc3(dna_seq: str) -> float:
    """Calcula el porcentaje de GC en la tercera posicion de codon."""
    clean = dna_seq.strip().upper()
    n = len(clean)
    codons = [clean[i:i+3] for i in range(0, n - n % 3, 3)]
    if not codons:
        return 0.0
```



```

gc3_count = sum(1 for c in codons if c[2] in "GC")
return round((gc3_count / len(codons)) * 100.0, 2)

def calculate_tpm(counts: List[float], lengths: List[float]) -> List[float]:
    """Normaliza conteos de RNA-seq a Transcripts Per Million (TPM)."""
    if len(counts) != len(lengths) or not counts:
        raise ValueError("Listas de conteos y longitudes deben coincidir y ser no vacias")
    rpk = [c / (1 / 1000.0) for c, l in zip(counts, lengths)]
    sum_rpk = sum(rpk)
    if sum_rpk == 0:
        return [0.0] * len(counts)
    return [round((r / sum_rpk) * 1e6, 6) for r in rpk]

```

11 Peligros computacionales y actividad de depuración

Omitir los marcos de lectura de la hebra reversa y comparar conteos brutos sin normalizar o RPKM inconsistente entre librerías representan errores computacionales mayores.

11.1 Tres errores críticos en análisis transcriptómico

Localice y corrija los tres errores en la siguiente función:

```

def analyze_expression_data(raw_counts, gene_lengths):
    # Error 1: Intenta comparar muestras dividiendo solo por el total de lecturas
    # sin corregir por la longitud de los transcritos (distorsion de genes largos)

    # Error 2: Asume que RPKM es aditivo y comparable entre librerías distintas

    # Error 3: Al traducir marcos de lectura en ADN genómico, solo explora
    # los marcos +1, +2 y +3, olvidando los marcos de la hebra antisentido (-1, -2, -3)
    pass

```

Diagnóstico de causa raíz (Protocolo 5 Whys):

- Fallo 1 (Sesgo de longitud):** Los conteos brutos no reflejan abundancia molar; un gen de 10 kb produce 10 veces más lecturas que un gen de 1 kb a igual concentración molar.
- Fallo 2 (Uso indebido de RPKM/FPKM entre muestras):** Dado que la suma de RPKM varía entre muestras, no es una proporción molar estricta; debe utilizarse TPM.
- Fallo 3 (Omisión de la hebra reversa):** En genomas bicatenarios, los genes pueden estar codificados en cualquiera de las dos hebras; omitir la hebra reversa pierde el 50% de los genes anotados.

12 Síntesis operativa y tablas de diagnóstico

12.1 Tabla de diagnóstico de problemas en pipelines de RNA-seq

Problema detectado	Causa probable	Comprobación y solución
Suma de expresión no constante entre muestras	Empleo de RPKM o FPKM en lugar de TPM	Migrar a cuantificación TPM ($\sum \text{TPM} = 10^6$)
Pérdida del 50% de ORFs predichos	Se omitieron los marcos de la hebra complementaria	Explorar siempre los 6 marcos (+1,+2,+3, -1,-2,-3)
Falso codón de parada prematuro	Confundir ADN codificante con ARN transcrito	Convertir Timinas a Uracilos antes de consultar la tabla
Falso sesgo en genes largos	Comparación de conteos brutos no normalizados	Normalizar primero por longitud génica (RPK)

12.2 Tabla de síntesis: Tipos de ARN y funciones

Tipo de ARN	Longitud típica	Función molecular principal	Localización celular
ARNm	0.5–10 kb	Molde codificante para síntesis proteica	Núcleo y Citoplasma
ARNt	70–90 nt	Adaptador anticodón-aminoácido	Citoplasma y Mitocondria
ARNr	0.1–5 kb	Centro catalítico peptidil transferasa	Ribosomas / Nucleolo
miRNA	≈ 22 nt	Silenciamiento postranscripcional	Citoplasma (RISC)
lncRNA	> 200 nt	Andamio, guía epigenética y señuelo	Núcleo y Citoplasma

13 Glosario conceptual

- **Transcriptoma:** Conjunto dinámico de transcritos en un instante.
- **PIC:** Complejo de Pre-Iniciación de la ARN Polimerasa II.
- **TBP:** Subunidad de TFIID que dobla la caja TATA.
- **TFIIH:** Factor basal con actividad helicasa y quinasas CDK7.
- **Capping 5':** Enlace 5'-5' trifosfato de m⁷G.
- **Splicing:** Escisión precisa de intrones por el spliceosoma.
- **Bamboleo:** Apareamiento no canónico en 3^a posición (Crick).
- **GC3:** Porcentaje de G/C en la tercera base de los codones.
- **ORE:** Marco abierto entre un codón de inicio y parada.
- **TPM:** Transcripts Per Million (suma invariante 10⁶).

14 Conexiones y mapa del curso

Este capítulo formaliza la expresión génica y la traducción, preparando el terreno para el alineamiento de secuencias proteicas y el modelado estructural en BC-CH05.

15 Fuentes y reproducibilidad

Este capítulo se apoya en la presentación docente de introducción de la asignatura, escrita por Álvaro Serrano Navarro. El descifrado del código genético sigue a Nirenberg y Matthaei [3]; la hipótesis del bamboleo que explica su degeneración, a Crick [2]; la métrica de normalización y su propiedad de suma constante, a Wagner y colaboradores [4]; y la transcripción, su maquinaria y el procesamiento del transcrito, a Alberts y colaboradores [1].

Todos los cálculos se reproducen con `verification/chapter_checks.py` tal como están impresos, con sus argumentos.

Anexo práctico · Flujo transcripcional, traducción en 6 marcos y cuantificación TPM

Pregunta, producto y separación de materiales

¿Puede escribir un módulo que localice marcos abiertos de lectura en los seis marcos con un umbral declarado, los traduzca, y normalice una tabla de expresión de forma que los valores sean comparables entre muestras? Este laboratorio responde que sí, y lo comprueba con una propiedad que usted mismo puede verificar sin mirar ningún resultado esperado.

El producto individual es `mi_modulo_expression.py`, con tres funciones: buscar marcos abiertos, traducir y normalizar. La normalización tiene un oráculo interno perfecto: si los valores no suman exactamente un millón, hay un error, y usted lo detecta solo.

El anexo es autónomo: solo necesita la biblioteca estándar. El generador deja el oráculo del capítulo y un comprobador que prueba su módulo con secuencias y tablas que el enunciado no muestra.

Mapa de ruta y productos entregables

Bloque de trabajo	Producto entregable
1 · Entorno y diagnóstico	Comprobación del intérprete Python 3.9
2 · Cálculo ancla (Transcripción, Traducción, TPM)	Flujo de ADN a proteína y matriz TPM base
3 · Perturbación de matriz TPM	Evaluación con conteos heterogéneos
4 · Búsqueda de ORFs en 6 marcos	Identificación de marco +1 y hebra reversa
5 · Guarda de dominio	Captura de <code>ValueError</code> ante ADN ATGGZX
6 · Preguntas de control transcriptómico	Preguntas sobre PIC, ARNt y normalización
7 · Verificación y empaquetado	Comprobación final y empaquetado

Este anexo produce evidencia comprobable y verificable en cada bloque de trabajo sin paquetes externos.

1 · Entorno y diagnóstico

Verifique que su entorno dispone de Python 3.9 o superior:

```
python3 --version
./practice_assets/create_workspace.sh BC04_entrega
cd BC04_entrega
```

2 · Escribir el módulo

Tarea. Implemente las tres funciones de `mi_modulo_expression.py`: buscar marcos abiertos en los seis marcos con un umbral de longitud mínima, traducir con la tabla estándar, y normalizar una tabla de conteos por longitud y por profundidad. El contrato está en la documentación de la plantilla.

Los tres tienen su trampa. En la búsqueda, los seis marcos: tres en la secuencia y tres en su complemento reverso, porque un gen puede estar en cualquiera de las dos hebras. En la traducción, el codón de parada, que se traduce y no se descarta. Y en la normalización, el orden de las dos correcciones: primero se divide cada conteo por la longitud del gen, y solo después se reparte sobre el total. Hacerlo al revés da otra cosa que también suma un millón y no significa lo mismo.

Comprueba. Después de normalizar, sume sus valores. Deben dar exactamente un millón, y esa es la propiedad que hace comparables dos muestras: cada valor es «de cada millón de transcritos, cuántos son de este gen». Si la suma no da un millón, no siga: el error está en el segundo paso, y ninguna comprobación posterior lo va a detectar por usted.

Compruebe su avance cuantas veces quiera:

```
bash herramienta/check_modulo.sh
```

3 · Cálculo ancla: flujo génico, GC3 y normalización

Dada la secuencia de ADN modelo $S = \text{'ATGGCCATTGTAATGTAA'}$ ($N = 18$ pb):

1. Transcriba a ARN: AUGGCCAUUGUAAUGUAA.

2. Traduzca en marco 0 obteniendo el péptido MAIVM*.
3. Evalúe el contenido GC en tercera posición de codones: GC3% = 50.00%.
4. Calcule los valores TPM para 3 genes con conteos [100, 200, 50] y longitudes [1000, 2000, 500] pb: TPM = [333333.333333, 333333.333333, 333333.333333].

```
python3 herramienta/chapter_checks.py gc3 ATGGCCATTGTA > resultados/ancla.txt
python3 herramienta/chapter_checks.py tpm --counts 100 200 50 --lengths 1000 2000 500 >> resultados/ancla.txt
cat resultados/ancla.txt
```

La secuencia de ADN ancla produce ARN AUGGCCAUUGUAAUGUAA, péptido MAIVM*, GC3% de 50.00% y un vector TPM base con 333333.333333 por gen.

Se reproduce con `verification/chapter_checks.py tpm --counts 100 200 50 --lengths 1000 2000 500`.

4 • Perturbación de la tabla de expresión

Modifique los conteos a [200, 200, 50] manteniendo las longitudes [1000, 2000, 500]:

```
python3 herramienta/chapter_checks.py tpm --counts 400 200 50 --lengths 1000 2000 500 > resultados/perturbado.txt
cat resultados/perturbado.txt
```

Al cuadruplicar el conteo del primer gen y dejar los otros dos igual, sus valores normalizados pasan a ser 666666,67, 166666,67 y 166666,67, y siguen sumando un millón.

Se reproduce con `verification/chapter_checks.py tpm --counts 400 200 50 --lengths 1000 2000 500`.

5 • Guarda de dominio y control de excepciones

Compruebe que el evaluador rechaza secuencias de ADN contaminadas con caracteres no canónicos:

```
python3 herramienta/chapter_checks.py transcribe ATGGZX > resultados/guarda.txt
cat resultados/guarda.txt
```

La guarda de dominio rechaza la secuencia no válida ATGGZX lanzando un `ValueError` que identifica los caracteres inválidos 'X' y 'Z'.

Se reproduce con `verification/chapter_checks.py transcribe ATGGZX`.

6 • Empaquetar y verificar

Escriba antes `notas/defensa.md`. Después:

```
cd ..
tar -czf BC04_entrega.tar.gz BC04_entrega
sha256sum BC04_entrega.tar.gz
./practice_assets/check_entrega.sh BC04_entrega BC04_entrega.tar.gz
```

El verificador prueba su módulo con secuencias y tablas que no ha visto, comprueba que la tabla de respuestas tiene al menos cuatro filas con justificación y una sobre el umbral, que resultados/ recoge alguna normalización, y que existe la defensa. Rechaza el espacio recién generado. No puntúa.

Rúbrica de calificación ponderada

La evaluación sobre 10 puntos se pondera según:

- **4.0 puntos (40%):** Ejecución correcta y reproducible de los scripts de comprobación (`chapter_checks.py` y `practice_checks.py`).
- **2.0 puntos (20%):** Cálculo manual y exacto de la normalización TPM base (333333.333333) y traducción del gen modelo (Bloque 2).
- **2.0 puntos (20%):** Evaluación de perturbación de TPM y control de excepciones en la guarda de dominio (Bloques 3 y 4).
- **2.0 puntos (20%):** Defensa conceptual escrita (100–150 palabras) sobre las ventajas matemáticas de TPM frente a RPKM y el papel de las aminoacil-ARNt sintetasas como verdaderos traductores moleculares.

Lista de autocorrección

- mi buscador de marcos examina las dos hebras, no solo una;
- declaré el umbral de longitud mínima que usé, y sé cómo cambia el recuento;
- mi traducción incluye el codón de parada en vez de descartarlo;
- normalicé primero por longitud y después por profundidad, en ese orden;
- mis valores normalizados suman exactamente un millón, en los tres casos;
- la guarda rechaza los caracteres que no son ADN y lo dice;
- guardé en `resultados/` la salida de cada ejecución que cito;
- el verificador termina en `ENTREGA_OK`.

Defensa conceptual

En `notas/defensa.md`, entre 100 y 150 palabras, explique por qué la métrica que suma un millón permite comparar dos muestras independientes y una que no lo hace, no. Use un ejemplo numérico de su propia entrega: dos muestras con distinta profundidad de secuenciación y el mismo gen.

Fuentes y reproducibilidad

Este anexo no usa datos externos ni paquetes de terceros. La métrica de normalización y su propiedad de suma constante siguen a Wagner y colaboradores [4], y la degeneración del código genético, a Crick [2].

Bibliografía

- [1] Bruce Alberts, Alexander Johnson, Julian Lewis, David Morgan, Martin Raff, Keith Roberts, and Peter Walter. *Molecular Biology of the Cell*. Garland Science, 6th edition, 2014. Tratado de referencia para transcripción procesamiento de ARN y traducción.
- [2] Francis H. C. Crick. Codon–anticodon pairing: The wobble hypothesis. *Journal of Molecular Biology*, 19(2):548–555, 1966. Hipótesis fundacional del balanceo (wobble) y degeneración en la tercera base del codón.
- [3] Marshall W. Nirenberg and J. Heinrich Matthaei. The dependence of cell-free protein synthesis in *e. coli* upon naturally occurring or synthetic polyribonucleotides. *Proceedings of the National Academy of Sciences*, 47(10):1588–1602, 1961. Descubrimiento histórico del código genético y correspondencia codón-aminoácido.
- [4] Günter P. Wagner, Koryu Kin, and Vincent J. Lynch. Measurement of mRNA abundance using RNA-seq data: RPKM measure is inconsistent among samples. *Theory in Biosciences*, 131(4):281–285, 2012. Artículo canónico sobre las ventajas matemáticas de la normalización TPM frente a RPKM/FPKM.