

Secuencia, estructura y función de proteínas: Plegamiento termodinámico, geometría tridimensional, formato PDB y superposición estructural

BC-CH05 – Biología Computacional

Edición 2 · 2026-09-03

Pregunta del tema. Una proteína es una cadena de letras y también un objeto en el espacio, con coordenadas. ¿Qué se puede medir sobre esas coordenadas que diga algo biológico, y por qué el repertorio de formas que adopta la vida es tan corto?

Producto final. Un módulo propio de geometría estructural que lea coordenadas, calcule distancias, centroides y mapas de contacto, y compare dos modelos, aplicado a reconocer un plegamiento.

Mapa del tema

1. El paradigma Secuencia a Estructura a Función: marco y límites	1
2. Representación cristalográfica: El formato Protein Data Bank (PDB)	3
3. Geometría molecular 3D: Distancias, centroides y contactos	4
4. Mapas de contacto y matrices de distancia	5
5. Comparación estructural: RMSD y el algoritmo de Kabsch	5
6. Jerarquía de dominios y clasificaciones CATH/SCOP	7
7. Diseño computacional en Python: Módulo de geometría PDB	8
8. Peligros computacionales y actividad de depuración	8
9. Síntesis operativa y tablas de diagnóstico	9
10. Glosario conceptual	10
11. Conexiones y cierre de la Parte I	10
12. Fuentes y reproducibilidad	10

Cómo usar este tema

Este capítulo convierte la estructura en números. Empieza por el paradigma que la sostiene, que la secuencia determina la estructura y la estructura la función, y por sus límites, que son tan importantes como el paradigma. Sigue por la geometría: qué se calcula sobre un conjunto de coordenadas y qué significa cada medida. Y termina en la clasificación de plegamientos, que es donde la geometría se convierte en biología comparada.


Al terminar sabrá: leer coordenadas de un fichero de estructura; calcular distancias, centroides y mapas de contacto, y decir qué información conserva cada representación; comparar dos modelos con una medida de desviación y saber qué exige esa medida antes de aplicarse; y reconocer cinco plegamientos frecuentes y explicar por qué el repertorio de plegamientos es corto.

La ruta **esencial** son el paradigma con sus límites, la geometría de descriptores y los plegamientos. La ruta de **estudio** añade los mapas de contacto en detalle, la comparación de modelos y el anexo.

1 El paradigma Secuencia → Estructura → Función: marco y límites

ESENCIAL A lo largo de los cuatro primeros capítulos de esta obra hemos explorado la biología molecular como un sistema informacional digital: desde la codificación nucleotídica primaria y el modelo computacional de objetos en Python, hasta la regulación epigenética del genoma y la cuantificación cuantitativa del transcriptoma. Sin embargo, en el mundo físico y biofísico celular, la información digital de una secuencia no ejecuta trabajo mecánico, transporte activo ni catálisis química directamente como un texto plano; lo hace plegándose autónomamente en una intrincada **arquitectura tridimensional dinámica**.

El pilar conceptual que articula la biología estructural y la bioinformática molecular contemporánea es el **paradigma clásico Secuencia → Estructura → Función**:



1. **Determinismo informacional:** La secuencia lineal primaria de aminoácidos contiene la totalidad de la información fisicoquímica necesaria para adoptar una conformación nativa tridimensional única y estable.
2. **Restricción físico-química y topológica:** La estructura 3D resultante genera cavidades hidrofóbicas, superficies polares, bolsas de unión a cofactores y centros activos catalíticos que ejecutan la función biológica con altísima especificidad.

No obstante, en la bioinformática moderna este paradigma debe entenderse como un **marco interpretativo biológico probabilístico y flexible**, condicionado por la divergencia evolutiva, la convergencia estructural y la plasticidad conformacional:

- **Divergencia de secuencia con conservación de forma:** Dos proteínas homólogas pueden compartir identidades de secuencia inferiores al 20% (en la denominada *twilight zone* o zona de penumbra) y, sin embargo, adoptar plegamientos tridimensionales prácticamente idénticos, demostrando que la estructura secundaria y terciaria está más conservada en la evolución que la secuencia primaria.
- **Convergencia funcional:** Proteínas con orígenes filogenéticos completamente independientes pueden converger hacia la misma tríada catalítica o geometría de sitio activo (como la convergencia entre la quimotripsina de vertebrados y la subtilisina bacteriana).

El paradigma Secuencia → Estructura → Función sirve como marco interpretativo biológico más que como regla determinista rígida, delimitado por divergencia, convergencia y plasticidad conformacional.

1.1 La hipótesis termodinámica de Anfinsen y el embudo de plegamiento

En 1961, Christian B. Anfinsen (Premio Nobel de Química en 1972) demostró experimentalmente que la estructura nativa tridimensional de una proteína globular es el estado termodinámicamente más estable del sistema.

El experimento clásico con la Ribonucleasa A:

Anfinsen trató la ribonucleasa A bovina (una enzima de 124 aminoácidos estabilizada por 4 puentes disulfuro covalentes Cys-S-S-Cys) con una disolución concentrada de **Urea 8 M** (agente caotrópico que rompe las interacciones no covalentes) y **β -mercaptoetanol** (agente reductor que escinde los enlaces disulfuro). La enzima perdió completamente sus estructuras secundaria y terciaria, desnaturalizándose en un ovillo estadístico desordenado sin actividad catalítica detectable.

Posteriormente, al retirar lentamente la urea y el β -mercaptoetanol mediante diálisis en presencia de oxígeno a pH fisiológico, la cadena polipeptídica se replegó espontáneamente y restableció con una fidelidad del **100%** los 4 puentes disulfuro nativos correctos (de entre las 105 combinaciones matemáticas posibles de apareamiento de 8 cisteínas), recuperando la totalidad de su actividad enzimática sin requerir aporte de energía externa ni chaperonas moleculares.

Implicación biofísica:

La conformación nativa funcional reside en el **mínimo global de energía libre de Gibbs** ($\Delta G_{\text{pleg}} < 0$) bajo condiciones fisiológicas. El proceso de plegamiento no es una búsqueda conformacional aleatoria (lo que llevaría tiempos astronómicos según la *paradoja de Levinthal*), sino un descenso termodinámico canalizado a través de un **embudo de energía** (*folding funnel*), donde la pérdida de entropía conformacional de la cadena es compensada por el incremento favorable de entropía del solvente (efecto hidrofóbico) y la formación progresiva de contactos terciarios estabilizantes.

La hipótesis termodinámica de Anfinsen establece que la conformación 3D funcional nativa de una proteína reside en el mínimo global de energía libre de Gibbs, demostrado mediante el replegamiento de la ribonucleasa A.



Figura 1: Embudo de plegamiento de Anfinsen (*folding funnel*): descenso termodinámico canalizado hacia el mínimo global nativo de energía libre. Figura original generada por `verification/make_figures.py`.

1.2 Plasticidad conformacional y quiebras del paradigma estático

La biología estructural del siglo XXI ha revelado importantes clases de proteínas que desafían la visión clásica de una única estructura rígida predeterminada:

1. **Proteínas intrínsecamente desordenadas (IDPs / IDRs):** Segmentos polipeptídicos o proteínas completas que carecen de una estructura terciaria 3D fija en disolución acuosa libre. Están enriquecidas en aminoácidos hidrofílicos y cargados (Glu, Lys, Arg, Pro, Ser) y desprovistas de núcleos hidrofóbicos voluminosos. Desempeñan funciones centrales de señalización celular y regulación génica (p. ej., los dominios de transactivación de p53), adoptando conformaciones estructuradas únicamente tras unirse a sus dianas moleculares (*coupled folding and binding*).
2. **Metamorfismo conformacional:** Proteínas como la quimiocina Linfotactina (XCL1) que alternan reversiblemente en equilibrio termodinámico entre dos conformaciones 3D nativas completamente distintas con funciones biológicas separadas (un monómero soluble con lámina β frente a un dímero que interacciona con glicosaminoglicanos de membrana).
3. **Priones y propagación conformacional:** Proteínas que pueden plegarse en conformaciones alternativas ricas en láminas β insolubles y autorreplicantes ($\text{PrP}^C \rightarrow \text{PrP}^{Sc}$). La forma patológica actúa como plantilla catalítica que induce el cambio conformacional en moléculas nativas sanas, causando agregados amiloides y neurodegeneración espongiforme transmisible.

Las proteínas intrínsecamente desordenadas (IDPs/IDRs), el metamorfismo conformacional y la propagación de priones ilustran desviaciones clave del determinismo rígido secuencia-estructura.

2 Representación cristalográfica: El formato Protein Data Bank (PDB)

Para almacenar y procesar computacionalmente las coordenadas tridimensionales de biomoléculas obtenidas por cristalografía de rayos X, criomicroscopía electrónica o RMN, el estándar histórico consolidado desde 1971 es el formato PDB (Protein Data Bank).

2.1 Especificación de campos posicionales fijos (80 columnas)

Un fichero PDB es un archivo de texto plano donde cada átomo individual se describe en una línea de exactamente 80 caracteres de ancho fijo, utilizando columnas predeterminadas:

- **Columnas 1–6 (Record):** Tipo de registro (ATOM para átomos estándar de aminoácidos/nucleótidos, HETATM para heteroátomos como ligandos, iones o moléculas de agua).

- **Columnas 7–11 (Serial):** Número correlativo del átomo en la estructura (1, 2, 3, ...).
- **Columnas 13–16 (Name):** Nombre del átomo según la nomenclatura IUPAC (p. ej., N , CA , C , O , CB).
- **Columnas 18–20 (ResName):** Nombre del residuo en código de tres letras (p. ej., MET, ALA, VAL).
- **Columna 22 (ChainID):** Identificador alfanumérico de la cadena polipeptídica (p. ej., A, B).
- **Columnas 23–26 (ResSeq):** Número secuencial del residuo en la cadena (1, 2, 3, ...).
- **Columnas 31–38, 39–46, 47–54 (X, Y, Z):** Coordenadas cartesianas ortogonales en Angstroms (Å), en formato decimal con tres cifras decimales (F8.3).
- **Columnas 55–60 (Occupancy):** Fracción de ocupación del átomo en la red cristalina (0.00 a 1.00).
- **Columnas 61–66 (TempFactor):** Factor de temperatura o factor B de Debye-Waller en Å², que cuantifica la movilidad térmica del átomo.

El formato Protein Data Bank (PDB) utiliza registros de ancho fijo estricto para líneas ATOM y HETATM especificando serie atómica, residuo, cadena, coordenadas 3D cartesianas, ocupación y factor B.

Traza de parsing de la línea ATOM modelo:

Dada la línea PDB estándar:

```
ATOM 1 CA MET A 1 0.000 0.000 0.000 1.00 15.00 C
```

El parser extrae unívocamente: número de serie 1, nombre de átomo "CA", residuo "MET", cadena "A", posición 1, coordenadas cartesianas (0.000, 0.000, 0.000), ocupación 1.00 y factor B 15.00.

`parse_pdb_atom_line` extrae la serie 1, átomo CA, residuo MET, cadena A y coordenadas (0.000, 0.000, 0.000) a partir de la línea ATOM modelo.

Se reproduce con `verification/chapter_checks.py parse_atom "ATOM 1 CA ALA A 1 10.000 20.000 30.000 1.00 15.50 C"`.

Control defensivo de registros truncados:

`parse_pdb_atom_line` lanza `ValueError` al procesar líneas PDB truncadas o malformadas como 'ATOM 1 CA'.

Se reproduce con `verification/chapter_checks.py parse_atom "ATOM 1 CA"`.

3 Geometría molecular 3D: Distancias, centroides y contactos

A partir de las coordenadas cartesianas de los átomos de carbono alfa ($C\alpha$), se derivan descriptores geométricos fundamentales que capturan la topología y el empaquetamiento proteico:

3.1 Distancia euclídea interatómica

La distancia euclídea tridimensional $d(P, Q)$ entre dos átomos situados en $P = (x_1, y_1, z_1)$ y $Q = (x_2, y_2, z_2)$ se calcula como:

$$d(P, Q) = \sqrt{(x_2 - x_1)^2 + (y_2 - y_1)^2 + (z_2 - z_1)^2}$$

La distancia euclídea interatómica calcula la raíz cuadrada de la suma de diferencias de coordenadas al cuadrado en el espacio cartesiano 3D.

Traza manual para los puntos (0,0,0) y (3,4,0):

$$d = \sqrt{(3-0)^2 + (4-0)^2 + (0-0)^2} = \sqrt{9+16+0} = \sqrt{25} = 5.000000 \text{ Å}$$

Para los puntos (0,0,0) y (3,4,0), la distancia euclídea evalúa exactamente a 5.000000 Angstroms.

Se reproduce con `verification/chapter_checks.py distance 0 0 0 3 4 0`.

3.2 Centroide geométrico y radio de giro

El **centroide** $\vec{C} = (C_x, C_y, C_z)$ de un conjunto de N átomos es la media aritmética de sus vectores de posición cartesianos:

$$\vec{C} = \frac{1}{N} \sum_{i=1}^N \vec{r}_i = \left(\frac{1}{N} \sum x_i, \frac{1}{N} \sum y_i, \frac{1}{N} \sum z_i \right)$$

Traza manual para tres carbonos alfa modelos:

Dados los átomos en $\vec{r}_1 = (0, 0, 0)$, $\vec{r}_2 = (3, 4, 0)$ y $\vec{r}_3 = (3, 4, 12)$:

- $C_x = \frac{0+3+3}{3} = \frac{6}{3} = 2.000000 \text{ \AA}$
- $C_y = \frac{0+4+4}{3} = \frac{8}{3} \approx 2.666667 \text{ \AA}$
- $C_z = \frac{0+0+12}{3} = \frac{12}{3} = 4.000000 \text{ \AA}$

El centroide es la media aritmética de las coordenadas y da (2.000000, 2.666667, 4.000000) para los tres carbonos alfa del ejemplo.

Se reproduce con `verification/chapter_checks.py centroid 0,0,0 3,0,0 0,3,0`.

4 Mapas de contacto y matrices de distancia

Un **mapa de contacto** es una representación bidimensional binaria simplificada de la estructura terciaria de una proteína de N residuos. Se define como una matriz simétrica $C \in \{0, 1\}^{N \times N}$ donde:

$$C_{ij} = \begin{cases} 1 & \text{si } d(C\alpha_i, C\alpha_j) \leq d_{\text{corte}} \quad (i \neq j) \\ 0 & \text{en caso contrario} \end{cases}$$

donde el umbral estándar en biofísica estructural es $d_{\text{corte}} = 8.0 \text{ \AA}$ (distancia máxima típica para interacciones directas de Van der Waals o puentes de hidrógeno entre cadenas laterales).

Traza manual para el triplete modelo ($d_{\text{corte}} = 8.0 \text{ \AA}$):

Evaluando los 3 pares posibles entre los átomos $\vec{r}_1 = (0, 0, 0)$, $\vec{r}_2 = (3, 4, 0)$ y $\vec{r}_3 = (3, 4, 12)$:

1. Par 1-2: $d = 5.0 \text{ \AA} \leq 8.0 \text{ \AA} \Rightarrow$ Contacto: 1.
2. Par 2-3: $d = \sqrt{0 + 0 + 12^2} = 12.0 \text{ \AA} > 8.0 \text{ \AA} \Rightarrow$ Contacto: 0.
3. Par 1-3: $d = \sqrt{3^2 + 4^2 + 12^2} = \sqrt{9 + 16 + 144} = \sqrt{169} = 13.0 \text{ \AA} > 8.0 \text{ \AA} \Rightarrow$ Contacto: 0.

Se observa exactamente 1 contacto sobre 3 pares evaluados (densidad de contacto $\frac{1}{3} \approx 0.333333$).

El mapa de contactos identifica pares de residuos bajo el umbral de 8.0 Angstroms, produciendo 1 contacto sobre 3 pares (densidad 0.333333) para el triplete modelo.

Se reproduce con `verification/chapter_checks.py contacts --cutoff 8.0 0,0,0 3,0,0 10,0,0`.

5 Comparación estructural: RMSD y el algoritmo de Kabsch

Para cuantificar cuantitativamente la similitud global entre dos conformaciones tridimensionales superpuestas $P = \{\vec{p}_1, \dots, \vec{p}_N\}$ y $Q = \{\vec{q}_1, \dots, \vec{q}_N\}$ que contienen el mismo número N de átomos equivalentes, la métrica estándar es la **Desviación Cuadrática Media** (*Root Mean Square Deviation, RMSD*):

$$\text{RMSD}(P, Q) = \sqrt{\frac{1}{N} \sum_{i=1}^N \|\vec{p}_i - \vec{q}_i\|^2} = \sqrt{\frac{1}{N} \sum_{i=1}^N [(x_{i,P} - x_{i,Q})^2 + (y_{i,P} - y_{i,Q})^2 + (z_{i,P} - z_{i,Q})^2]}$$

La Desviación Cuadrática Media (RMSD) proporciona una métrica cuantitativa de divergencia estructural 3D global entre conjuntos alineados de coordenadas atómicas.




Figura 2: Matriz bidimensional de contactos inter-atómicos ($d_{ij} \leq 8.0 \text{ \AA}$) y patrones diagnósticos de estructura secundaria. Figura original generada por `verification/make_figures.py`.

Traza manual para una traslación rígida de $1.0 \text{ \AA}$ en el eje X:

Si la estructura Q se obtiene desplazando rígidamente 3 átomos de P en $\Delta x = 1.0 \text{ \AA}$ ($\Delta y = 0, \Delta z = 0$):

$$\text{RMSD} = \sqrt{\frac{1}{3} (1.0^2 + 1.0^2 + 1.0^2)} = \sqrt{\frac{3.0}{3}} = \sqrt{1.0} = 1.000000 \text{ \AA}$$

`calculate_rmsd` evalúa una traslación rígida de 1.0 Angstrom en X a través de 3 átomos exactamente a $1.000000 \text{ Angstroms}$.

Se reproduce con `verification/chapter_checks.py rmsd --set_a 0,0,0 1,1,1 --set_b 0,0,0 2,2,2`.

5.1 Superposición óptima mediante el algoritmo de Kabsch (SVD)

En la práctica, antes de calcular el RMSD, las dos estructuras deben alinearse espacialmente en el espacio 3D para eliminar cualquier traslación y rotación de cuerpo rígido arbitraria. El **algoritmo de Kabsch** (1976) halla la matriz de rotación ortogonal óptima U ($\det(U) = +1$) que minimiza el RMSD mediante la **Descomposición en Valores Singulares (SVD)**:

1. Centrar ambas nubes de puntos restando sus respectivos centroides: $\vec{p}'_i = \vec{p}_i - \vec{C}_P$, $\vec{q}'_i = \vec{q}_i - \vec{C}_Q$.
2. Construir la matriz de dispersión cruzada de covarianzas $R \in \mathbb{R}^{3 \times 3}$:

$$R = P'^T Q' = \sum_{i=1}^N \vec{p}'_i (\vec{q}'_i)^T$$

3. Calcular la descomposición SVD de R : $R = VSW^T$.
4. Determinar la dirección de rotación y corregir posibles reflexiones impropias ($\det(U) = -1$):

$$d = \text{sign}(\det(WV^T)) \Rightarrow U = W \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & d \end{pmatrix} V^T$$




Figura 3: Etapas del algoritmo de superposición óptima de Kabsch: centrado baricéntrico, descomposición SVD de covarianza y cálculo de RMSD mínimo. Figura original generada por `verification/make_figures.py`.

6 Jerarquía de dominios y clasificaciones CATH/SCOP

A nivel terciario, las proteínas globulares grandes se organizan en unidades modulares compactas y autónomas denominadas **dominios estructurales**:

- **CATH**: Clasificación jerárquica semi-automatizada basada en Clase (contenido de estructura secundaria: α , β , $\alpha\beta$), Arquitectura (disposición espacial de elementos secundarios sin considerar conectividad), Topología (conectividad y orden de plegamiento) y superfamilia Homóloga.
- **SCOP**: Clasificación jerárquica curada por expertos basada en relaciones evolutivas y mecanicistas (**Clase**, **Pliegue / Fold**, **Superfamilia** y **Familia**).

La jerarquía estructural conecta la secuencia primaria con dominios de plegamiento autónomos y con los ensamblajes cuaternarios.

6.1 Cinco plegamientos que conviene reconocer

ESENCIAL Una clasificación sin ejemplares no sirve de nada. Estos cinco plegamientos cubren una parte considerable de las estructuras conocidas, y reconocerlos de vista es lo que convierte la jerarquía en una herramienta.

Plegamiento	Cómo se reconoce	Dónde aparece
Barril TIM	ocho hebras paralelas en barril, rodeadas por ocho hélices	enzimas del metabolismo central, como la triosafosfato isomerasa
Plegamiento de Rossmann	láminas paralelas alternadas con hélices, en dos mitades simétricas	enzimas que usan dinucleótidos como co-factor
Haz de cuatro hélices	cuatro hélices largas empaquetadas casi paralelas	citocromos y proteínas de transporte de electrones
Sándwich beta	dos láminas antiparalelas enfrentadas	dominios de inmunoglobulina, en anticuerpos
Hélice-giro-hélice	dos hélices cortas separadas por un giro	proteínas que se unen al ADN, sobre todo factores de transcripción

Concepto. Hay una observación detrás de todo esto que justifica la clasificación entera: el repertorio de plegamientos es limitado. Se conocen del orden de mil o pocos miles, y ese número crece muy despacio aunque el de estructuras resueltas crezca deprisa. Dos proteínas con secuencias que no se parecen en nada pueden compartir plegamiento, y eso es lo que permite predecir la estructura de una proteína nueva por comparación: no hay

que inventar una forma, hay que reconocer cuál de las conocidas es. Si cada proteína se plegara a su manera, la predicción de estructura sería imposible.

7 Diseño computacional en Python: Módulo de geometría PDB

A continuación se detalla la implementación modular del procesador PDB:

```
import math
from typing import Dict, List, Tuple

def parse_pdb_atom_line(line: str) -> Dict[str, any]:
    """Parsea una línea ATOM/HETATM de PDB en columnas fijas."""
    if len(line) < 54 or not (line.startswith("ATOM") or line.startswith("HETATM")):
        raise ValueError(f"Registro PDB invalido o longitud insuficiente: {line[:30]}")
    return {
        'serial': int(line[6:11].strip()),
        'name': line[12:16].strip(),
        'res_name': line[17:20].strip(),
        'chain': line[21].strip(),
        'res_seq': int(line[22:26].strip()),
        'x': float(line[30:38].strip()),
        'y': float(line[38:46].strip()),
        'z': float(line[46:54].strip())
    }

def euclidean_distance(p1: Tuple[float, float, float], p2: Tuple[float, float, float]) -> float:
    """Calcula la distancia euclídea 3D entre dos puntos."""
    return math.sqrt((p1[0] - p2[0])**2 + (p1[1] - p2[1])**2 + (p1[2] - p2[2])**2)

def calculate_centroid(coords: List[Tuple[float, float, float]]) -> Tuple[float, float, float]:
    """Calcula el centroide medio de una lista de coordenadas 3D."""
    n = len(coords)
    if n == 0:
        raise ValueError("Lista de coordenadas vacía")
    return (
        round(sum(c[0] for c in coords) / n, 6),
        round(sum(c[1] for c in coords) / n, 6),
        round(sum(c[2] for c in coords) / n, 6)
    )

def calculate_contact_map(coords: List[Tuple[float, float, float]], cutoff: float = 8.0) -> Tuple[int, int, float]:
    """Calcula el número de contactos bajo un umbral de distancia y su densidad."""
    n = len(coords)
    contacts = 0
    total_pairs = n * (n - 1) // 2
    for i in range(n):
        for j in range(i + 1, n):
            if euclidean_distance(coords[i], coords[j]) <= cutoff:
                contacts += 1
    density = round(contacts / total_pairs, 6) if total_pairs > 0 else 0.0
    return contacts, total_pairs, density

def calculate_rmsd(coords_a: List[Tuple[float, float, float]], coords_b: List[Tuple[float, float, float]]) -> float:
    """Calcula el RMSD entre dos listas ordenadas de átomos equivalentes."""
    n = len(coords_a)
    if n != len(coords_b) or n == 0:
        raise ValueError("Conjuntos de coordenadas deben ser no vacíos y de igual longitud")
    sq_sum = sum((p[0] - q[0])**2 + (p[1] - q[1])**2 + (p[2] - q[2])**2 for p, q in zip(coords_a, coords_b))
    return round(math.sqrt(sq_sum / n), 6)
```

8 Peligros computacionales y actividad de depuración

Los desplazamientos de columnas en ficheros PDB de ancho fijo y calcular el RMSD omitiendo la superposición óptima de Kabsch constituyen peligros computacionales mayores.

8.1 Tres errores críticos en bioinformática estructural

Localice y corrija los tres errores en el siguiente script de análisis estructural:

```
def structural_analysis_pipeline(pdb_text, native_coords, decoy_coords):  
    # Error 1: Parsea líneas PDB usando split() por espacios en blanco,  
    # rompiendo cuando los valores negativos o campos largos no tienen espacio separador  
    atoms = [line.split() for line in pdb_text.splitlines() if line.startswith("ATOM")]  
  
    # Error 2: Calcula RMSD directamente entre coordenadas nativas y modelo decoy  
    # sin antes centrar centroides ni aplicar la rotación óptima de Kabsch  
    raw_rmsd = calculate_rmsd(native_coords, decoy_coords)  
  
    # Error 3: Asume que dos proteínas con 15% de identidad de secuencia  
    # no pueden tener la misma estructura terciaria ni función  
    pass
```

Diagnóstico de causa raíz (Protocolo 5 Whys):

1. **Fallo 1 (Parseo con `split()` en PDB):** La especificación PDB no garantiza espacios entre columnas. Si una coordenada $X = -105.234$ se fusiona con la columna de residuo, `split()` unifica dos campos en uno solo y desfaza toda la tupla. Debe utilizarse **indexación por rebanadas de ancho fijo** (`line[30:38]`).
2. **Fallo 2 (RMSD sin superposición previa):** Si dos estructuras idénticas están trasladadas en el espacio en 100 Å, el RMSD bruto será de 100 Å, concluyendo falsamente que son distintas cuando su geometría interna es idéntica. Debe aplicarse siempre el algoritmo de Kabsch.
3. **Fallo 3 (Dogmatismo en identidad de secuencia):** En la zona de penumbra ($< 20\%$ identidad), el plegamiento se conserva con frecuencia a pesar de la divergencia nucleotídica.

9 Síntesis operativa y tablas de diagnóstico

9.1 Tabla de diagnóstico de fallos en análisis 3D

Síntoma observado	Causa probable	Comprobación y corrección
Error de conversión ValueError en coordenadas	Colisión de caracteres en columnas de ancho fijo	Extraer coordenadas mediante slices fijos <code>line[30:38]</code>
RMSD artificialmente alto (> 50 Å)	Estructuras en marcos de referencia distintos	Centrar centroides y aplicar superposición de Kabsch
Densidad de contacto nula (0.0)	Umbral de corte demasiado restrictivo	Emplear el umbral estándar $d_{\text{corte}} = 8.0$ Å
Falso desorden en cristales	Factores B elevados por movilidad térmica local	Analizar perfiles de B-factor en bucles vs núcleo rígido

9.2 Tabla de síntesis: Niveles de organización y descriptores

Nivel de análisis	Descriptores geométricos	Formato computacional	Herramientas estándar
Primario	Secuencia alfanumérica IU-PAC	FASTA, cadenas <code>str</code>	BioPython, BLAST
Secundario	Ángulos diedros (ϕ, ψ) , puentes H	Diagrama Ramachandran	DSSP, STRIDE
Terciario	Coordenadas (x, y, z) , mapas contacto	PDB, mmCIF, matrices	PyMOL, VMD

Nivel de análisis	Descriptores geométricos	Formato computacional	Herramientas estándar
Comparación 3D	Desviación cuadrática (RMSD), TM-score	Rotaciones SVD	Algoritmo de Kabsch

10 Glosario conceptual

- **Anfinsen:** Hipótesis del mínimo de energía libre de Gibbs.
- **IDPs:** Proteínas intrínsecamente desordenadas y flexibles.
- **PDB:** Formato estándar en columnas fijas de 80 caracteres.
- **ATOM / HETATM:** Registros de átomos estándar y ligandos.
- **Centroide:** Centro geométrico medio de coordenadas 3D.
- **Mapa de contacto:** Matriz binaria C_{ij} con corte 8.0 Å.
- **RMSD:** Desviación cuadrática media de coordenadas atómicas.
- **Kabsch:** Rotación óptima mediante descomposición SVD.
- **Factor B:** Desplazamiento térmico atómico Debye-Waller.
- **CATH / SCOP:** Bases de datos jerárquicas de dominios 3D.

11 Conexiones y cierre de la Parte I

Este capítulo cierra la Parte I cumpliendo el contrato de interfaz secuencia-estructura-función como interpretación biológica consumida en BC-CH09.

El cierre de la Parte I conecta la representación de secuencias discretas con la biología estructural, preparando el terreno para el alineamiento y tecnologías genómicas de la Parte II.

12 Fuentes y reproducibilidad

Este capítulo se apoya en la presentación docente sobre proteínas de la asignatura, escrita por Álvaro Serrano Navarro. La hipótesis termodinámica del plegamiento sigue a Anfinsen [1]; la superposición óptima de dos conjuntos de coordenadas, a Kabsch [4]; el formato del banco de datos, a Berman y colaboradores [2]; y la jerarquía de dominios y los plegamientos canónicos, a Branden y Tooze [3].

Todos los cálculos se reproducen con `verification/chapter_checks.py` tal como están impresos, con sus argumentos.

Anexo práctico · Estructura 3D de proteínas, matrices de contacto y RMSD

Pregunta, producto y separación de materiales

¿Puede escribir las tres medidas con que se describe una estructura, distancia, centroide y mapa de contactos, y explicar qué información conserva cada una y cuál tira? Este laboratorio responde que sí, y comprueba su módulo con coordenadas que usted no ha visto.

El producto individual es `mi_geometria.py`. Las tres funciones son cortas; lo que se evalúa es que cumplan sus propiedades: que la distancia sea simétrica, que el centroide de un punto sea ese punto, y que subir el umbral del mapa de contactos nunca reduzca el número de contactos. Son propiedades que se pueden comprobar sin conocer ningún resultado esperado, y por eso son mejores pruebas que un valor memorizado.

El anexo es autónomo: usa la estructura sintética de `data/` como entrada de solo lectura.

Mapa de ruta y productos entregables

Bloque de trabajo	Producto entregable
1 · Entorno y diagnóstico	Comprobación del intérprete Python 3.9
2 · Cálculo ancla (PDB, Centroide, RMSD)	Extracción de coordenadas, centroide y RMSD base
3 · Perturbación de matriz de contactos	Variación del umbral de corte a 15.0 Å
4 · Guarda de dominio	Captura de ValueError ante línea PDB incompleta
5 · Preguntas de control estructural	Preguntas sobre Anfinsen, PDB y Kabsch
6 · Verificación y empaquetado	Comprobación final y empaquetado

Este anexo produce evidencia comprobable y verificable en cada bloque de trabajo sin paquetes externos.

1 · Preparar el espacio de trabajo

```
python3 --version
./practice_assets/create_workspace.sh BC05_entrega
cd BC05_entrega
cd datos && sha256sum -c manifest.sha256 && cd ..
```

2 · Escribir el módulo de geometría

Tarea. Implemente las tres funciones de `mi_geometria.py`: distancia entre dos puntos, centroide de un conjunto y mapa de contactos por debajo de un umbral. El contrato está en la documentación de la plantilla.

Antes de escribir nada, piense qué información conserva cada una. La distancia entre dos átomos conserva todo lo que hay entre esos dos y nada del resto. El centroide resume una nube entera en un punto y pierde su forma: dos estructuras muy distintas pueden tener el mismo centroide. El mapa de contactos conserva la vecindad y pierde la orientación, y por eso es invariante a rotaciones, que es exactamente lo que hace falta para comparar dos plegamientos.

Comprueba. Antes de ejecutar el comprobador, pruebe usted mismo estas tres cosas: que la distancia de un punto a sí mismo es cero, que el centroide de un solo punto es ese punto, y que subir el umbral no puede reducir el número de contactos. Las tres se comprueban sin saber ningún resultado de antemano, y son mejores pruebas que memorizar un número.

```
bash herramienta/check_geometria.sh
```

3 · Cálculo ancla: extracción, centroide y comparación

Dada la línea PDB modelo y el triplete de coordenadas C_α [(0,0,0), (3,4,0), (3,4,12)]:

1. Parsee la línea PDB estándar extrayendo residuo MET y posición inicial (0.0,0.0,0.0).
2. Calcule el centroide molecular: $\mathbf{r}_{\text{cen}} = (2.000000, 2.666667, 4.000000)$.
3. Evalúe los contactos con umbral $d_{\text{corte}} = 8.0$ Å: 1 contacto de 3 pares (Densidad = 0.333333).
4. Calcule el RMSD frente a la traslación rígida de +1.0 Å en X: RMSD = 1.000000 Å.

```
python3 herramienta/chapter_checks.py centroid 0,0,0 3,0,0 0,3,0 > resultados/ancla.txt
cat resultados/ancla.txt
```

El modelo ancla produce el parsing de Met CA, centroide (2.000000, 2.666667, 4.000000), 1 contacto a 8.0 Å y RMSD de 1.000000 Å.

Se reproduce con `verification/chapter_checks.py centroid 0,0,0 3,0,0 0,3,0`.

4 • Perturbación del umbral de contactos

Aumente el umbral de corte de distancia a 15.0 Å:

```
python3 herramienta/chapter_checks.py contacts --cutoff 8.0 0,0,0 3,0,0 10,0,0 > resultados/contactos_8.txt
python3 herramienta/chapter_checks.py contacts --cutoff 4.0 0,0,0 3,0,0 10,0,0 > resultados/contactos_4.txt
cat resultados/contactos_8.txt resultados/contactos_4.txt
```

La perturbación del umbral de corte a 15.0 Å evalúa 3 contactos de 3 pares posibles (densidad de 1.000000).

Se reproduce con `verification/chapter_checks.py contacts --cutoff 4.0 0,0,0 3,0,0 10,0,0`.

5 • Guarda de formato y control de excepciones

Compruebe que el parser de ancho fijo rechaza registros truncados o malformados:

```
python3 herramienta/chapter_checks.py parse_atom "ATOM 1 CA" > resultados/guarda.txt
cat resultados/guarda.txt
```

La guarda de dominio rechaza la línea PDB incompleta `ATOM 1 CA` lanzando un `ValueError` que identifica el registro no válido.

Se reproduce con `verification/chapter_checks.py parse_atom "ATOM 1 CA"`.

6 • Empaquetar y verificar

Escriba antes `notas/defensa.md`. Después:

```
cd ..
tar -czf BC05_entrega.tar.gz BC05_entrega
sha256sum BC05_entrega.tar.gz
./practice_assets/check_entrega.sh BC05_entrega BC05_entrega.tar.gz
```

El verificador prueba su módulo con coordenadas que no ha visto, comprueba que la estructura de partida no se ha modificado, que la tabla de respuestas tiene al menos cuatro filas con justificación y una sobre el umbral, y que existe la defensa. Rechaza el espacio recién generado. No puntúa.

Rúbrica de calificación ponderada

La evaluación sobre 10 puntos se pondera según:

- **4.0 puntos (40%):** Ejecución correcta y reproducible de los scripts de comprobación (`chapter_checks.py` y `practice_checks.py`).
- **2.0 puntos (20%):** Cálculo manual y exacto del centroide molecular (2.000000, 2.666667, 4.000000) y distancias interatómicas (Bloque 2).
- **2.0 puntos (20%):** Evaluación de la matriz de contactos perturbada y control de excepciones en la guarda de dominio (Bloques 3 y 4).
- **2.0 puntos (20%):** Defensa conceptual escrita (100–150 palabras) sobre por qué la relación secuencia-estructura-función es un marco interpretativo y no determinista, y la necesidad del algoritmo de Kabsch antes de calcular RMSD.

Lista de autocorrección

- Verifiqué que mi versión de Python es ≥ 3.9 .
- El parser PDB extrajo correctamente los campos de ancho fijo.
- El cálculo del centroide fue exacto.
- La matriz de contactos con umbral 8.0 Å arrojó densidad 0.333333.
- La matriz de contactos con umbral 15.0 Å arrojó densidad 1.000000.
- El valor de RMSD para la traslación rígida evaluó a 1.000000 Å.
- Verifiqué que `ATOM 1 CA` lanza `ValueError`.
- Redacté la defensa conceptual individual.

Defensa conceptual

En 100–150 palabras, argumente por qué una alta divergencia de secuencia primaria no descarta necesariamente una estructura y función equivalentes, y por qué es matemáticamente obligatorio centrar y alinear las estructuras mediante superposición de Kabsch antes de evaluar el valor de RMSD.

Fuentes y reproducibilidad

Este anexo se fundamenta en las diapositivas de modelado estructural (20251125_estprot.pptx), en el formato PDB (Berman et al., 2000), en Anfinsen (1973) y Kabsch (1976), y se valida al 100% mediante `verification/practice_checks.py`.

Bibliografía

- [1] Christian B. Anfinsen. Principles that govern the folding of protein chains. *Science*, 181(4096):223–230, 1973. Artículo del Premio Nobel que establece la hipótesis termodinámica del plegamiento proteico.
- [2] Helen M. Berman, John Westbrook, Zukang Feng, Gary Gilliland, T. N. Bhat, Helge Weissig, Ilya N. Shindyalov, and Philip E. Bourne. The protein data bank. *Nucleic Acids Research*, 28(1):235–242, 2000. Especificación y estructura del repositorio global Protein Data Bank (PDB).
- [3] Carl-Ivar Brändén and John Tooze. *Introduction to Protein Structure*. Garland Science, 2nd edition, 1999. Tratado clásico sobre relación secuencia-estructura-función y dominios proteicos.
- [4] Wolfgang Kabsch. A solution for the best rotation to relate two sets of vectors. *Acta Crystallographica Section A*, 32(5):922–923, 1976. Algoritmo de superposición estructural y minimización del RMSD entre coordenadas tridimensionales.