

Tecnologías de secuenciación y diseño experimental: Química de ácidos nucleicos, modelo de Lander-Waterman y dimensionamiento genómico

BC-CH06 – Biología Computacional

Edición 2 · 2026-09-04

Pregunta del tema. Secuenciar el primer genoma humano costó unos tres mil millones de dólares y trece años. Hoy se hace en un día por menos de mil. ¿Qué cambió exactamente, y qué decisiones hay que tomar antes de encargar una secuenciación para que los datos sirvan?

Producto final. Una calculadora de dimensionamiento escrita por usted que, dado un genoma y una profundidad objetivo, diga cuántas lecturas hacen falta, y que avise cuando los parámetros no tengan sentido físico.

Mapa del tema

1. Del corte químico a la lectura masiva	2
2. Antes de la máquina: la preparación de la librería	2
3. Segunda generación: Secuenciación masiva en paralelo (NGS)	3
4. Tercera generación: Molécula única y lecturas largas	3
5. Métricas teóricas: Cobertura y profundidad genómica	4
6. El modelo estadístico de Lander-Waterman	5
7. Dimensionamiento experimental y control de sesgo GC	5
8. Diseño experimental riguroso en genómica	6
9. Diseño computacional en Python: Calculadora genómica	7
10. Peligros computacionales y actividad de depuración	8
11. Síntesis operativa y tablas de diagnóstico	8
12. Glosario conceptual	9
13. Conexiones y mapa del curso	9
14. Fuentes y reproducibilidad	9

Cómo usar este tema

Este capítulo es de tecnología, y por eso conviene leerlo con una pregunta en la cabeza: qué decisión permite tomar cada cosa que se explica. Las plataformas no se estudian por coleccionismo, sino porque cada una tiene un perfil de error distinto y eso condiciona todo el análisis posterior. Y el dimensionamiento no es una fórmula: es la decisión de cuánto dinero gastar para obtener datos utilizables.

Al terminar sabrá: distinguir las generaciones de secuenciación por lo que cada una resuelve y lo que cada una no; explicar qué pasos del laboratorio introducen los sesgos que después hay que corregir por ordenador; calcular la profundidad que da un número de lecturas y, al revés, las lecturas que exige una profundidad; y decir por qué una cobertura media de treinta no garantiza que todas las posiciones estén cubiertas.

La ruta **esencial** son las tres generaciones, la preparación de la librería, la cobertura y el dimensionamiento. La ruta de **estudio** añade el modelo estadístico de huecos, el sesgo por composición, el diseño experimental y el anexo.

Hito	Cuándo	Rendimiento por carrera	Coste por genoma humano
Método de terminación	desde 1977	del orden de kilobases	miles de millones de dólares
Primera secuenciación masiva	mediados de los 2000	del orden de gigabases	centenares de miles
Plataformas actuales de lectura corta	desde 2015	del orden de terabases	unos centenares

Concepto. Ese salto de nueve órdenes de magnitud en rendimiento, y de siete en coste, es la razón de que exista la bioinformática como disciplina con problemas propios. Cuando secuenciar era caro, el cuello de botella estaba en el laboratorio; ahora está en el análisis. Un experimento produce en un día más datos de los que una persona puede mirar en su vida, y eso obliga a decidir de antemano qué se va a medir y cómo.

1 Del corte químico a la lectura masiva

ESENCIAL Antes de alinear, ensamblar o llamar variantes hay que saber de dónde salen las lecturas y con qué sesgos vienen. Eso lo decide la **tecnología de secuenciación**, y es lo que trata este capítulo.

A lo largo del último medio siglo, la capacidad de descifrar el orden lineal de las bases nitrogenadas en el ADN ha experimentado una transformación tecnológica radical dividida en tres grandes generaciones:

1.1 Primera generación: Secuenciación enzimática y capilar

1. **Método químico de Maxam-Gilbert (1977):** Basado en el marcaje radiactivo con ^{32}P en el extremo 5' y la escisión química específica de bases mediante reactivos agresivos (sulfato de dimetilo para purinas, hidrazina para pirimidinas), seguido de electroforesis en gel de poliacrilamida. Fue rápidamente desplazado por su toxicidad y baja automatizabilidad.
2. **Método de terminación de cadena de Sanger (1977):** Desarrollado por Fred Sanger (galardonado con su segundo Premio Nobel de Química en 1980), se fundamenta en la síntesis enzimática *in vitro* utilizando una ADN polimerasa, los cuatro desoxirribonucleótidos estándar (dNTPs) y una pequeña proporción de **dideoxirribonucleótidos trifosfato (ddNTPs)** marcados con fluoróforos. Al carecer del grupo hidroxilo en el carbono 3' (3'-OH), la incorporación de un ddNTP impide estéricamente la formación del siguiente enlace fosfodiéster, terminando la elongación de la cadena de forma específica.

La automatización de la técnica de Sanger mediante **electroforesis capilar** fluorescente (desde el secuenciador ABI 370 en 1985 hasta el ABI 3700 de 96 capilares en 1999) permitió la culminación del histórico **Proyecto Genoma Humano (HGP, 1990–2003)**, produciendo lecturas de alta precisión (> 99.9%) con longitudes de hasta 800–1.000 pares de bases, pero con un coste económico y temporal prohibitivo para la medicina clínica personalizada.

La secuenciación de primera generación comprende la escisión química de Maxam-Gilbert y la terminación de cadena con dideoxinucleótidos (ddNTPs) de Sanger mediante electroforesis capilar.

2 Antes de la máquina: la preparación de la librería

ESENCIAL Ninguna plataforma secuencia una muestra biológica directamente. Entre el tubo y el instrumento hay un procedimiento de laboratorio, la *preparación de la librería*, que convierte el material genético en una colección de fragmentos compatibles con la química de la máquina. Conocerlo importa por una razón concreta: casi todos los sesgos que después habrá que corregir por medios computacionales se introducen aquí.

1. **Extracción.** Se obtiene ADN, o ARN que se retrotranscribe a ADN complementario. Ya en este paso la calidad y la integridad del material condicionan todo lo demás.
2. **Fragmentación.** El material se corta en trozos del tamaño que la plataforma admite. Hay tres vías y no son equivalentes:

Vía	A favor	En contra
Física	amplio rango de tamaños, prácticamente insesgada	requiere equipo específico
Química	adecuada para ARN, poca variación entre muestras	menos control del tamaño
Enzimática	equipo común, muy escalable, basta poco material	introduce sesgo allí donde la enzima corta con preferencia

Una variante muy extendida, la *tagmentación*, fragmenta y añade los adaptadores en un solo paso enzimático, lo que abarata y acelera el procedimiento a costa de un sesgo de inserción conocido.

3. **Reparación de extremos y ligación de adaptadores.** Los cortes dejan extremos irregulares que se reparan, y a cada fragmento se le liga por los dos lados una secuencia conocida, el adaptador. Sirve para tres cosas a la vez: anclar el fragmento a la superficie de la máquina, dar el punto de partida a la polimerasa y, mediante un código propio de cada muestra, permitir mezclar varias muestras en una misma carrera y separarlas después.
4. **Amplificación.** Se hacen copias por reacción en cadena de la polimerasa para tener señal suficiente.
5. **Purificación y control de calidad.** Se retiran adaptadores libres y fragmentos fuera de rango, y se comprueba la distribución de tamaños antes de cargar la máquina.

Atención. El paso de amplificación es el que introduce el sesgo por composición que este capítulo cuantifica más adelante. La polimerasa copia con menor eficiencia los fragmentos de composición extrema, muy ricos o muy pobres en G y C, y esas regiones acaban infrarrepresentadas en los datos. Cuando después vea una región del genoma con cobertura anormalmente baja, la primera hipótesis no es que falte en el genoma: es que se amplificó peor. Ese es el orden causal que conviene tener claro, porque determina qué se puede corregir por ordenador y qué no: un sesgo introducido aquí se puede modelar y compensar, pero la información que no se llegó a generar no se recupera.

3 Segunda generación: Secuenciación masiva en paralelo (NGS)

A mediados de la década de 2000 emergió la **Secuenciación de Nueva Generación (NGS)** o segunda generación, reduciendo el coste de secuenciación por base en más de cinco órdenes de magnitud (superando con creces la ley de Moore) mediante la paralelización masiva de millones de reacciones simultáneas en superficies miniaturizadas:

1. Secuenciación por síntesis de Illumina:

- **Amplificación clonal en fase sólida:** Las moléculas de ADN adaptadas se hibridan en una celda de flujo de vidrio (*flow cell*) y se amplifican mediante PCR en puente (*bridge amplification*) o amplificación por exclusión, generando densos **cúmulos clonales** (*clusters*) de ≈ 1.000 copias idénticas para amplificar la señal óptica.
- **Terminadores fluorescentes reversibles:** En cada ciclo de secuenciación se añade una mezcla de los cuatro dNTPs modificados, cada uno con un fluoróforo de emisión característica y un grupo bloqueador reversible en el extremo 3'-OH (3'-O-azidometilo). La polimerasa incorpora únicamente un nucleótido por ciclo.
- **Captura de imagen y desbloqueo:** Un sensor óptico de alta resolución registra la fluorescencia emitida en cada cúmulo; a continuación, un reactivo químico corta el fluoróforo y regenera el grupo 3'-OH libre, permitiendo que comience el siguiente ciclo de incorporación.
- **Rendimiento:** Produce miles de millones de **lecturas cortas** de extraordinaria precisión (150–300 pb, tasa de error $< 0.1\%$).

2. **Detección semiconductor de Ion Torrent:** Prescinde de óptica y láseres. Se basa en la monitorización directa mediante microchips semiconductores CMOS de los protones (H^+) liberados como subproducto natural cada vez que una ADN polimerasa incorpora un dNTP complementario, detectando cambios infinitesimales de pH en micropozos individuales.

La secuenciación de segunda generación (NGS) se basa en la secuenciación por síntesis masiva en paralelo (Illumina) y detección de pH por semiconductores (Ion Torrent), generando lecturas cortas de alta precisión.

4 Tercera generación: Molécula única y lecturas largas

A pesar del éxito abrumador de la NGS, las lecturas cortas (150 pb) son incapaces de resolver regiones genómicas repetitivas complejas, elementos transponibles largos (LINEs de 6 kb), variantes estructurales masivas (CNVs) o

ensamblajes cromosómicos de telómero a telómero (T2T). Para superar estas limitaciones, la **tercera generación** secuencía moléculas individuales de ADN sin amplificación previa por PCR:

1. **Pacific Biosciences (PacBio SMRT)**: Utiliza nanoestructuras ópticas denominadas **guías de onda en modo cero (ZMWs)**, cavidades cilíndricas de diámetro inferior a la longitud de onda de la luz donde se inmoviliza una única molécula de ADN polimerasa en el fondo. Mediante el protocolo de **lectura de consenso circular (HiFi)**, una misma molécula circularizada es leída múltiples veces en pasadas sucesivas, generando lecturas largas (15–25 kb) con una precisión superior al 99.9%.
2. **Oxford Nanopore Technologies (ONT)**: Aplica una diferencia de potencial eléctrico a través de una membrana sintética con **nanoporos proteicos biológicos**. A medida que la cadena simple de ADN transloca por el poro, bloquea físicamente el flujo iónico de manera característica según el *k*-mero presente en el canal, registrando variaciones de corriente eléctrica (*pA*). Las señales eléctricas son decodificadas en bases nucleotídicas mediante redes neuronales profundas, produciendo lecturas continuas (> 100 kb hasta megabases) y permitiendo la **detección directa de modificaciones epigenéticas nativas** (5mC, 6mA) sin tratamiento químico previo con bisulfito.

La secuenciación de tercera generación de lecturas largas comprende PacBio SMRT (guías de onda ZMW) y Oxford Nanopore (detección de corriente iónica en nanoporos proteicos).




Figura 1: Comparativa tecnológica de las tres generaciones de secuenciación de ácidos nucleicos: principios químicos, longitud de lectura y rendimiento. Figura original generada por `verification/make_figures.py`.

5 Métricas teóricas: Cobertura y profundidad genómica

En el diseño de proyectos genómicos, la **profundidad de secuenciación o cobertura teórica media** (*C*) se define como el número medio de veces que una posición nucleotídica del genoma de referencia es secuenciada en el conjunto de datos:

$$C = \frac{N \times L}{G}$$

donde *N* es el número total de lecturas secuenciadas, *L* es la longitud media de cada lectura en pares de bases y *G* es el tamaño total del genoma o región diana en pares de bases.

La cobertura genómica de secuenciación *C* calcula la profundidad dividiendo el total de bases secuenciadas por el tamaño del genoma diana *G* mediante $C = (N * L) / G$.

Traza manual para el lote genómico modelo:

Para *N* = 100 lecturas de longitud *L* = 150 pb alineadas sobre un genoma bacteriano de *G* = 3.000 pb:

$$C = \frac{100 \times 150}{3000} = \frac{15000}{3000} = 5.000000X$$

`calculate_coverage` evalúa 100 lecturas de 150 pb sobre un genoma diana de 3000 pb exactamente en 5.000000X.

Se reproduce con `verification/chapter_checks.py coverage --reads 100 --length 150 --genome 3000`.

Control defensivo de dimensiones inválidas:

`calculate_coverage` lanza `ValueError` ante dimensiones genómicas no positivas como $G = -100$.

Se reproduce con `verification/chapter_checks.py coverage --reads 100 --length 150 --genome -100`.

6 El modelo estadístico de Lander-Waterman

En 1988, Eric Lander y Michael Waterman formularon el modelo matemático canónico para la secuenciación aleatoria (*shotgun sequencing*). Asumiendo que el proceso de fragmentación y secuenciación muestrea el genoma de manera puramente aleatoria e independiente, el número de lecturas que cubren una posición genómica dada sigue una **distribución de Poisson** con parámetro $\lambda = C$:

$$P(k) = \frac{C^k e^{-C}}{k!}$$

donde $P(k)$ es la probabilidad de que una base específica esté cubierta por exactamente k lecturas.

- **Fracción de genoma no cubierto (lagunas o gaps):** Probabilidad de cobertura cero ($k = 0$):

$$\text{Fracción no cubierta} = P(0) = e^{-C}$$

- **Fracción de genoma cubierto:** Proporción de bases cubiertas por al menos una lectura ($k \geq 1$):

$$\text{Fracción cubierta} = 1 - P(0) = 1 - e^{-C}$$

El modelo de Poisson de Lander-Waterman calcula la fracción no cubierta del genoma como e^{-C} y la fracción cubierta como $1 - e^{-C}$ bajo muestreo aleatorio uniforme.

Traza manual para una cobertura $C = 5.00X$:

1. Fracción no cubierta = $e^{-5.0} \approx 0.006738$ (0.6738%).
2. Fracción cubierta = $1 - 0.006738 = 0.993262$ (99.3262%).

Para una cobertura de 5.00X, el modelo de Lander-Waterman evalúa la fracción de lagunas en 0.006738 y la fracción cubierta en 0.993262.

Se reproduce con `verification/chapter_checks.py poisson_gaps --coverage 5.0`.

7 Dimensionamiento experimental y control de sesgo GC

Para garantizar estadísticamente que se alcanza una profundidad objetivo C_{target} dada una longitud de lectura L y tamaño de genoma G , el número mínimo de lecturas requeridas N se obtiene despejando la ecuación de cobertura:

$$N_{\text{requerido}} = \left\lceil \frac{C_{\text{target}} \times G}{L} \right\rceil$$

Traza manual para $C_{\text{target}} = 30.0X$, $G = 3000$ pb, $L = 150$ pb:

$$N = \frac{30.0 \times 3000}{150} = \frac{90000}{150} = 600 \text{ lecturas}$$

`required_reads` calcula el número mínimo de lecturas requeridas para una profundidad objetivo, produciendo exactamente 600 lecturas para 30.0X sobre 3000 pb con lecturas de 150 pb.

Se reproduce con `verification/chapter_checks.py required_reads --target_cov 30.0 --length 150 --genome 3000`.




Figura 2: Modelo estadístico de Poisson de Lander-Waterman: caída exponencial de bases no cubiertas ($P(0) = e^{-C}$) y asíntota de cobertura completa. Figura original generada por `verification/make_figures.py`.

7.1 Evaluación cuantitativa del sesgo de contenido GC

Las enzimas de polimerasa empleadas en la amplificación por PCR durante la preparación de librerías presentan una marcada ineficiencia cinética al amplificar regiones extremas con muy alto o muy bajo contenido de Guanina y Citosina (%GC). La métrica de sesgo GC evalúa el ratio entre el contenido GC observado en las lecturas respecto al valor genómico esperado:

$$\text{Sesgo GC} = \frac{GC_{\text{observado}}}{GC_{\text{esperado}}}$$

Traza manual para un $GC_{\text{obs}} = 60.0\%$ frente a un $GC_{\text{exp}} = 50.0\%$:

$$\text{Sesgo GC} = \frac{60.0}{50.0} = \frac{0.60}{0.50} = 1.200000$$

`gc_bias_metric` calcula el ratio de GC observado sobre esperado, rindiendo exactamente 1.200000 para 60.0 por ciento observado frente a 50.0 por ciento esperado.

Se reproduce con `verification/chapter_checks.py gc_bias --obs 60.0 --exp 50.0`.

8 Diseño experimental riguroso en genómica

Un diseño experimental defectuoso invalida cualquier análisis bioinformático posterior, independientemente de la sofisticación de los algoritmos empleados:

- **Réplicas biológicas frente a réplicas técnicas:** Las **réplicas biológicas** (muestras obtenidas de individuos u organismos independientes) capturan la variabilidad biológica natural de la población y son estrictamente obligatorias para la inferencia estadística (p. ej., análisis de expresión diferencial con DESeq2/edgeR). Las **réplicas técnicas** (secuenciación repetida de la misma muestra extraída) solo miden la precisión del instrumento. Tratar réplicas técnicas como si fueran biológicas constituye el grave error metodológico de **pseudorreplicación**.
- **Mitigación de efectos de lote (*Batch Effects*):** Ocurren cuando variables técnicas no biológicas (diferentes días de preparación, técnicos de laboratorio, lotes de reactivos o carriles de celda de flujo) correlacionan espuriamente con las condiciones biológicas de estudio. Se neutralizan mediante el **diseño en bloques aleatorizados** y la secuenciación distribuida de condiciones en los mismos carriles.




Figura 3: Sesgo de amplificación por contenido GC en plataformas NGS: zona óptima central (35–60%) y atenuación de cobertura en extremos. Figura original generada por `verification/make_figures.py`.

El diseño experimental riguroso requiere réplicas biológicas sobre técnicas para capturar la variabilidad poblacional genuina para inferencia estadística válida.

La mitigación del efecto de lote requiere la aleatorización de muestras entre celdas de flujo y un diseño de bloques balanceado.

8.1 Umbrales estándar de profundidad según la pregunta biológica

La profundidad de secuenciación objetivo varía estrictamente según la pregunta biológica: 30X para WGS germinal, >100X para oncología somática y 20-50M de lecturas para RNA-seq diferencial.

9 Diseño computacional en Python: Calculadora genómica

A continuación se presenta el módulo computacional en Python 3.9:

```
import math
from typing import Tuple

def calculate_coverage(num_reads: int, read_length: int, genome_size: int) -> float:
    """Calcula la cobertura teorica media de secuenciacion."""
    if num_reads <= 0 or read_length <= 0 or genome_size <= 0:
        raise ValueError("Parametros de cobertura deben ser enteros estrictamente positivos")
    return round((num_reads * read_length) / genome_size, 6)

def calculate_lander_waterman(coverage: float) -> Tuple[float, float]:
    """Calcula la fraccion de genoma no cubierta y cubierta bajo Poisson."""
    if coverage < 0:
        raise ValueError("La cobertura no puede ser negativa")
    gap_fraction = math.exp(-coverage)
    covered_fraction = 1.0 - gap_fraction
    return round(gap_fraction, 6), round(covered_fraction, 6)

def required_reads_for_coverage(target_coverage: float, read_length: int, genome_size: int) -> int:
    """Calcula el numero minimo de lecturas para alcanzar la cobertura deseada."""
    if target_coverage <= 0 or read_length <= 0 or genome_size <= 0:
        raise ValueError("Parametros deben ser estrictamente positivos")
    return math.ceil((target_coverage * genome_size) / read_length)

def calculate_gc_bias(observed_gc: float, expected_gc: float) -> float:
```

```

"""Calcula el ratio de sesgo GC observado frente a esperado."""
if expected_gc <= 0:
    raise ValueError("El contenido GC esperado debe ser mayor que cero")
return round(observed_gc / expected_gc, 6)

```

10 Peligros computacionales y actividad de depuración

Confundir réplicas técnicas con réplicas biológicas (pseudorreplicación) e ignorar el sesgo de GC en las librerías representan fallos críticos de diseño experimental.

10.1 Tres errores críticos en diseño genómico

Localice y corrija los tres errores en la siguiente función:

```

def plan_sequencing_experiment(n_tech_reps, n_bio_reps, target_depth):
    # Error 1: Asume que 10 replicas tecnicas de 1 solo raton sustituyen
    # a tener 10 replicas biologicas independientes (pseudorreplicacion)

    # Error 2: Calcula numero de lecturas ignorando la perdida por bases no cubiertas
    # bajo la distribucion de Poisson de Lander-Waterman

    # Error 3: Secuencia todas las muestras tratadas en el Carril 1 y todos los controles
    # en el Carril 2, introduciendo un efecto de lote irresoluble
    pass

```

Diagnóstico de causa raíz (Protocolo 5 Whys):

- Fallo 1 (Pseudorreplicación):** Medir 10 veces la misma muestra reduce el error de medida instrumental, pero proporciona $N = 1$ en grados de libertad biológicos; no permite extrapolar conclusiones a la población.
- Fallo 2 (Omisión del modelo de Poisson):** Una profundidad media de 1X deja un 36.8% del genoma sin cubrir ($e^{-1} \approx 0.368$). Se requiere al menos 30X para cubrir > 99.999% del genoma.
- Fallo 3 (Confusión de lote con condición):** El efecto de carril queda completamente colineal con el tratamiento biológico, imposibilitando distinguir si las diferencias son biológicas o artefactos del secuenciador.

11 Síntesis operativa y tablas de diagnóstico

11.1 Tabla comparativa de plataformas de secuenciación

Plataforma	Longitud de lectura	Precisión media	Aplicación principal
Sanger (ABI 3730)	800–1000 pb	> 99.99%	Validación clínica, plásmidos
Illumina NovaSeq	150–300 pb	> 99.9% (Q30)	WGS poblacional, RNA-seq
Ion Torrent	200–400 pb	≈ 99.0%	Paneles clínicos rápidos
PacBio Sequel IIe	15–25 kb (HiFi)	> 99.9% (Q30)	Ensamblaje <i>de novo</i> , SVs
Nanoporo de alto rendimiento	de diez kilobases a más de una megabase	98 a 99,5%	lecturas muy largas y metilación directa

11.2 Tabla de diagnóstico de anomalías en secuenciación

Síntoma observado	Causa probable	Comprobación y corrección
Caída de cobertura en promotores	Fuerte sesgo de GC en PCR de libre-ría	Emplear polimerasas optimizadas o protocolos PCR-free
Separación en PCA por fecha de extracción	Efecto de lote técnico (<i>batch effect</i>)	Aplicar corrección con ComBat / SVA o bloquear carriles
Muchas posiciones sin cubrir con cobertura 1	el modelo de Poisson deja un 37% sin cubrir	subir la profundidad a treinta o más
Falsos positivos en variantes somáticas	la frecuencia del alelo tumoral es muy baja	subir la profundidad muy por encima de cien

12 Glosario conceptual

- **Sanger:** Terminación de cadena mediante ddNTPs fluorescentes.
- **NGS:** Secuenciación masiva en paralelo por síntesis.
- **Cúmulo clonal:** ≈ 1000 copias amplificadas en flowcell.
- **PacBio HiFi:** Lecturas largas de alta fidelidad por consenso circular.
- **Nanoporo:** Detección de corriente iónica a través de poro proteico.
- **Cobertura (C):** Profundidad media $C = (N \times L)/G$.
- **Lander-Waterman:** Modelo de Poisson de cobertura (e^{-C}).
- **Sesgo GC:** Desviación en eficiencia de amplificación por GC.
- **Pseudorreplicación:** Confusión de réplicas técnicas con biológicas.
- **Efecto de lote:** Variación técnica espuria ligada a días/carriles.

13 Conexiones y mapa del curso

Este capítulo abre la Parte II conectando la química de secuenciación con los formatos computacionales de lecturas y métricas de calidad en BC-CH07.

Las métricas de secuenciación proporcionan el fundamento necesario para el procesamiento FASTQ, puntuaciones de calidad Phred y mapeo de lecturas en BC-CH07 y BC-CH08.

14 Fuentes y reproducibilidad

Este capítulo se apoya en la presentación docente sobre tecnologías de secuenciación de la asignatura, escrita por Álvaro Serrano Navarro. El método de terminación con terminadores sigue a Sanger y colaboradores [4]; el modelo estadístico de cobertura y huecos, a Lander y Waterman [3]; la comparación entre generaciones y sus perfiles de error, a Goodwin y colaboradores [2]; y los criterios de diseño experimental y replicación, a Conesa y colaboradores [1].

Todos los cálculos se reproducen con `verification/chapter_checks.py` tal como están impresos, con sus argumentos.

Anexo práctico · Tecnologías de secuenciación, cobertura Lander-Waterman y diseño experimental

Pregunta, producto y separación de materiales

¿Puede decidir, con números y no con costumbre, cuántas lecturas encargar para un experimento, y explicar por qué una cobertura media de treinta no significa que todas las posiciones estén cubiertas treinta veces? Este laboratorio responde que sí.

El producto individual es `mi_calculadora.py`, con tres funciones: la cobertura que produce un número de

lecturas, las lecturas que exige una cobertura objetivo, y la fracción de genoma que el modelo deja sin cubrir. Las tres son cortas. Lo que se evalúa es que cumplan sus relaciones: que ir y volver entre las dos primeras dé el mismo sitio, y que la tercera baje cuando la cobertura sube.

El anexo es autónomo: solo necesita la biblioteca estándar. El comprobador prueba su calculadora con genomas y profundidades que el enunciado no muestra.

Mapa de ruta y productos entregables

Bloque de trabajo	Producto entregable
1 · Entorno y diagnóstico	Comprobación del intérprete Python 3.9
2 · Cálculo ancla (Cobertura, Poisson, Sesgo GC)	Cobertura 5.0X, brechas y dimensionamiento
3 · Perturbación a 10.0X	Recálculo de brechas bajo alta cobertura
4 · Guarda de dominio	Captura de ValueError ante $G = -100$
5 · Preguntas de control experimental	Preguntas sobre Lander-Waterman y réplicas
6 · Verificación y empaquetado	Comprobación final y empaquetado

Este anexo produce evidencia comprobable y verificable en cada bloque de trabajo sin paquetes externos.

1 · Preparar el espacio de trabajo

```
python3 --version
./practice_assets/create_workspace.sh BC06_entrega
cd BC06_entrega
```

2 · Escribir la calculadora

Tarea. Implemente las tres funciones de `mi_calculadora.py`. El contrato está en la documentación de la plantilla. Preste atención a dos cosas: el redondeo de las lecturas necesarias, que tiene que ser hacia arriba porque quedarse corto no vale, y la guarda, que debe rechazar un genoma de tamaño cero antes de dividir por él.

Comprueba. Antes de programar nada, conteste sobre el papel: si duplica el número de lecturas, ¿qué le pasa a la cobertura? ¿Y si duplica el tamaño del genoma? Sus dos respuestas son dos de las propiedades que el comprobador verifica, y si las tiene claras, la función se escribe sola.

```
bash herramienta/check_calculadora.sh
```

2 · Cálculo ancla: cobertura, modelo de Poisson y sesgo GC

Dado un experimento de secuenciación con $N = 100$ lecturas, longitud $L = 150$ pb sobre un genoma modelo $G = 3000$ pb:

1. Calcule la cobertura genómica teórica: $C = \frac{100 \times 150}{3000} = 5.000000X$.
2. Aplique el modelo de Lander-Waterman: fracción no cubierta $e^{-5.0} = 0.006738$ y fracción cubierta **0.993262**.
3. Calcule las lecturas requeridas para alcanzar 30.0X: $N_{\text{req}} = 600$ lecturas.
4. Evalúe el sesgo GC para un 60.0% observado frente a un 50.0% esperado: Ratio = **1.200000**.

```
python3 herramienta/chapter_checks.py coverage --reads 100 --length 150 --genome 3000 > resultados/anc.a.txt
cat resultados/anc.a.txt
```

El modelo ancla produce una cobertura de 5.000000X, fracción de brechas de 0.006738, 600 lecturas requeridas para 30X y un ratio de sesgo GC de 1.200000.

Se reproduce con `verification/chapter_checks.py coverage --reads 100 --length 150 --genome 3000`.

3 • Perturbación a alta cobertura (10.0X)

Incremente la profundidad teórica a $C = 10.0X$:

```
python3 herramienta/chapter_checks.py poisson_gaps --coverage 5.0 > resultados/huecos_5.txt
python3 herramienta/chapter_checks.py poisson_gaps --coverage 30.0 > resultados/huecos_30.txt
cat resultados/huecos_5.txt resultados/huecos_30.txt
```

La perturbación a 10.0X de cobertura evalúa la fracción de brechas a 0.000045 y la fracción cubierta a 0.999955.

Se reproduce con `verification/chapter_checks.py poisson_gaps --coverage 30.0`.

4 • Guarda de dominio y control de excepciones

Compruebe que el calculador rechaza dimensiones biológicas físicamente imposibles:

```
python3 herramienta/chapter_checks.py coverage --reads 100 --length 150 --genome -100 > resultados/guarda.txt
cat resultados/guarda.txt
```

La guarda de dominio rechaza un tamaño de genoma negativo $G = -100$ lanzando un `ValueError` que identifica parámetros no estrictamente positivos.

Se reproduce con `verification/chapter_checks.py coverage --reads 100 --length 150 --genome -100`.

6 • Empaquetar y verificar

Escriba antes `notas/defensa.md`. Después:

```
cd ..
tar -czf BC06_entrega.tar.gz BC06_entrega
sha256sum BC06_entrega.tar.gz
./practice_assets/check_entrega.sh BC06_entrega BC06_entrega.tar.gz
```

El verificador prueba su calculadora con parámetros que no ha visto, comprueba que la tabla de respuestas tiene al menos cuatro filas con justificación y una sobre la fracción sin cubrir, y que existe la defensa. Rechaza el espacio recién generado. No puntúa.

Rúbrica de calificación ponderada

La evaluación sobre 10 puntos se pondera según:

- **4.0 puntos (40%)**: Ejecución correcta y reproducible de los scripts de comprobación (`chapter_checks.py` y `practice_checks.py`).
- **2.0 puntos (20%)**: Cálculo manual y exacto de la cobertura genómica (5.000000X) y dimensionamiento de lecturas para 30X (Bloque 2).
- **2.0 puntos (20%)**: Evaluación del modelo de Poisson perturbado a 10.0X y control de excepciones en la guarda de dominio (Bloques 3 y 4).
- **2.0 puntos (20%)**: Defensa conceptual escrita (100–150 palabras) sobre la primacía de las réplicas biológicas frente a las técnicas y la aplicación del modelo de Lander-Waterman.

Lista de autocorrección

- Verifiqué que mi versión de Python es ≥ 3.9 .
- El cálculo de cobertura C fue 5.000000X.
- La fracción de brechas e^{-5} fue 0.006738.
- Las lecturas requeridas para 30X fueron 600.
- El ratio de sesgo GC fue 1.200000.
- La cobertura perturbada arrojó 0.000045 de brechas.
- Verifiqué que $G = -100$ lanza `ValueError`.
- Redacté la defensa conceptual individual.

Defensa conceptual

En 100–150 palabras, justifique por qué multiplicar las réplicas técnicas de una única muestra no sustituye a la replicación biológica independiente para el control de falsos descubrimientos (FDR), y cómo el modelo de Poisson de Lander-Waterman predice el rendimiento decreciente de aumentar indefinidamente la cobertura.

Fuentes y reproducibilidad

Este anexo no usa datos externos ni paquetes de terceros. El modelo estadístico de cobertura y huecos sigue a Lander y Waterman [3], y los criterios de diseño experimental, a Conesa y colaboradores [1].

Bibliografía

- [1] Ana Conesa, Pedro Madrigal, Sonia Tarazona, David Gomez-Cabrero, Andrea Cervera, Andrew McPherson, Michał W. Szczesiński, Daniel J. Gaffney, Laura L. Elo, Xuegong Zhang, and Ali Mortazavi. A survey of best practices for rna-seq data analysis. *Genome Biology*, 17(1):13, 2016. Guías metodológicas y diseño experimental para estudios transcriptómicos con NGS.
- [2] Sara Goodwin, John D. McPherson, and W. Richard McCombie. Coming of age: Ten years of next-generation sequencing technologies. *Nature Reviews Genetics*, 17(6):333–351, 2016. Revisión exhaustiva sobre plataformas de secuenciación de segunda y tercera generación.
- [3] Eric S. Lander and Michael S. Waterman. Genomic mapping by fingerprinting random clones: A mathematical analysis. *Genomics*, 2(3):231–239, 1988. Modelo matemático fundacional de cobertura de secuenciación y distribución de Poisson.
- [4] Frederick Sanger, Steven Nicklen, and Alan R. Coulson. Dna sequencing with chain-terminating inhibitors. *Proceedings of the National Academy of Sciences*, 74(12):5463–5467, 1977. Método clásico de secuenciación de primera generación por terminación de cadena con ddNTPs.