

Contents

1	Calidad de lecturas, formato FASTQ y preprocesamiento	1
1.1	La incertidumbre física de la secuenciación	1
1.2	Anatomía y estructura del formato FASTQ	1
1.2.1	Arquitecturas de secuenciación: Single-End frente a Paired-End	2
1.3	La escala de calidad Phred (Q score) y codificación ASCII	2
1.3.1	Niveles de calidad estándar e interpretación	2
1.3.2	Codificación estándar Sanger Phred+33	2
1.3.3	Validación defensiva de caracteres Phred	3
1.4	Control de calidad con FastQC	3
1.5	Preprocesamiento y recorte de calidad (<i>Trimming</i>)	4
1.6	Genomas de referencia y sistemas de coordenadas	4
1.6.1	Sistemas de coordenadas en genómica computacional	5
1.7	Diseño computacional en Python	5
1.8	Peligros computacionales en preprocesamiento	5
1.9	Actividad de depuración: 3 errores en procesamiento FASTQ	5
1.10	Síntesis operativa y tablas de diagnóstico	6
1.10.1	Tabla de diagnóstico de problemas de calidad FASTQ	6
1.10.2	Tabla de síntesis: equivalencias de escala Phred	6
1.11	Glosario conceptual	6
1.12	Cierre y conexiones hacia adelante	7
1.13	Fuentes y reproducibilidad	7
	Anexo práctico · Formato FASTQ, decodificación Phred y filtrado por ventana deslizante	9

Chapter 1

Calidad de lecturas, formato FASTQ y preprocesamiento

1.1 La incertidumbre física de la secuenciación

Durante la secuenciación de ácidos nucleicos, los detectores ópticos o electrónicos de los secuenciadores miden señales físicas continuas (intensidades de fluorescencia, emisiones de fotones o corrientes iónicas en picoamperios). La conversión de estas señales analógicas en una cadena discreta de bases nucleotídicas (A, C, G, T, N) se denomina **llamada de bases** (*basecalling*).

Esencial

Dado que todo proceso físico de medición conlleva ruido instrumental, decaimiento de señal y superposición de fases (*phasing*), cada nucleótido asignado no es una certeza matemática absoluta, sino una **estimación probabilística**. Para no perder esta información crítica durante el análisis bioinformático, la comunidad científica estandarizó el formato **FASTQ**, que almacena en un único archivo de texto la secuencia leída junto con la probabilidad de error de cada base individual codificada en la escala **Phred**.

La ruta **esencial** cubre la anatomía de 4 líneas del formato FASTQ, la definición logarítmica de la escala de calidad Phred (Q), la codificación ASCII estándar Sanger Phred+33, las métricas diagnósticas de FastQC y el algoritmo de recorte por ventana deslizante; 120–140 minutos. La ruta de **estudio** profundiza en arquitecturas *paired-end*, sistemas de coordenadas sobre genomas de referencia FASTA (1-based vs 0-based), peligros de promediado de calidades, actividad de depuración y el anexo práctico; 60–80 minutos adicionales.

Esencial

1.2 Anatomía y estructura del formato FASTQ

Un archivo FASTQ almacena millones de lecturas (*reads*) individuales. Cada lectura se estructura invariablemente en un bloque de **exactamente cuatro líneas**:

1. **Línea 1 (Cabecera de identificación):** Comienza obligatoriamente por el carácter @, seguido del identificador único de la lectura e información técnica del secuenciador:

```
@EAS139:136:FC706VJ:2:2104:15343:197393 1:N:0:18
```

que especifica el identificador del instrumento (**EAS139**), número de corrida (**136**), ID de la *flowcell* (**FC706VJ**), carril (**2**), tesela (**2104**), coordenadas cartesianas ($X : Y$), miembro del par (**1** o **2**), filtro superado (**N**) e índice de muestra (**18**).

2. **Línea 2 (Secuencia de bases):** Cadena continua de nucleótidos (A, C, G, T) y bases ambiguas (N cuando el algoritmo de *basecalling* no puede resolver la base).

3. **Línea 3 (Separador):** Comienza obligatoriamente por el carácter +, pudiendo repetir opcionalmente el identificador de la línea 1.
4. **Línea 4 (Calidades Phred codificadas):** Cadena de caracteres ASCII con **exactamente la misma longitud** que la secuencia de la Línea 2, donde cada carácter codifica la puntuación de calidad del nucleótido correspondiente en su misma posición.

El formato FASTQ define un registro estándar de cuatro líneas por lectura: cabecera con @, secuencia nucleotídica, separador + y cadena de calidades ASCII de idéntica longitud.

1.2.1 Arquitecturas de secuenciación: Single-End frente a Paired-End

- **Lecturas individuales (*Single-End*, SE):** El fragmento de ADN se secuencia en una única dirección, generando un único archivo `.fastq.gz` por muestra.
- **Lecturas emparejadas (*Paired-End*, PE):** El mismo fragmento de ADN se secuencia desde ambos extremos (5' y 3'), generando dos archivos coordinados: `_R1.fastq.gz` (lectura directa o *forward*) y `_R2.fastq.gz` (lectura reversa). El conocimiento de la distancia física esperada entre ambos extremos (*insert size*) facilita enormemente el mapeo en regiones repetitivas y la detección de reordenamientos cromosómicos.

La secuenciación Single-End produce un archivo FASTQ por muestra, mientras que la arquitectura Paired-End genera dos archivos complementarios R1 y R2 con lecturas forward y reverse.

1.3 La escala de calidad Phred (*Q* score) y codificación ASCII

La puntuación de calidad **Phred** (*Q*) fue desarrollada por Brent Ewing y Phil Green (1998) para cuantificar logarítmicamente la probabilidad de que una base nucleotídica haya sido llamada incorrectamente por el secuenciador:

$$Q = -10 \log_{10}(P_{\text{error}}) \iff P_{\text{error}} = 10^{-\frac{Q}{10}}$$

1.3.1 Niveles de calidad estándar e interpretación

Puntuación Phred (<i>Q</i>)	Probabilidad de error (P_{error})	Exactitud de la base	Significado biológico
$Q = 10$	1 en 10 (0.10)	90.0%	Calidad inaceptable / alto ruido
$Q = 20$	1 en 100 (0.01)	99.0%	Umbral mínimo aceptable de filtrado
$Q = 30$	1 en 1000 (0.001)	99.9%	Estándar de alta calidad en NGS
$Q = 40$	1 en 10000 (0.0001)	99.99%	Máxima fidelidad de secuenciación

La escala de calidad Phred define la probabilidad de error logarítmicamente como $Q = -10 \log_{10}(P_{\text{error}})$ y $P_{\text{error}} = 10^{-Q/10}$.

1.3.2 Codificación estándar Sanger Phred+33

Para almacenar puntuaciones numéricas $Q \in [0, 42]$ en un solo byte por base sin separadores en el archivo de texto, el estándar moderno (Sanger / Illumina 1.8+) desplaza el valor Phred sumándole un **desplazamiento (*offset*) de 33**, mapeando el número directamente sobre los caracteres imprimibles de la tabla ASCII (desde ! en ASCII 33 hasta J en ASCII 74):

$$Q = \text{ord}(\text{carácter}) - 33 \iff \text{carácter} = \text{chr}(Q + 33)$$

El estándar Sanger FASTQ codifica las puntuaciones Phred mediante un desplazamiento ASCII de 33 ($Q = \text{ord}(\text{char}) - 33$).

Ejemplo de decodificación Phred para el carácter ‘?’:

- Código ASCII de ‘?’: $\text{ord}('?') = 63$.
- Puntuación Phred: $Q = 63 - 33 = 30$.
- Probabilidad de error: $P_{\text{error}} = 10^{-30/10} = 10^{-3} = \mathbf{0.001000}$ (99.9% de exactitud).

El carácter de calidad ‘?’ (ASCII 63) evalúa a $Q = 30$ y una probabilidad de error $P_{\text{error}} = 0.001000$ (exactitud del 99.9%). Se reproduce con `verification/chapter_checks.py phred "?"`.

Parsing y calidad media de una lectura modelo: Dada la lectura de 8 bases con calidades `IIII????`:

- I (ASCII 73) $\implies Q = 73 - 33 = 40$ ($P_{\text{error}} = 0.0001$).
- ? (ASCII 63) $\implies Q = 63 - 33 = 30$ ($P_{\text{error}} = 0.0010$).
- Puntuaciones: `[40, 40, 40, 40, 30, 30, 30, 30]`.
- Calidad media aritmética: $\bar{Q} = \frac{4 \times 40 + 4 \times 30}{8} = \frac{160 + 120}{8} = \mathbf{35.00}$.
- Probabilidad media de error real: $\bar{P} = \frac{4 \times 0.0001 + 4 \times 0.0010}{8} = \frac{0.0004 + 0.0040}{8} = \mathbf{0.000550}$.

`parse_fastq_block` procesa la lectura modelo `@READ_01` con calidades `IIII????`, obteniendo una calidad media $\bar{Q} = 35.00$ y probabilidad media de error 0.000550. Se reproduce con `verification/chapter_checks.py parse_fastq -header "@READ_01" -seq "ATCGATCG" -plus "+" -qual "IIII????"`.

1.3.3 Validación defensiva de caracteres Phred

`decode_phred_string` lanza `ValueError` al detectar caracteres ASCII fuera de rango (< 33) como el espacio en blanco. Se reproduce con `verification/practice_checks.py domain_guard -char " "`.

1.4 Control de calidad con FastQC

La herramienta estándar para inspeccionar la calidad global de librerías FASTQ es **FastQC** (Andrews, 2010), que genera perfiles diagnósticos clave:

1. **Per base sequence quality:** Diagramas de caja (*boxplots*) que representan la distribución de Q posición a posición a lo largo del ciclo de secuenciación. En tecnología Illumina, es universal observar una **caída progresiva de calidad hacia el extremo 3'** debido a la acumulación de desfase de polimerasas y foto-degradación de fluoróforos.
2. **Per base sequence content:** Proporción relativa de A, C, G, T en cada posición. En RNA-seq es habitual un sesgo composicional en las primeras 10–12 bases debido al apareamiento preferencial de los **cebadores de hexámeros aleatorios** durante la retrotranscripción.
3. **Adapter Content:** Detección de secuencias de adaptadores sintéticos cuando el fragmento biológico de ADN insertado es más corto que la longitud de lectura (*read-through*).
4. **Per sequence GC content:** Desviaciones bimodales respecto a la distribución normal teórica señalan posibles contaminaciones por micoplasmas o bacterias.

Los perfiles diagnósticos de FastQC capturan la degradación progresiva de calidad en el extremo 3', el sesgo de cebadores en el extremo 5' y la presencia de adaptadores.

1.5 Preprocesamiento y recorte de calidad (*Trimming*)

Para maximizar la tasa de alineamiento (*mapping rate*) y evitar llamadas erróneas de variantes, los datos FASTQ crudos deben preprocesarse mediante:

- **Recorte de adaptadores (*Adapter Clipping*):** Detección y eliminación de secuencias sintéticas de adaptadores en los extremos 3' de las lecturas.
- **Recorte por ventana deslizante (*Sliding-Window Trimming*):** Algoritmo popularizado por herramientas como *Trimmomatic* (Bolger et al., 2014). Escanea la lectura de 5' → 3' evaluando la calidad media en una ventana móvil de tamaño W (típicamente $W = 4$ pb). En cuanto la calidad media de la ventana cae por debajo de un umbral $Q_{\min}$ (típicamente 20.0), el extremo 3' restante se recorta y descarta.
- **Filtrado por longitud mínima (*Length Filtering*):** Si tras el recorte la longitud residual de la lectura es menor que un umbral mínimo de seguridad ($L < 36$ pb), la lectura completa se descarta por riesgo de mapeo espurio no específico en el genoma.

El recorte por ventana deslizante escanea la lectura con una ventana móvil de tamaño W y trunca el extremo 3' cuando la calidad media de la ventana desciende del umbral.

El recorte de adaptadores elimina oligonucleótidos sintéticos del extremo 3' cuando la longitud de lectura supera el tamaño del inserto biológico.

Caso computable de recorte por ventana deslizante: Dada la secuencia $S = \text{'ATCGATCGAT'}$ (10 pb) con calidades IIIIII!!!! ($Q = [40, 40, 40, 40, 40, 40, 0, 0, 0, 0]$), ventana $W = 4$ y $Q_{\min} = 20.0$:

- Ventana 0 (pos 0..3): $\bar{Q} = 40.0 \geq 20.0$.
- Ventana 1 (pos 1..4): $\bar{Q} = 40.0 \geq 20.0$.
- Ventana 2 (pos 2..5): $\bar{Q} = 40.0 \geq 20.0$.
- Ventana 3 (pos 3..6): $\bar{Q} = \frac{40+40+40+0}{4} = 30.0 \geq 20.0$.
- Ventana 4 (pos 4..7): $\bar{Q} = \frac{40+40+0+0}{4} = 20.0 \geq 20.0$.
- Ventana 5 (pos 5..8): $\bar{Q} = \frac{40+0+0+0}{4} = 10.0 < 20.0 \implies$ **Corte en posición 5.**
- Secuencia recortada resultante: $S' = \text{ATCGA}$ (longitud residual 5 pb).

`sliding_window_trim` sobre `ATCGATCGAT` con calidades `IIIIII!!!!` ($W = 4, Q_{\min} = 20.0$) corta en la posición 5 generando la secuencia recortada `ATCGA` de longitud 5. Se reproduce con `verification/chapter_checks.py trim -seq "ATCGATCGAT" -qual "IIIIII!!!!" -window 4 -min_qual 20.0`.

1.6 Genomas de referencia y sistemas de coordenadas

Las lecturas procesadas se sitúan computacionalmente alineándolas contra un **genoma de referencia** almacenado en formato **FASTA**:

- Cabecera con `>` seguida del nombre del cromosoma (p. ej., `>chr1`, `>NC_000913.3`).
- Secuencia continua de nucleótidos en líneas sucesivas.

Los genomas de referencia se almacenan en formato FASTA conteniendo cabeceras de identificación de cromosomas y secuencias nucleotídicas continuas.

1.6.1 Sistemas de coordenadas en genómica computacional

- **Sistema 1-based cerrado** $[a, b]$: La primera base del cromosoma es la posición 1 y el intervalo incluye ambos extremos. Empleado en formatos **SAM**, **VCF** y **GFF**.
- **Sistema 0-based semiabierto** $[a, b)$: La primera base es la posición 0 y el extremo superior b no está incluido. La longitud del segmento es simplemente $b - a$. Empleado en formatos **BED**, **BAM index** y **Python**.

Los sistemas de coordenadas genómicas diferencian los intervalos cerrados 1-based (GFF, VCF, SAM) de los intervalos semiabiertos 0-based (BED y Python).

1.7 Diseño computacional en Python

Presentamos las funciones de decodificación Phred y parsing FASTQ:

Listing 1.1: Modulo de decodificacion Phred y parsing FASTQ en Python.

```
def decode_phred(qual_string: str, offset: int = 33) -> list[int]:
    return [ord(c) - offset for c in qual_string]

def parse_fastq_record(lines: list[str]) -> tuple[str, str, list[int]]:
    if len(lines) != 4 or not lines[0].startswith("@") or not lines[2].startswith("+"):
        raise ValueError("Formato FASTQ invalido")
    seq = lines[1].strip()
    qual = lines[3].strip()
    if len(seq) != len(qual):
        raise ValueError("Longitudes discordantes entre secuencia y calidades")
    return lines[0].strip(), seq, decode_phred(qual)
```

1.8 Peligros computacionales en preprocesamiento

1. **Confusión de offset Phred (Phred+33 vs histórico Phred+64)**: Procesar un archivo codificado en el formato histórico Illumina 1.3–1.7 (offset 64) asumiendo offset 33 produce puntuaciones Phred artificialmente infladas en 31 unidades, impidiendo cualquier filtrado de calidad.
2. **Cálculo directo de la media aritmética de puntuaciones Q** : Promediar directamente los valores de Q subestima sistemáticamente la tasa real de error debido a la naturaleza exponencial/logarítmica de la escala. Una base con $Q = 10$ ($P = 0.1$) y tres bases con $Q = 40$ ($P = 0.0001$) tienen una media aritmética de $\bar{Q} = 32.5$, pero la probabilidad media de error es $\bar{P} \approx 0.025$ (equivalente a un $Q_{\text{real}} \approx 16$).

La confusión entre la codificación estándar Sanger Phred+33 y el formato histórico Illumina Phred+64 corrompe críticamente la evaluación de calidades.

El cálculo de la media aritmética simple de puntuaciones Phred subestima la tasa real de error secuenciador debido a la transformación no lineal logarítmica.

1.9 Actividad de depuración: 3 errores en procesamiento FASTQ

Localice los tres errores en la siguiente función:

Listing 1.2: Funcion con 3 errores de logica en FASTQ y Phred.

```
def process_fastq_read(lines):
    # Error 1: asume offset 64 en lugar del estandar Sanger offset 33
    scores = [ord(c) - 64 for c in lines[3].strip()]
    # Error 2: no valida que len(seq) == len(qual)
    # Error 3: calcula probabilidad de error como 10^(Q/10) en vez de 10^(-Q/10)
    p_err = [10.0 ** (q / 10.0) for q in scores]
    return scores, p_err
```

1.10 Síntesis operativa y tablas de diagnóstico

1.10.1 Tabla de diagnóstico de problemas de calidad FASTQ

Síntoma observado	Causa probable	Comprobación y corrección
Calidades con caracteres ASCII inverosímiles (g, h, i)	El archivo utiliza codificación histórica Phred+64	Convertir calidades aplicando sustracción de 64 y sumando 33
Caída abrupta de calidad en los últimos 20 pb de todas las lecturas	Decaimiento natural de la química de secuenciación Illumina	Aplicar recorte por ventana deslizante (<code>sliding_window_trim</code>)
Alerta de sobre-representación de secuencias idénticas en FastQC	Dímeros de adaptadores o duplicación excesiva por PCR	Recortar adaptadores y filtrar duplicados ópticos/PCR
ValueError de longitud discordante	Fichero FASTQ truncado por descarga incompleta	Verificar suma de comprobación MD5 / sha256 del fichero crudo

1.10.2 Tabla de síntesis: equivalencias de escala Phred

Carácter	Código ASCII	Puntuación Phred (Q)	Probabilidad de error (P_{error})
!	33	$Q = 0$	1.000000 (100% de error)
+	43	$Q = 10$	0.100000 (10% de error)
5	53	$Q = 20$	0.010000 (1% de error)
?	63	$Q = 30$	0.001000 (0.1% de error)
I	73	$Q = 40$	0.000100 (0.01% de error)

1.11 Glosario conceptual

- **FASTQ:** formato de 4 líneas que combina secuencia y calidad.
- **Phred (Q):** puntuación logarítmica de confianza de llamada.
- **Offset +33:** desplazamiento ASCII del estándar Sanger FASTQ.
- **Single-End:** secuenciación unidireccional de fragmentos.
- **Paired-End:** secuenciación bidireccional coordinada R1 y R2.
- **FastQC:** suite diagnóstica de control de calidad de lecturas.
- **Trimming:** recorte bioinformático de adaptadores y baja calidad.

- **Ventana deslizante:** algoritmo de corte por calidad media local.
- **FASTA:** formato estándar para secuencias y genomas de referencia.
- **Coordenadas 1-based:** sistema cerrado indexado desde 1 (SAM, VCF).

1.12 Cierre y conexiones hacia adelante

Este capítulo completa el preprocesamiento de datos crudos de secuenciación, preparando lecturas limpias y filtradas para su alineamiento y mapeo contra genomas de referencia en BC-CH08.

En el siguiente capítulo (**BC-CH08: Alineamiento contra genoma de referencia y mapeo NGS**), estudiaremos los algoritmos de indexación Burrows-Wheeler (BWA) y los formatos SAM/BAM para posicionar millones de lecturas sobre el genoma.

1.13 Fuentes y reproducibilidad

Este capítulo se fundamenta en las diapositivas docentes (20251006_seq (2).pdf, Álvaro Serrano Navarro), en la especificación Sanger FASTQ (Cock et al., 2010), en la escala Phred (Ewing & Green, 1998) y en Trimmomatic (Bolger et al., 2014). Todos los cálculos se reproducen mediante `verification/chapter_checks.py`.

Anexo práctico · Formato FASTQ, decodificación Phred y filtrado por ventana deslizante

Pregunta, producto y separación de materiales

¿Puede implementar un módulo en Python que parsee registros FASTQ de cuatro líneas, convierta caracteres ASCII a puntuaciones de calidad Phred (Q) y probabilidades de error, y ejecute un algoritmo de recorte por ventana deslizante sin recurrir a paquetes externos opacos? Este laboratorio responde afirmativamente de forma totalmente determinista y reproducible.

El producto individual contiene: la decodificación Phred base, el parsing de registros FASTQ, el algoritmo de recorte por ventana deslizante, la perturbación con calidad $Q=20$, el control de excepciones de la guarda de dominio y la defensa conceptual escrita.

El anexo es autónomo e independiente: no requiere paquetes externos. Emplea `verification/practice_checks` como oráculo determinista.

Mapa de ruta, tiempos y dedicación

Bloque de trabajo	Minutos	Producto entregable
1 · Entorno y diagnóstico	5	Comprobación del intérprete Python 3.9
2 · Cálculo ancla (Phred, FASTQ, Trimming)	20–25	Decodificación $Q=30$, parsing FASTQ y corte
3 · Perturbación a $Q=20$	15–20	Recálculo de probabilidad de error ($P = 0.01$)
4 · Guarda de dominio	10–15	Captura de <code>ValueError</code> ante <code>ASCII < 33</code>
5 · Preguntas de control	5–10	Preguntas sobre offsets y promediado de Q
6 · Verificación y empaquetado	5	Comprobación final y empaquetado

La ruta de este anexo suma 75–100 minutos y produce evidencia comprobable y verificable en cada bloque de trabajo sin paquetes externos.

1 · Entorno y diagnóstico

Verifique que su entorno dispone de Python 3.9 o superior:

Listing 1.3: Comprobacion de interprete y oraculo.

```
python3 --version
python3 verification/practice_checks.py --help
```

2 · Cálculo ancla: decodificación Phred, parsing FASTQ y trimming

Dado el carácter de calidad ‘?’ y la lectura modelo @READ_01 con calidades IIII????:

1. Convierta el carácter ‘?’ a Phred+33: $\text{ord}('?') - 33 = 63 - 33 = \mathbf{30}$ ($P_{\text{error}} = \mathbf{0.001000}$).
2. Parsee la lectura de 8 bases con calidades IIII????: puntuaciones [40, 40, 40, 40, 30, 30, 30, 30] y calidad media $\bar{Q} = \mathbf{35.00}$.
3. Aplique recorte por ventana deslizante ($W = 4, Q_{\min} = 20.0$) sobre ATCGATCGAT con calidades IIIIII!!!!: corta en la posición 5 produciendo la secuencia ATCGA de longitud 5.

Listing 1.4: Ejecucion del calculo ancla.

```
python3 verification/practice_checks.py anchor
```

El modelo ancla valida la conversion del caracter ? a Q=30, el parsing de @READ_01 con calidad media 35.00 y el recorte por ventana deslizante a longitud 5. Se reproduce con `verification/practice_checks.py anchor`.

3 · Perturbación a calidad Q=20

Evalúe la decodificación del carácter ‘5’ (ASCII 53):

Listing 1.5: Perturbacion con caracter de calidad 5.

```
python3 verification/practice_checks.py perturbation
```

La perturbacion con el caracter 5 evalua a una puntuacion Phred $Q = 20$ y una probabilidad de error de 0.010000. Se reproduce con `verification/practice_checks.py perturbation`.

4 · Guarda de dominio y control de excepciones

Compruebe que el decodificador rechaza caracteres fuera del rango imprimible estándar (< 33):

Listing 1.6: Guarda de dominio ante caracter ASCII invalido.

```
python3 verification/practice_checks.py domain_guard --char " "
```

La guarda de dominio rechaza caracteres de calidad fuera de rango lanzando un `ValueError` que identifica el caracter invalido. Se reproduce con `verification/practice_checks.py domain_guard -char " "`.

5 · Verificación y entrega

La verificación de entrega confirma la ejecución autónoma bajo el intérprete estándar de Python 3.9 sin librerías externas opacas.

Rúbrica de calificación ponderada

La evaluación sobre 10 puntos se pondera según:

- **4.0 puntos (40%):** Ejecución correcta y reproducible de los scripts de comprobación (`chapter_checks.py` y `practice_checks.py`).
- **2.0 puntos (20%):** Implementación del parser FASTQ de cuatro líneas y cálculo exacto de la calidad media $\bar{Q} = 35.00$ (Bloque 2).
- **2.0 puntos (20%):** Algoritmo de recorte por ventana deslizante ($W = 4, Q_{\min} = 20.0$) y control de excepciones de la guarda de dominio (Bloques 3 y 4).
- **2.0 puntos (20%):** Defensa conceptual escrita (100–150 palabras) sobre el significado de la escala Phred, el impacto de promediar directamente puntuaciones Q y la caída de calidad en 3'.

Lista de autocorrección

- Verifiqué que mi versión de Python es ≥ 3.9 .
- El carácter '?' decodificó a $Q = 30$.
- La calidad media de la lectura fue $\bar{Q} = 35.00$.
- La secuencia recortada fue **ATCGA** (5 pb).
- El carácter '5' decodificó a $Q = 20$ ($P = 0.01$).
- Verifiqué que el espacio en blanco lanza `ValueError`.
- Comprobé que el archivo FASTQ tiene 4 líneas por registro.
- Redacté la defensa conceptual individual.

Defensa conceptual

En 100–150 palabras, explique por qué promediar aritméticamente puntuaciones Phred subestima la tasa de error global de una lectura frente al promedio de probabilidades reales $10^{-Q/10}$, y describa el mecanismo físico y químico responsable de la pérdida de calidad hacia el extremo 3' en secuenciación Illumina.

Fuentes y reproducibilidad

Este anexo se fundamenta en las diapositivas de FASTQ y calidad (`20251006_seq (2).pdf`), en Cock et al. (2010), Ewing & Green (1998) y Bolger et al. (2014), y se valida al 100% mediante `verification/practice_checks.py`.