

Contents

1	Mapeo de lecturas y flujos NGS	1
1.1	El problema de la escala en el mapeo de lecturas	1
1.2	Estrategias de indexación y algoritmos de mapeo	1
1.2.1	Indexación basada en tablas de dispersión (<i>Hash Tables</i>) y <i>k</i> -mers . . .	1
1.2.2	Validación defensiva de la longitud de semilla	2
1.2.3	Indexación por Transformada de Burrows-Wheeler (BWT) y FM-Index .	2
1.3	El formato SAM/BAM y la calidad de mapeo MAPQ	3
1.3.1	Los 11 campos tabulares obligatorios del formato SAM	3
1.3.2	Cadenas CIGAR (<i>Compact Idiosyncratic Gapped Alignment Report</i>) . .	3
1.3.3	Puntuación de calidad de mapeo (MAPQ) y lecturas multimapeadas . .	4
1.4	Flujos de trabajo NGS de extremo a extremo y alineamiento transcriptómico .	4
1.4.1	Alineamiento de transcriptómica (RNA-seq con empalme / <i>Spliced Alignment</i>)	5
1.5	Diseño computacional en Python	5
1.6	Peligros computacionales en alineamiento y mapeo	5
1.7	Actividad de depuración: 3 errores en flujo de mapeo	5
1.8	Síntesis operativa y tablas de diagnóstico	6
1.8.1	Tabla de diagnóstico de fallos en flujos de mapeo NGS	6
1.8.2	Tabla comparativa de alineadores de lecturas NGS	6
1.9	Glosario conceptual	6
1.10	Cierre de la Parte II y transición conceptual hacia BC-CH09	7
1.11	Fuentes y reproducibilidad	7
	Anexo práctico · Indexado de genomas, algoritmo Seed-and-Extend y parsing CIGAR	9

Chapter 1

Maapeo de lecturas y flujos NGS

1.1 El problema de la escala en el mapeo de lecturas

Con este capítulo cerramos la **Parte II (Producir, procesar y situar datos de secuencia)**. Esencial
Tras haber estudiado las tecnologías de secuenciación (BC-CH06) y el control de calidad de archivos FASTQ (BC-CH07), enfrentamos el núcleo computacional de la genómica moderna: **¿cómo posicionar de forma rápida, exacta y reproducible cientos de millones de lecturas cortas sobre un genoma de referencia de miles de millones de pares de bases?**

En el capítulo TC-CH09 estudiamos los algoritmos de programación dinámica exacta (Needleman–Wunsch y Smith–Waterman), cuya complejidad temporal es cuadrática: $\mathcal{O}(N \times M)$, donde N es la longitud de la lectura y M el tamaño del genoma. Si intentáramos alinear una corrida estándar de Illumina con 10^9 lecturas ($N \approx 150$ pb) frente al genoma humano ($M \approx 3.2 \times 10^9$ pb), el alineamiento requeriría del orden de 10^{19} operaciones elementales, lo que exigiría décadas de cómputo continuo.

Para superar este cuello de botella intratable, los alineadores de lecturas cortas (*Short Read Aligners*, SRA) aplican el paradigma "**Indexar una vez, consultar millones de veces**": el genoma de referencia se preprocesa e indexa en una estructura de datos optimizada en memoria RAM, permitiendo localizar cada lectura en fracciones de milisegundo mediante algoritmos heurísticos.

La ruta **esencial** cubre la formulación del problema de mapeo, las estrategias de indexación por tablas de k -mers (*Seed-and-Extend*) y Transformada de Burrows-Wheeler (BWT/FM-index), la estructura del formato SAM/BAM, las operaciones CIGAR y la calidad de mapeo MAPQ; 120–140 minutos. La ruta de **estudio** profundiza en alineamiento transcriptómico con empalme (*spliced alignment*), flujos de trabajo GATK de extremo a extremo, actividad de depuración y el anexo práctico; 60–80 minutos adicionales. Esencial

El mapeo de lecturas cortas resuelve el posicionamiento masivo de millones de lecturas sobre genomas gigantescos mediante estructuras indexadas precomputadas en memoria en lugar de programación dinámica exhaustiva.

1.2 Estrategias de indexación y algoritmos de mapeo

1.2.1 Indexación basada en tablas de dispersión (*Hash Tables*) y k -mers

La estrategia clásica de indexación por dispersión (*Hash-based mapping*, empleada históricamente por herramientas como MAQ, MOSAIK o Novoalign) divide el genoma de referencia en palabras de longitud fija denominadas **k -mers** y construye una tabla de búsqueda que asocia cada k -mer con la lista de todas sus posiciones cromosómicas:

Algoritmo *Seed-and-Extend*:

1. **Fase de siembra (*Seeding*):** Se extrae un k -mer inicial de la lectura (*query*) como semilla y se consulta instantáneamente en la tabla hash para obtener las posiciones candidatas en el genoma.
2. **Fase de extensión (*Extension*):** En cada posición candidata, se extiende el alineamiento hacia ambos extremos comparando base a base y contabilizando discrepancias (*mismatches*) o pequeñas inserciones/deleciones (*indels*) hasta un umbral de tolerancia.

La indexación por tablas hash particiona el genoma en k -mers para permitir la estrategia Seed-and-Extend con tolerancia controlada a discrepancias.

Ejemplo computable de indexación k -mer y mapeo: Dado el genoma modelo $G = \text{'CATGGTCATTGGTTCC'}$ (16 pb) y tamaño de semilla $k = 3$:

- `build_kmer_index` genera 11 k -mers únicos.
- El k -mer CAT aparece en las posiciones 1-based $[1, 7]$ (coordenadas 0-based $[0, 6]$).
- El k -mer TGG aparece en las posiciones 1-based $[3, 10]$.

`build_kmer_index` sobre el genoma modelo de 16 pb con $k = 3$ produce 11 k -mers únicos, situando CAT en $[1, 7]$ y TGG en $[3, 10]$. Se reproduce con `verification/chapter_checks.py index_kmers -genome "CATGGTCATTGGTTCC" -k 3`.

Mapeo de la lectura TGGTCA:

- Semilla $k = 3$: TGG $\implies$ Posiciones candidatas en genoma: 3 y 10.
- En posición 3: la diana genómica es TGGTCA $\implies$ 0 discrepancias $\implies$ **Mapeo exacto** con CIGAR 6M.
- En posición 10: la diana genómica es TGGTTCC ... $\implies$ 2 discrepancias (TGGTTC vs TGGTCA).

`seed_and_extend_map` mapea la lectura TGGTCA en la posición 3 del genoma modelo con 0 discrepancias y CIGAR 6M. Se reproduce con `verification/chapter_checks.py map_read -query "TGGTCA" -genome "CATGGTCATTGGTTCC" -k 3 -max_mismatches 1`.

1.2.2 Validación defensiva de la longitud de semilla

`seed_and_extend_map` lanza `ValueError` cuando la longitud de la lectura es menor que el tamaño de semilla k . Se reproduce con `verification/practice_checks.py domain_guard -query "TG" -k 3`.

1.2.3 Indexación por Transformada de Burrows-Wheeler (BWT) y FM-Index

Para genomas eucariotas grandes (como el genoma humano de 3.2 Gb), las tablas hash requieren decenas de gigabytes de memoria RAM. Los alineadores modernos más utilizados en ADN genómico (**BWA-MEM**, Li & Durbin 2009; **Bowtie 2**, Langmead & Salzberg 2012) emplean la **Transformada de Burrows-Wheeler (BWT)** complementada con el índice de Ferragina-Manzini (**FM-index**):

1. **Compresión en memoria:** La BWT reordena los caracteres del genoma según el orden lexicográfico de sus sufijos, agrupando repeticiones de bases idénticas. Esto permite comprimir el genoma humano completo en **menos de 4 GB de RAM**, haciéndolo ejecutable en cualquier ordenador portátil moderno.
2. **Búsqueda exacta hacia atrás (*Backward Search*):** Permite determinar el número de ocurrencias y el intervalo de posiciones de cualquier secuencia patrón en tiempo proporcional a su longitud $\mathcal{O}(L)$, **independientemente del tamaño del genoma G .**

La Transformada de Burrows-Wheeler (BWT) y el FM-index comprimen el genoma de referencia en RAM permitiendo búsquedas hacia atrás en tiempo $\mathcal{O}(L)$ independiente del tamaño genómico.

1.3 El formato SAM/BAM y la calidad de mapeo MAPQ

El resultado del alineamiento se estandariza en el formato tabular **SAM** (*Sequence Alignment/Map*, Li et al., 2009) y su versión binaria comprimida e indexada **BAM** (o **CRAM**, con compresión basada en referencia).

1.3.1 Los 11 campos tabulares obligatorios del formato SAM

Cada línea de alineamiento contiene 11 campos separados por tabuladores:

Columna	Campo	Descripción y significado
1	QNAME	Identificador de la lectura (procedente del FASTQ).
2	FLAG	Bandera bit a bit con propiedades del alineamiento (par mapeado, orientación, etc.).
3	RNAME	Nombre del cromosoma o contig de referencia (chr1, chrX).
4	POS	Posición 1-based de la base más a la izquierda del alineamiento.
5	MAPQ	Calidad de mapeo Phred (0–60).
6	CIGAR	Cadena de operaciones de alineamiento (matches, inserciones, deleciones).
7	RNEXT	Nombre del cromosoma del par (= si es el mismo).
8	PNEXT	Posición 1-based del par emparejado (<i>mate</i>).
9	TLEN	Longitud del inserto biológico inferido (<i>template length</i>).
10	SEQ	Secuencia nucleotídica de la lectura.
11	QUAL	Calidades Phred codificadas en ASCII (de la Línea 4 del FASTQ).

El formato SAM estandariza 11 campos tabulares obligatorios por alineamiento (QNAME, FLAG, RNAME, POS, MAPQ, CIGAR, RNEXT, PNEXT, TLEN, SEQ, QUAL).

1.3.2 Cadenas CIGAR (*Compact Idiosyncratic Gapped Alignment Report*)

La cadena CIGAR codifica cómo se transforma la lectura para alinearse con la referencia:

- M: Alineamiento (coincidencia *match* o discrepancia *mismatch*).
- I: Inserción en la lectura respecto a la referencia (consume bases de query).
- D: Delección en la lectura respecto a la referencia (consume bases de referencia).
- S: *Soft-clipping* (bases no alineadas en los extremos pero conservadas en el registro).
- N: Salto de intrón en transcritos de ARN (consume referencia).

Ejemplo de parsing CIGAR para 10M2I38M:

- Bases consumidas de la lectura query: $10 + 2 + 38 = 50$ pb.
- Bases consumidas de la referencia: $10 + 38 = 48$ pb (la inserción no consume referencia).

`parse_cigar` procesa la cadena 10M2I38M evaluando la longitud consumida en la query a 50 pb y en la referencia a 48 pb. Se reproduce con `verification/chapter_checks.py cigar "10M2I38M"`.

1.3.3 Puntuación de calidad de mapeo (MAPQ) y lecturas multimapeadas

La puntuación **MAPQ** cuantifica en escala logarítmica Phred la probabilidad de que la posición asignada a la lectura sea errónea:

$$\text{MAPQ} = -10 \log_{10}(P_{\text{mapeo erróneo}})$$

- $\text{MAPQ} = 60.0 \implies P = 10^{-6} = 0.000001$ (alineamiento único de máxima certeza).
- $\text{MAPQ} = 0 \implies P = 1.0$ (**lectura multimapeada**): la lectura alinea con igual puntuación en múltiples regiones idénticas del genoma (p. ej., transposones o duplicaciones segmentales), por lo que su posición precisa es ambigua.

La calidad de mapeo MAPQ mide la probabilidad de error logarítmicamente, evaluando $\text{MAPQ} = 60.0$ exactamente a una probabilidad de error de 0.000001. Se reproduce con `verification/chapter_checks.py mapq 60.0`.

Las lecturas multimapeadas que alinean en múltiples loci reciben calidades de mapeo nulas ($\text{MAPQ} = 0$) para prevenir llamadas espurias de variantes.

1.4 Flujos de trabajo NGS de extremo a extremo y alineamiento transcriptómico

Un flujo bioinformático de genómica traslacional (siguiendo las *GATK Best Practices*, DePristo et al., 2011) encadena las siguientes etapas:

1. **Control y limpieza FASTQ:** FastQC y Trimmomatic (BC-CH07).
2. **Alineamiento genómico:** BWA-MEM sobre referencia indexada $\rightarrow$ archivo SAM.
3. **Conversión, ordenado e indexado:** `samtools view -bS`, `samtools sort` y `samtools index` $\rightarrow$ archivo `sample.sorted.bam` con índice `.bai`.
4. **Marcaje de duplicados por PCR (*MarkDuplicates*):** Identificación de lecturas con idénticas coordenadas 5' de inicio de fragmento generadas por amplificación clonal en PCR para evitar falsos sesgos alélicos.
5. **Recalibración de calidades de bases (BQSR):** Corrección empírica de puntuaciones Phred sistemáticamente sesgadas por la química del secuenciador.
6. **Llamada de variantes (*Variant Calling*):** GATK HaplotypeCaller $\rightarrow$ archivo VCF (BC-CH03).

Los flujos NGS de extremo a extremo encadenan control FASTQ, alineamiento BWA-MEM, ordenado BAM, marcaje de duplicados por PCR, recalibración BQSR y llamada de variantes.

El marcaje de duplicados por PCR identifica lecturas con coordenadas 5' idénticas para eliminar artefactos de amplificación clonal.

1.4.1 Alineamiento de transcriptómica (RNA-seq con empalme / *Spliced Alignment*)

En ARN mensajero maduro, los intrones han sido eliminados por *splicing* (BC-CH04). Una lectura de 150 pb que solapa una unión exón-exón no puede mapearse con alineadores continuos de ADN como BWA-MEM (que penalizarían un gap de 10 kb con un coste prohibitivo). Por ello, el análisis de RNA-seq exige **alineadores con empalme** (**STAR**, Dobin et al., 2013; **HISAT2**, Kim et al., 2019), capaces de detectar uniones intrónicas y anotar operaciones N en el CIGAR.

El mapeo de transcriptómica (RNA-seq) exige alineadores con empalme (STAR, HISAT2) capaces de saltar uniones intrónicas kilobásicas.

1.5 Diseño computacional en Python

Presentamos un prototipo de indexación y mapeo Seed-and-Extend:

Listing 1.1: Prototipo de indexado k-mer y Seed-and-Extend en Python.

```
def build_index(genome: str, k: int = 3) -> dict[str, list[int]]:
    index = {}
    for i in range(len(genome) - k + 1):
        kmer = genome[i:i+k]
        index.setdefault(kmer, []).append(i)
    return index

def map_query(query: str, genome: str, k: int = 3) -> list[int]:
    idx = build_index(genome, k)
    seed = query[:k]
    hits = idx.get(seed, [])
    valid_pos = []
    for pos in hits:
        if genome[pos:pos+len(query)] == query:
            valid_pos.append(pos + 1) # Coordinada 1-based
    return valid_pos
```

1.6 Peligros computacionales en alineamiento y mapeo

1. **Confusión entre sistemas de coordenadas (1-based vs 0-based):** Formatos como SAM, VCF y GFF son 1-based cerrados, mientras que BED y los rangos de corte en Python son 0-based semiabiertos. Mezclar índices sin traslación introduce un desfase sistemático de 1 base (*off-by-one error*) que arruina la anotación de mutaciones.
2. **Uso de alineadores de ADN en experimentos de RNA-seq:** Mapear lecturas de ARN maduro con BWA-MEM descarta masivamente todas las lecturas de unión exón-exón, falseando la cuantificación de expresión génica.

El empleo de alineadores de ADN no preparados para empalme en datos de ARN y la confusión de coordenadas 1-based frente a 0-based constituyen errores críticos de análisis NGS.

1.7 Actividad de depuración: 3 errores en flujo de mapeo

Localice los tres errores en la siguiente función:

Listing 1.2: Funcion con 3 errores de logica en mapeo NGS.

```
def parse_sam_record(fields):
    # Error 1: no valida que SAM tenga al menos 11 campos
    qname, flag, rname, pos, mapq, cigar = fields[:6]
    # Error 2: no convierte la posicion y MAPQ a enteros
    # Error 3: calcula probabilidad de error como 10^(MAPQ/10) sin signo negativo
    p_err = 10.0 ** (float(mapq) / 10.0)
    return qname, int(pos), p_err
```

1.8 Síntesis operativa y tablas de diagnóstico

1.8.1 Tabla de diagnóstico de fallos en flujos de mapeo NGS

Síntoma observado	Causa probable	Comprobación y corrección
Tasa de mapeo anormalmente baja (< 50%) en RNA-seq	Uso de alineador continuo (BWA) en lugar de alineador con empalme	Reemplazar por STAR o HISAT2
Porcentaje muy alto de lecturas con MAPQ = 0	Secuenciación en regiones de alta duplicación o lecturas muy cortas	Usar lecturas más largas o paired-end con mayor resolución
Frecuencias alélicas infladas al 100% en múltiples variantes	No se ejecutó el paso de marcado de duplicados por PCR	Incluir <code>MarkDuplicates</code> de Picard/GATK antes de llamar variantes
Error al consultar el archivo BAM con IGV / Samtools	Falta el fichero de índice .bai asociado	Generar índice mediante <code>samtools index sample.sorted.bam</code>

1.8.2 Tabla comparativa de alineadores de lecturas NGS

Alineador	Algoritmo base	Tipo de datos	Aplicación diana
BWA-MEM	BWT / FM-index	ADN genómico	WGS, WES, variantes germinales/somáticas
Bowtie 2	BWT / FM-index	ADN genómico	ChIP-seq, ATAC-seq, metagenómica
STAR	Sufijos no comprimidos	ARN maduro	RNA-seq diferencial, detección de fusiones
HISAT2	BWT jerárquico	ARN maduro	RNA-seq con bajo consumo de memoria

1.9 Glosario conceptual

- **Mapeo:** localización espacial de lecturas en una referencia.
- **k-mer:** subsecuencia de longitud fija k .
- **Seed-and-Extend:** búsqueda de semilla exacta y extensión.
- **BWT:** Transformada reversible de Burrows-Wheeler.
- **FM-index:** índice de texto comprimido

para búsqueda rápida.

- **SAM:** formato tabular de alineamiento de secuencias.
- **BAM:** formato binario comprimido de SAM indexable.
- **CIGAR:** descriptor compacto de operaciones de alineamiento.
- **MAPQ:** calidad de mapeo en escala logarítmica Phred.
- ***Spliced alignment:*** alineamiento tolerante a intrones.

1.10 Cierre de la Parte II y transición conceptual hacia BC-CH09

Este capítulo cierra la Parte II completando la trilogía tecnológica y computacional de tecnologías de secuenciación, control de calidad y mapeo sobre genomas de referencia.

Localizar observaciones sobre un genoma de referencia no basta para comparar posiciones homólogas ni inferir historia evolutiva, estableciendo la transición conceptual indispensable hacia el estudio de filogenia y evolución molecular en BC-CH09.

El mapeo proyecta observaciones experimentales individuales sobre una plantilla estática. Sin embargo, para reconstruir las relaciones de parentesco entre especies, identificar presiones selectivas y descifrar la historia de los linajes biológicos, es indispensable formular modelos evolutivos explícitos de sustitución nucleotídica y matrices de distancias genéticas. Esta transición abre la **Parte III: Evolución, filogenia y modelado de sistemas** en el siguiente capítulo (BC-CH09: De secuencias homólogas a hipótesis evolutivas).

1.11 Fuentes y reproducibilidad

Este capítulo se fundamenta en las diapositivas docentes (20251009_seq (2).pdf, Álvaro Serrano Navarro), en la especificación del formato SAM (Li et al., 2009), en el alineador BWA (Li & Durbin, 2009), en Bowtie 2 (Langmead & Salzberg, 2012) y en las buenas prácticas de GATK (DePristo et al., 2011). Todos los cálculos se reproducen mediante `verification/chapter_checks.py`.

Anexo práctico · Indexado de genomas, algoritmo Seed-and-Extend y parsing CIGAR

Pregunta, producto y separación de materiales

¿Puede implementar un módulo en Python que indexe un genoma de referencia mediante tablas de k -mers, ejecute el algoritmo heurístico de mapeo *Seed-and-Extend*, parsee cadenas descriptivas CIGAR y evalúe la calidad de mapeo MAPQ sin recurrir a paquetes externos opacos? Este laboratorio responde afirmativamente de forma totalmente determinista y reproducible.

El producto individual contiene: la indexación de k -mers del genoma modelo, el mapeo de lecturas Seed-and-Extend, el parsing de descriptores CIGAR, la conversión logarítmica de MAPQ, la perturbación con discrepancia, el control de excepciones de la guarda de dominio y la defensa conceptual escrita.

El anexo es autónomo e independiente: no requiere paquetes externos. Emplea `verification/practice_checks` como oráculo determinista.

Mapa de ruta, tiempos y dedicación

Bloque de trabajo	Minutos	Producto entregable
1 · Entorno y diagnóstico	5	Comprobación del intérprete Python 3.9
2 · Cálculo ancla (Indexado, Mapeo, CIGAR, MAPQ)	20–25	Indexación 11 kmers, mapeo 6M, CIGAR y MAPQ
3 · Perturbación con discrepancia	15–20	Mapeo con 1 mismatch en posición 3
4 · Guarda de dominio	10–15	Captura de <code>ValueError</code> ante query $< k$
5 · Preguntas de control de flujos NGS	5–10	Preguntas sobre SAM, MAPQ y RNA-seq
6 · Verificación y empaquetado	5	Comprobación final y empaquetado

La ruta de este anexo suma 75–100 minutos y produce evidencia comprobable y verificable en cada bloque de trabajo sin paquetes externos.

1 · Entorno y diagnóstico

Verifique que su entorno dispone de Python 3.9 o superior:

Listing 1.3: Comprobacion de interprete y oraculo.

```
python3 --version
python3 verification/practice_checks.py --help
```

2 · Cálculo ancla: indexado k-mer, mapeo, CIGAR y MAPQ

Dado el genoma modelo $G = \text{'CATGGTCATTGGTTCC'}$ (16 pb) y la lectura $Q = \text{'TGGTCA'}$:

1. Construya el índice de k -mers con $k = 3$: genera 11 k -mers únicos, situando CAT en [1, 7] y TGG en [3, 10].
2. Mapee la lectura TGGTCA mediante *Seed-and-Extend*: identifica alineamiento exacto en posición 3 con 0 discrepancias y CIGAR 6M.
3. Parsee la cadena CIGAR 10M2I38M: evalúa longitud consumida en query a 50 pb y en referencia a 48 pb.
4. Convierta la puntuación MAPQ = 60.0: evalúa probabilidad de error de mapeo $P = 0.000001$.

Listing 1.4: Ejecucion del calculo ancla.

```
python3 verification/practice_checks.py anchor
```

El modelo ancla valida el indexado de 11 kmers, el mapeo exacto de TGGTCA en la posicion 3 con CIGAR 6M, el parsing de 10M2I38M (50/48) y la conversion de MAPQ 60.0 a probabilidad 0.000001. Se reproduce con `verification/practice_checks.py anchor`.

3 · Perturbación: lectura con discrepancia (*Mismatch*)

Mapee la lectura perturbada TGGTCT permitiendo hasta 1 discrepancia:

Listing 1.5: Mapeo de lectura con discrepancia.

```
python3 verification/practice_checks.py perturbation
```

La perturbacion con la lectura TGGTCT mapea en la posicion 3 con 1 discrepancia frente a la secuencia diana TGGTCA. Se reproduce con `verification/practice_checks.py perturbation`.

4 · Guarda de dominio y control de excepciones

Compruebe que el algoritmo rechaza lecturas cuya longitud sea estrictamente inferior al tamaño de semilla k :

Listing 1.6: Guarda de dominio ante query menor que k.

```
python3 verification/practice_checks.py domain_guard --query "TG" --k 3
```

La guarda de dominio rechaza lecturas con longitud menor que k lanzando un `ValueError` que identifica la dimension insuficiente. Se reproduce con `verification/practice_checks.py domain_guard -query "TG" -k 3`.

5 · Verificación y entrega

La verificación de entrega confirma la ejecución autónoma bajo el intérprete estándar de Python 3.9 sin librerías externas opacas.

Rúbrica de calificación ponderada

La evaluación sobre 10 puntos se pondera según:

- **4.0 puntos (40%):** Ejecución correcta y reproducible de los scripts de comprobación (`chapter_checks.py` y `practice_checks.py`).
- **2.0 puntos (20%):** Implementación del generador de índice k -mer y algoritmo *Seed-and-Extend* (Bloque 2).
- **2.0 puntos (20%):** Parser de operaciones CIGAR, cálculo de MAPQ y control de excepciones en la guarda de dominio (Bloques 3 y 4).
- **2.0 puntos (20%):** Defensa conceptual escrita (100–150 palabras) sobre por qué la indexación BWT/FM-index supera a las tablas hash en genomas grandes y el papel de los alineadores con empalme en RNA-seq.

Lista de autocorrección

- Verifiqué que mi versión de Python es ≥ 3.9 .
- El índice de 16 pb generó 11 k -mers únicos.
- TGGTCA mapeó exactamente en posición 3.
- CIGAR 10M2I38M arrojó 50 pb en query
- y 48 pb en referencia.
- MAPQ = 60.0 evaluó a $P = 0.000001$.
- TGGTCT mapeó con 1 discrepancia.
- Verifiqué que query de 2 pb con $k = 3$ lanza `ValueError`.
- Redacté la defensa conceptual individual.

Defensa conceptual

En 100–150 palabras, justifique por qué la Transformada de Burrows-Wheeler (BWT) y el FM-index permiten mapear lecturas en tiempo $\mathcal{O}(L)$ independiente del tamaño del genoma G , y por qué localizar observaciones sobre una referencia no es equivalente a establecer homología evolutiva entre secuencias.

Fuentes y reproducibilidad

Este anexo se fundamenta en las diapositivas de mapeo y alineamiento (20251009_seq(2).pdf), en Li et al. (2009), Li & Durbin (2009) y Langmead & Salzberg (2012), y se valida al 100% mediante `verification/practice_checks.py`.