

Estructura tridimensional de proteínas: Métodos experimentales, formato PDB y validación cristalográfica

BC-CH11 – Biología Computacional

Edición 2 · 2026-09-03

Pregunta del tema. Una estructura de un banco de datos no es una observación directa: es un modelo ajustado a una medida indirecta. ¿Cómo se obtiene, qué se puede creer de ella y qué comprobaciones hay que hacer antes de usarla?

Producto final. Un procesador de ficheros de estructura escrito por usted que valide el formato línea a línea, extraiga las coordenadas y los factores de temperatura, y emita un informe de validación con las señales de alarma que el capítulo enumera.

Mapa del tema

1. La estructura macromolecular y la evidencia experimental	1
2. Técnicas biofísicas de determinación estructural	2
3. Formatos estructurales: Del PDB clásico al estándar mmCIF	2
4. Geometría tridimensional, RMSD y factores B	4
5. Validación estereoquímica y el diagrama de Ramachandran	5
6. Clasificación jerárquica de dominios: CATH y SCOP	6
7. Diseño computacional en Python: Procesador PDB y métricas	6
8. Peligros computacionales y actividad de depuración	7
9. Síntesis operativa y tablas de diagnóstico	7
10. Glosario conceptual	8
11. Conexiones y mapa del curso	8
12. Fuentes y reproducibilidad	8

Cómo usar este tema

Este capítulo trata la estructura como evidencia, no como dato. La diferencia importa: un fichero de coordenadas parece una medida y es una interpretación, ajustada a un mapa de densidad que a su vez viene de un patrón de difracción. Saber de dónde viene cada número es lo que permite decidir cuánto pesa.

Al terminar sabrá: distinguir las tres técnicas principales por lo que cada una puede y no puede resolver; leer una línea de un fichero de estructura sabiendo que sus campos van por posición y no por separador; interpretar un factor de temperatura y decir qué partes de un modelo son fiables; y aplicar las comprobaciones de validación que separan un modelo creíble de uno sobreajustado.

La ruta **esencial** son las técnicas, los formatos, los factores de temperatura y la validación. La ruta de **estudio** añade la evolución al formato moderno y la comparación entre modelos.

1 La estructura macromolecular y la evidencia experimental

ESENCIAL Hasta aquí las proteínas han sido cadenas de texto. A partir de este capítulo son objetos con coordenadas, y esas coordenadas vienen de un experimento que tiene resolución, incertidumbre y decisiones de quien lo interpretó.

En los sistemas celulares, las proteínas no operan como cadenas unidimensionales de texto, sino como entidades físicas tridimensionales cuya arquitectura espacial crea superficies de interacción, cavidades hidrofóbicas y centros catalíticos. Sin embargo, en la bioinformática moderna es un error crítico tratar las coordenadas tridimensionales descargadas de una base de datos como verdades matemáticas absolutas o imágenes fotográficas estáticas: cada conjunto de coordenadas atómicas es un **modelo interpretativo derivado de datos experimentales biofísicos con resolución finita, incertidumbres térmicas y posibles artefactos de cristalización**.

La estructura macromolecular tridimensional dicta la función biológica requiriendo una comprensión rigurosa de la evidencia experimental que sustenta los modelos depositados.

2 Técnicas biofísicas de determinación estructural

ESENCIAL

La casi totalidad de las estructuras macromoleculares depositadas en el Protein Data Bank provienen de tres metodologías biofísicas complementarias:

1. Cristalografía de Rayos X (X-ray Crystallography):

- **Fundamento:** Requiere purificar la proteína e inducir la formación de un monocristal periódico tridimensional. Al ser irradiado con un haz monocromático de rayos X (de longitud de onda comparable a los enlaces covalentes, $\lambda \approx 1 \text{ \AA}$), los electrones de los átomos dispersan la radiación, generando un patrón de difracción de Bragg.
- **El problema de las fases y mapas de densidad:** Los detectores registran las intensidades de difracción pero pierden las fases de las ondas. Las fases se resuelven mediante **reemplazamiento molecular (MR)** o dispersión anómala (SAD/MAD). A partir de las intensidades y fases se calcula por transformada de Fourier el **mapa de densidad electrónica** ($2F_o - F_c$ para contornear la macromolécula y $F_o - F_c$ de diferencia para localizar aguas, ligandos o errores de ajuste).
- **Métricas de calidad** (R_{work} y R_{free}): El ajuste entre las amplitudes observadas (F_o) y calculadas del modelo (F_c) se mide mediante el factor residual R_{work} . Para evitar el sobreajuste (*overfitting*), Axel Brünger introdujo en 1992 el **factor** R_{free} , calculado sobre un conjunto ciego del 5–10% de reflexiones excluidas deliberadamente del refinamiento.

2. Resonancia Magnética Nuclear (RMN / NMR):

- **Fundamento:** Mide el desapantallamiento magnético y el acoplamiento dipolar entre espines nucleares (^1H , ^{13}C , ^{15}N) en solución acuosa libre a temperatura ambiente.
- **Características:** Determina restricciones de distancia espacial mediante efecto nuclear Overhauser (NOE). Al no existir un único estado rígido, la RMN genera un **conjunto de conformaciones dinámicas** (*ensemble*). Está limitada a macromoléculas de tamaño moderado ($< 30\text{--}50 \text{ kDa}$).

3. Crio-Microscopía Electrónica (Cryo-EM):

- **Fundamento:** La muestra en disolución se congela instantáneamente por inmersión en etano líquido a -180°C (**vitrificación**), formando hielo amorfo sin cristales de agua. Un microscopio electrónico de transmisión captura cientos de miles de proyecciones bidimensionales de partículas individuales orientadas al azar.
- **Revolución de resolución:** Algoritmos de alineamiento y clasificación 3D reconstruyen la densidad a resolución atómica ($< 2.5 \text{ \AA}$), permitiendo resolver enormes complejos macromoleculares (ribosomas, spliceosomas, cápsides virales) y receptores de membrana sin necesidad de cristalización.

Los métodos estructurales experimentales comprenden la cristalografía de rayos X (alta resolución atómica $< 2.0 \text{ \AA}$, requiere cristales), RMN (ensamblajes conformacionales en disolución $< 30 \text{ kDa}$) y Cryo-EM (grandes complejos macromoleculares).

Las métricas de calidad de refinamiento cristalográfico incluyen R_{work} y R_{free} validado de forma cruzada sobre reflexiones excluidas para evitar el sobreajuste del modelo.

Los mapas de densidad electrónica ($2F_o - F_c$ y mapas de diferencia $F_o - F_c$) guían el posicionamiento de coordenadas atómicas y el ajuste de rotámeros de cadenas laterales.

3 Formatos estructurales: Del PDB clásico al estándar mmCIF

ESENCIAL

3.1 Especificación del formato PDB de ancho fijo

El formato clásico del Protein Data Bank (Bernstein et al., 1977) se estructura en líneas de texto de exactamente **80 caracteres de ancho fijo**:



Figura 1: Comparativa metodológica de las técnicas biofísicas de resolución estructural tridimensional: Cristalografía, RMN y Cryo-EM. Figura original generada por `verification/make_figures.py`.

- **Líneas ATOM:** Coordenadas de aminoácidos y nucleótidos estándar.
- **Líneas HETATM:** Heteroátomos (iones, moléculas de agua, cofactores, ligandos farmacológicos).

Mapeo de columnas fijas en registros ATOM/HETATM:

Columnas	Campo	Descripción y formato
1–6	Record name	Identificador ("ATOM " o "HETATM").
7–11	Atom serial	Número correlativo entero de serie del átomo (1 a 99.999).
13–16	Atom name	Nombre químico del átomo (p. ej., " CA " para Carbono α).
18–20	ResName	Código de 3 letras del residuo (p. ej., "ALA").
22	Chain ID	Cadena polipeptídica (carácter único, p. ej., 'A').
23–26	ResSeq	Número de secuencia del residuo en la cadena.
31–38	X coordinate	Coordenada cartesiana X en Ångströms (float 8.3).
39–46	Y coordinate	Coordenada cartesiana Y en Ångströms (float 8.3).
47–54	Z coordinate	Coordenada cartesiana Z en Ångströms (float 8.3).
55–60	Occupancy	Ocupación cristalográfica (0.00 a 1.00).
61–66	TempFactor	Factor B de temperatura de Debye-Waller (float 6.2).

El formato Protein Data Bank (PDB) especifica registros de ancho fijo estricto de 80 columnas para líneas ATOM y HETATM complementado por los estándares modernos mmCIF/PDBx.

Traza de parsing del registro ATOM modelo:

Dada la línea PDB canónica:

```
ATOM      1  CA  ALA  A   1       10.000  20.000  30.000  1.00 15.50           C
```

De ahí se extraen, por posición de columna y no por separador, la serie del átomo, su nombre, el residuo al que pertenece, la cadena, el número de residuo, las tres coordenadas, la ocupación y el factor de temperatura.

`parse_pdb_atom` analiza registros ATOM de ancho fijo extrayendo átomo 1, nombre CA, residuo ALA 1, coordenadas (10.000, 20.000, 30.000), ocupación 1.00 y factor B 15.50.

Se reproduce con `verification/chapter_checks.py parse_pdb --line "ATOM 1 CA ALA A 1 10.000 20.000 30.000 1.00 78.96 C"`.

Límites del formato PDB y adopción de mmCIF:

El formato PDB clásico asigna 5 dígitos para el número de serie del átomo (máximo 99.999) y 1 carácter para el identificador de cadena (máximo 62 cadenas alfanuméricas). Los ribosomas y megacomplejos modernos desbordan estos límites, forzando a la wwPDB a adoptar el estándar extensible **mmCIF** (**macromolecular Crystallographic Information File**).

Los límites del formato PDB clásico de 99999 átomos y 62 cadenas llevaron a la adopción del estándar de datos extensible mmCIF por el consorcio wwPDB.

Control defensivo de registros incompletos:

`parse_pdb_atom` lanza `ValueError` al recibir líneas que no son ATOM/HETATM o cadenas truncadas de longitud menor a 66 caracteres.

Se reproduce con `verification/chapter_checks.py parse_pdb --line "ATOM 1 CA"`.

4 Geometría tridimensional, RMSD y factores B

ESENCIAL

4.1 Distancia euclídea 3D

$$d(P_1, P_2) = \sqrt{(x_2 - x_1)^2 + (y_2 - y_1)^2 + (z_2 - z_1)^2}$$

Traza manual para (10, 20, 30) y (13, 24, 30):

$$d = \sqrt{(13 - 10)^2 + (24 - 20)^2 + (30 - 30)^2} = \sqrt{3^2 + 4^2 + 0} = \sqrt{9 + 16} = \sqrt{25} = 5.000000 \text{ \AA}$$

`euclidean_distance_3d` calcula la distancia interatómica entre (10, 20, 30) y (13, 24, 30) evaluando exactamente a 5.000000 Å.

Se reproduce con `verification/chapter_checks.py distance 10 20 30 13 24 30`.

4.2 RMSD entre estructuras superpuestas

`calculate_rmsd` calcula la Desviación Cuadrática Media entre coordenadas atómicas emparejadas evaluando a 0.000000 Å para estructuras idénticas.

Se reproduce con `verification/chapter_checks.py rmsd 10,20,30:11,21,31 10,20,30:12,22,32`.

4.3 El factor B de Debye-Waller y la fluctuación atómica cuadrática media (RMSF)

El factor de temperatura o factor B cuantifica la atenuación de la difracción por agitación térmica y desorden estático. Se relaciona con la fluctuación cuadrática media de la posición atómica $\langle u^2 \rangle$ mediante la ecuación:

$$B = 8\pi^2 \langle u^2 \rangle \iff \langle u^2 \rangle = \frac{B}{8\pi^2} \implies \text{RMSF} = \sqrt{\langle u^2 \rangle} = \sqrt{\frac{B}{8\pi^2}}$$

Traza manual para $B = 78.956835 \text{ \AA}^2$:

Tomando $\pi \approx 3.14159265 \implies 8\pi^2 \approx 78.956835$:

$$\langle u^2 \rangle = \frac{78.956835}{78.956835} = 1.000000 \text{ \AA}^2 \implies \text{RMSF} = \sqrt{1.0} = 1.000000 \text{ \AA}$$

Los factores B térmicos de Debye-Waller evalúan la fluctuación atómica mediante $B = 8\pi^2 \langle u^2 \rangle$, evaluando $B = 78.956835 \text{ \AA}^2$ a una fluctuación cuadrática media de $1.000000 \text{ \AA}^2$ y RMSF $1.000000 \text{ \AA}$.

Se reproduce con `verification/chapter_checks.py bfactor --b 78.956835`.




Figura 2: Relación cuantitativa entre factores B térmicos cristalográficos y fluctuación cuadrática atómica media (RMSF). Figura original generada por `verification/make_figures.py`.

5 Validación estereoquímica y el diagrama de Ramachandran

ESENCIAL

Para evaluar si un modelo tridimensional es físicamente plausible, se analiza la conformación del esqueleto polipeptídico en el **diagrama de Ramachandran** (Ramachandran et al., 1963):

- Mapea los pares de ángulos diedros (ϕ, ψ) del enlace peptídico:
 - ϕ (Phi): Rotación alrededor del enlace $C_\alpha - N$.
 - ψ (Psi): Rotación alrededor del enlace $C_\alpha - C'$.
- Debido a impedimentos estéricos entre átomos no enlazados, solo ciertas regiones del espacio (ϕ, ψ) son energéticamente permitidas:
 - **Hélice α dextrógira** ($\phi \approx -60^\circ, \psi \approx -45^\circ$): la región más poblada del diagrama, donde cae la mayoría de los residuos de una proteína plegada.
 - **Hélice α levógira** ($\phi \approx +60^\circ, \psi \approx +45^\circ$): región pequeña y poco poblada, accesible sobre todo a la glicina, que al carecer de cadena lateral no sufre el impedimento estérico que excluye a los demás residuos.
 - Láminas β paralelas y antiparalelas ($\phi \approx -120^\circ, \psi \approx +130^\circ$).
 - Conformaciones de colágeno y giros β .
- Los programas de validación exigen que más del noventa por ciento de los residuos caiga en las regiones favorecidas para considerar el modelo de buena calidad.

Atención. Encontrar residuos que no sean glicina en la región levógira es una de las señales de alarma habituales al validar un modelo. Puede ser real, porque esa conformación existe y a veces cumple una función en un giro, y puede ser un error de ajuste a la densidad. Lo que no se puede es pasarla por alto: hay que mirar cada caso y justificarlo. Situar las dos regiones helicoidales en el mismo punto del diagrama, que es un error frecuente, hace imposible ese control.

Los gráficos de Ramachandran mapean los ángulos diedros del esqueleto polipeptídico phi y psi para validar la favorabilidad estereoquímica y detectar impedimentos estéricos.




Figura 3: Diagrama de Ramachandran: validación estereoquímica de ángulos diedros (ϕ, ψ) y zonas energéticamente favorecidas. Figura original generada por `verification/make_figures.py`.

6 Clasificación jerárquica de dominios: CATH y SCOP

Las clasificaciones jerárquicas CATH y SCOP organizan las arquitecturas de dominios estructurales proteicos en Clase, Arquitectura, Topología y Superfamilia Homóloga.

7 Diseño computacional en Python: Procesador PDB y métricas

ESTUDIO

A continuación se presenta la implementación modular del procesador en Python 3.9:

```
import math
from typing import Dict, List, Tuple

def parse_pdb_atom(line: str) -> Dict[str, any]:
    """Parsea una línea ATOM de PDB con extracción por columnas fijas."""
    if len(line) < 66 or not line.startswith("ATOM"):
        raise ValueError(f"Línea ATOM de PDB inválida o incompleta ({len(line)} chars)")
    return {
        'serial': int(line[6:11].strip()),
        'name': line[12:16].strip(),
        'res_name': line[17:20].strip(),
        'chain': line[21].strip(),
        'res_seq': int(line[22:26].strip()),
        'x': float(line[30:38].strip()),
        'y': float(line[38:46].strip()),
        'z': float(line[46:54].strip()),
        'occupancy': float(line[54:60].strip()),
        'b_factor': float(line[60:66].strip())
    }

def euclidean_distance_3d(p1: Tuple[float, float, float], p2: Tuple[float, float, float]) -> float:
    """Calcula la distancia euclídea 3D entre dos puntos."""
    return round(math.sqrt((p1[0] - p2[0])**2 + (p1[1] - p2[1])**2 + (p1[2] - p2[2])**2), 6)

def calculate_rmsd(coords1: List[Tuple[float, float, float]], coords2: List[Tuple[float, float, float]]) -> float:
    """Calcula el RMSD entre dos conjuntos emparejados de coordenadas 3D."""
```

```

if len(coords1) != len(coords2) or len(coords1) == 0:
    raise ValueError("Listas de coordenadas deben tener igual longitud no vacia")
sq_diff = sum((p[0] - q[0])**2 + (p[1] - q[1])**2 + (p[2] - q[2])**2 for p, q in zip(coords1, coords2))
return round(math.sqrt(sq_diff / len(coords1)), 6)

def bfactor_to_rmsf(b_factor: float) -> Tuple[float, float]:
    """Convierte el factor B a varianza posicional <u^2> y RMSF."""
    if b_factor < 0:
        raise ValueError("El factor B no puede ser negativo")
    u_sq = b_factor / (8.0 * (math.pi ** 2))
    rmsf = math.sqrt(u_sq)
    return round(u_sq, 6), round(rmsf, 6)

```

8 Peligros computacionales y actividad de depuración

ESTUDIO

Parsear ficheros PDB con `split()` por espacios en lugar de rebanadas de ancho fijo e ignorar factores B elevados ($>60 \text{ \AA}^2$) representan errores computacionales severos.

8.1 Tres errores críticos en procesamiento de estructuras 3D

Localice y corrija los tres errores en la siguiente función:

```

def analyze_crystal_structure(pdb_lines):
    # Error 1: Parsea líneas PDB usando line.split(), fallando sistemáticamente
    # cuando coordenadas negativas fusionan campos sin espacio intermedio

    # Error 2: Asume que todos los átomos con B-factor > 80 Å² están perfectamente
    # posicionados, incluyéndolos en cálculos finos de docking de alta precisión

    # Error 3: Compara la bondad de dos estructuras cristalográficas fijándose
    # únicamente en R-work e ignorando completamente la brecha con R-free (sobreajuste)
    pass

```

Diagnóstico de causa raíz (Protocolo 5 Whys):

- Fallo 1 (Parseo con `split()` en PDB):** Slicing posicional estricto (`line[30:38]`) es obligatorio.
- Fallo 2 (Ignorar alta movilidad en factores B):** Factores $B > 60\text{--}80 \text{ \AA}^2$ denotan regiones altamente flexibles, desordenadas o mal ajustadas a la densidad electrónica.
- Fallo 3 (Sobreajuste cristalográfico):** Una estructura con $R_{\text{work}} = 0.15$ pero $R_{\text{free}} = 0.32$ presenta un modelo sobreajustado con átomos encajados artificialmente en el ruido.

9 Síntesis operativa y tablas de diagnóstico

REFERENCIA

9.1 Tabla comparativa de métodos de determinación estructural

Método biofísico	Resolución típica	Estado de la muestra	Límite de tamaño molecular
Cristalografía Rayos X	1.0–3.0 Å (Atómica)	Monocristal sólido periódico	Sin límite superior
RMN en disolución	Conformaciones múltiples	Disolución acuosa fisiológica	< 30–50 kDa
Cryo-EM partícula única	1.8–4.0 Å	Hielo vítreo amorfo congelado	> 100 kDa hasta MDa
AlphaFold2 / ESMFold	Confianza pLDDT	Predicción computacional	Sin límite intrínseco

9.2 Tabla de diagnóstico de problemas en coordenadas PDB

Síntoma observado	Causa probable	Comprobación y corrección
Residuos en regiones desfavorables de Ramachandran	Impedimentos estéricos o errores en cadena	Refinar geometría o reconstruir el bucle
Factores B anormalmente elevados ($> 100 \text{ \AA}^2$)	Desorden conformacional o bucles móviles	Tratar como región flexible/desordenada
Brecha $R_{\text{free}} - R_{\text{work}} > 0.08$	Sobreajuste (<i>overfitting</i>) de parámetros	Revisar peso de restricciones estereoquímicas
Ocupación parcial	el residuo tiene varias conformaciones alternativas	tratar cada conformación por separado

10 Glosario conceptual

REFERENCIA

- **Difracción de Rayos X:** Dispersión elástica por electrones de cristales.
- **Mapas $2F_o - F_c$:** Densidad electrónica observada vs calculada.
- **R-free (Brünger):** Validación cruzada ciega sobre 5–10% de datos.
- **Vitrificación:** Congelación ultra-rápida sin cristalización de agua.
- **PDB (80 columnas):** Estándar posicional en caracteres de ancho fijo.
- **mmCIF:** Estándar extensible para macromoléculas gigantes.
- **Factor B:** Desplazamiento térmico atómico $B = 8\pi^2\langle u^2 \rangle$.
- **RMSF:** Fluctuación cuadrática media de posición atómica.
- **Ramachandran:** Mapa de ángulos diedros (ϕ, ψ).
- **CATH / SCOP:** Clasificación jerárquica de dominios 3D.

11 Conexiones y mapa del curso

Este capítulo abre la Parte IV estableciendo la línea base experimental requerida para evaluar los métodos clásicos e impulsados por IA de predicción estructural.

La comprensión de las coordenadas experimentales transita directamente hacia la predicción de estructura secundaria y el modelado por homología en BC-CH12.

12 Fuentes y reproducibilidad

El diagrama de ángulos permitidos y su uso en validación siguen a Ramachandran y colaboradores [4]; el formato del banco de datos y su gobernanza, a Berman y colaboradores [1]; la superposición óptima de dos estructuras, a Kabsch [3]; y la dispersión anómala como solución al problema de las fases, a Hendrickson y colaboradores [2].

Todos los cálculos se reproducen con `verification/chapter_checks.py` tal como están impresos, con sus argumentos.

Bibliografía

- [1] Helen M. Berman, John Westbrook, Zukang Feng, Gary Gilliland, T. N. Bhat, Helge Weissig, Ilya N. Shindyalov, and Philip E. Bourne. The protein data bank. *Nucleic Acids Research*, 28(1):235–242, 2000. Artículo canónico sobre el Protein Data Bank (PDB) y la estandarización de estructuras 3D.
- [2] Wayne A. Hendrickson. Stereochemically restrained refinement of macromolecular structures. *Methods in Enzymology*, 115:252–270, 1985. Refinamiento y factores térmicos B de Debye-Waller en cristalografía de proteínas.

- [3] Wolfgang Kabsch. A solution for the best rotation to relate two sets of vectors. *Acta Crystallographica Section A*, 32(5):922–923, 1976. Algoritmo de Kabsch para superposicion optima de estructuras y calculo de RMSD.
- [4] G. N. Ramachandran, C. Ramakrishnan, and V. Sasisekharan. Stereochemistry of polypeptide chain configurations. *Journal of Molecular Biology*, 7(1):95–99, 1963. Articulo fundacional sobre los angulos diedros phi y psi y el diagrama de Ramachandran.