

Contents

1	Predicción estructural con IA y evaluación de confianza	1
1.1	La revolución de la inteligencia artificial en biología estructural	1
1.2	Fundamento biológico: coevolución y alineamiento múltiple (MSA)	1
1.3	Arquitectura de AlphaFold2: Evoformer y Módulo Estructural	2
1.3.1	El módulo Evoformer (48 bloques de comunicación dual)	2
1.3.2	Actualización triangular (<i>Triangle Update</i>)	2
1.3.3	Módulo Estructural e Invarianza SE(3)	3
1.4	Métricas de confianza: pLDDT y matrices PAE	3
1.4.1	Confianza local por residuo: pLDDT	3
1.4.2	Matriz de error posicional alineado (PAE)	4
1.4.3	Validación defensiva de puntuaciones pLDDT	4
1.5	Nuevas fronteras: modelos de difusión y modelos de lenguaje	4
1.5.1	Modelos generativos de difusión: AlphaFold3 y RoseTTAFold All-Atom	4
1.5.2	Modelos de lenguaje proteico (<i>pLMs</i>): ESMFold	5
1.6	Responsabilidad bioinformática y auditoría ética (BC-C7)	5
1.7	Diseño computacional en Python	5
1.8	Peligros computacionales y auditoría de limitaciones	6
1.9	Actividad de depuración: 3 errores en auditoría de predicciones	6
1.10	Síntesis operativa y tablas de diagnóstico	6
1.10.1	Tabla de diagnóstico y toma de decisiones según métricas de confianza	6
1.10.2	Tabla comparativa de modelos modernos de predicción por IA	6
1.11	Glosario conceptual	7
1.12	Transición hacia BC-CH14: Dinámica molecular y diseño de fármacos	7
1.13	Fuentes y reproducibilidad	7
	Anexo práctico · Métricas de confianza pLDDT, matrices PAE y auditoría de modelos de IA	9

Chapter 1

Predicción estructural con IA y evaluación de confianza

1.1 La revolución de la inteligencia artificial en biología estructural

Durante más de medio siglo, el problema del plegamiento de proteínas formulado por Christian Anfinsen se consideró uno de los mayores retos abiertos de la ciencia contemporánea. Como estudiamos en BC-CH12, los métodos clásicos basados en simulación física y ensamblaje de fragmentos (Rosetta, MODELLER) tropezaban sistemáticamente con paisajes energéticos rugosos e intratables cuando no existían plantillas homólogas con identidad superior al 30%.

Esencial

La irrupción de las redes neuronales profundas de atención geométrica en las ediciones CASP13 (2018) y CASP14 (2020) con **AlphaFold2** (Jumper et al., 2021) y **RoseTTAFold** (Baek et al., 2021) transformó radicalmente este escenario, reconocido con el Premio Nobel de Química de 2024. El cambio de paradigma consistió en sustituir la simulación física estocástica por el **aprendizaje geométrico de representaciones de coevolución extremo a extremo** (*End-to-End Deep Learning*).

Sin embargo, en la práctica bioinformática contemporánea, predecir una estructura con un modelo de IA no basta: **resulta imperativo auditar la confianza local y global de la predicción, comprender sus límites físicos y no confundir regiones de desorden intrínseco funcional con fallos del algoritmo.**

La ruta **esencial** cubre los fundamentos de coevolución, la arquitectura Evoformer, las métricas de confianza pLDDT y matrices PAE, los modelos de difusión (AlphaFold3), los modelos de lenguaje proteico (ESMFold) y la auditoría responsable de limitaciones bajo la competencia oficial **BC-C7**; 120–140 minutos. La ruta de **estudio** profundiza en la invarianza SE(3), actividad de depuración y el anexo práctico; 60–80 minutos adicionales.

Esencial

La predicción estructural mediante aprendizaje profundo transforma la simulación física tradicional en un aprendizaje de patrones geométricos extremo a extremo sobre datos de coevolución biológica.

1.2 Fundamento biológico: coevolución y alineamiento múltiple (MSA)

El núcleo informativo que permite a las redes neuronales deducir distancias tridimensionales es la **hipótesis de coevolución**:

1. Cuando dos aminoácidos alejados en la secuencia primaria se encuentran en contacto

físico directo en el núcleo 3D nativo (p. ej., un puente salino o un empaquetamiento hidrofóbico), una mutación perjudicial en la posición i desestabiliza la proteína.

2. Para preservar la viabilidad celular y la función biológica, la selección natural favorece mutaciones compensatorias en la posición j .
3. Al analizar un alineamiento múltiple de secuencias (MSA) con cientos o miles de secuencias homólogas, las mutaciones correlacionadas entre pares de columnas revelan restricciones de proximidad espacial $C\alpha$ - $C\alpha$ sin necesidad de conocer la estructura experimental previa.

La coevolución biológica en alineamientos múltiples de secuencias (MSA) captura restricciones de contacto espacial que preservan la estabilidad nativa de la macromolécula.

1.3 Arquitectura de AlphaFold2: Evoformer y Módulo Estructural

AlphaFold2 abandona la clásica predicción intermedia de mapas 2D aislados y adopta un flujo de procesamiento continuo estructurado en dos módulos principales:

1.3.1 El módulo Evoformer (48 bloques de comunicación dual)

El Evoformer procesa simultáneamente dos representaciones acopladas:

- **Pista de secuencias (MSA 1D):** Matriz de dimensiones $N_{\text{seq}} \times N_{\text{res}}$ que codifica la diversidad filogenética y las correlaciones de columnas.
- **Pista de pares de residuos (2D):** Matriz $N_{\text{res}} \times N_{\text{res}}$ que representa las distancias y orientaciones relativas hipotetizadas entre pares de residuos.

Ambas pistas intercambian información mediante mecanismos de atención cruzada en cada bloque, refinando iterativamente las hipótesis de contacto.

El módulo Evoformer de AlphaFold2 combina la representación del MSA 1D con la representación por pares 2D mediante atención geométrica dual y actualización triangular (*Triangle Update*).

1.3.2 Actualización triangular (*Triangle Update*)

Para garantizar que la matriz 2D represente un espacio físico euclidiano tridimensional realizable y no contenga distancias imposibles, la red aplica la desigualdad triangular en cada triplete de residuos (i, j, k) :

$$d_{ik} \leq d_{ij} + d_{jk}$$

Evaluación computacional de consistencia triangular: Para distancias interatómicas propuestas $d_{12} = 3.0$ Å, $d_{23} = 4.0$ Å y $d_{13} = 5.0$ Å:

$$d_{13} = 5.0 \leq 3.0 + 4.0 = 7.0 \quad (\text{Válido})$$

`check_triangle_inequality` valida la consistencia geométrica asegurando que las distancias cumplan la desigualdad triangular, evaluando la terna $(3, 4, 5)$ como geométricamente válida. Se reproduce con `verification/chapter_checks.py triangle -d12 3.0 -d23 4.0 -d13 5.0`.

1.3.3 Módulo Estructural e Invarianza SE(3)

El **Structure Module** (8 capas iterativas) convierte las representaciones abstractas del Evoformer en coordenadas atómicas 3D reales. Emplea el mecanismo de **Invariant Point Attention (IPA)**, que opera sobre marcos rígidos locales tridimensionales asociados al enlace peptídico de cada carbono alfa $C\alpha$. Esto garantiza que las predicciones sean formalmente invariantes bajo el grupo especial euclidiano SE(3) (rotaciones y traslaciones en el espacio tridimensional).

El Módulo Estructural emplea Invariant Point Attention (IPA) operando sobre marcos rígidos locales con invarianza SE(3) para generar coordenadas atómicas del esqueleto tridimensional.

1.4 Métricas de confianza: pLDDT y matrices PAE

Uno de los mayores avances metodológicos de AlphaFold2 es que la red no solo produce coordenadas atómicas, sino que calcula de forma nativa dos métricas de confianza calibradas:

1.4.1 Confianza local por residuo: pLDDT

El **pLDDT** (*predicted Local Distance Difference Test*) es una estimación que evalúa en una escala de 0 a 100 qué porcentaje de distancias interatómicas en un entorno de 15 Å alrededor de cada $C\alpha$ coincidirían con una estructura resuelta experimentalmente. Se divide en cuatro bandas canónicas:

Banda pLDDT	Categoría	Interpretación bioinformática
≥ 90	Muy alta (<i>Very High</i>)	Precisión atómica en esqueleto y cadenas laterales; apto para diseño de fármacos.
70–90	Confiable (<i>Confident</i>)	Esqueleto polipeptídico altamente fiable y topología secundaria correcta.
50–70	Baja (<i>Low</i>)	Conformación aproximada; requiere precaución en la orientación de dominios.
< 50	Muy baja (<i>Very Low</i>)	Marcador diagnóstico de regiones intrínsecamente desordenadas (IDPs) .

El pLDDT cuantifica la confianza local en una escala de 0 a 100: muy alta (≥ 90), confiable (70–90), baja (50–70) y muy baja (< 50 , asociada a desorden intrínseco).

Evaluación computacional de pLDDT:

- Para una puntuación de 92.50: clasifica en la banda **VERY_HIGH**.
- Para un cuarteto de residuos con puntuaciones [95.0, 92.0, 88.0, 45.0]:

$$\overline{\text{pLDDT}} = \frac{95.0 + 92.0 + 88.0 + 45.0}{4} = \frac{320.0}{4} = \mathbf{80.000000}$$

`classify_plddt` clasifica la puntuación de confianza evaluando el score 92.50 en la banda **VERY_HIGH**. Se reproduce con `verification/chapter_checks.py plddt -score 92.5`.

`calculate_mean_plddt` evalúa la confianza media del modelo evaluando el cuarteto [95, 92, 88, 45] exactamente a 80.000000. Se reproduce con `verification/chapter_checks.py mean_plddt`.

1.4.2 Matriz de error posicional alineado (PAE)

El pLDDT mide la precisión local de cada residuo, pero no informa sobre la orientación relativa entre dos dominios independientes conectados por un bucle flexible. Para resolver esta ambigüedad, AlphaFold genera la matriz **PAE** (*Predicted Aligned Error*), de tamaño $N \times N$, donde cada entrada (i, j) representa el error esperado (en Å) en la posición tridimensional del residuo j cuando el modelo predicho se alinea sobre el residuo i .

- **PAE interdominio baja** (< 5.0 Å): Los dos dominios tienen una orientación relativa rígida y bien definida.
- **PAE interdominio alta** (> 15.0 Å): Cada dominio individual está bien plegado (alto pLDDT interno), pero la orientación mutua entre ambos es incierta debido a un enlazador (*linker*) flexible.

La matriz PAE de $N \times N$ en Å cuantifica la incertidumbre espacial interresiduo para discriminar el empaquetamiento rígido de dominios frente a bisagras flexibles.

Evaluación computacional de submatriz PAE: Para una submatriz de contacto interdominio de 2×2 :

$$\text{PAE} = \begin{pmatrix} 2.5 & 3.0 \\ 3.0 & 2.8 \end{pmatrix} \Rightarrow \overline{\text{PAE}} = \frac{2.5 + 3.0 + 3.0 + 2.8}{4} = \mathbf{2.825000 \text{ Å}}$$

Dado que $\overline{\text{PAE}} < 5.0$ Å, se clasifica como RIGID_ORIENTATION.

`evaluate_interdomain_pae` evalúa la matriz PAE modelo con media de 2.825000 Å clasificando el contacto como orientación rígida (RIGID_ORIENTATION). Se reproduce con `verification/chapter_checks.py pae`.

1.4.3 Validación defensiva de puntuaciones pLDDT

`classify_plddt` lanza `ValueError` cuando la puntuación pLDDT se sitúa fuera del intervalo físicamente válido $[0, 100]$. Se reproduce con `verification/practice_checks.py domain_guard -score 105.0`.

1.5 Nuevas fronteras: modelos de difusión y modelos de lenguaje

1.5.1 Modelos generativos de difusión: AlphaFold3 y RoseTTAFold All-Atom

La tercera generación de modelos (AlphaFold3, Abramson et al., 2024; RoseTTAFold All-Atom, Baek et al., 2021) reemplaza el módulo estructural rígido por un **modelo generativo de difusión**. A partir de una nube de coordenadas con ruido gaussiano, la red aprende a eliminar el ruido paso a paso guiada por representaciones de pares (Pairformer), permitiendo predecir simultáneamente complejos heterogéneos que contienen proteínas, ADN, ARN, iones metálicos y ligandos químicos de pequeño tamaño.

Los modelos generativos de difusión en AlphaFold3 y RoseTTAFold All-Atom predicen ensamblajes heterogéneos de proteínas, ácidos nucleicos, iones y ligandos mediante eliminación iterativa de ruido gaussiano.

1.5.2 Modelos de lenguaje proteico (*pLMs*): ESMFold

Inspirados en los grandes modelos de lenguaje de procesamiento del lenguaje natural (NLP), modelos como **ESM-2** y **ESMFold** (Meta AI; Lin et al., 2023) aprenden la "gramática evolutiva" entrenándose sobre miles de millones de secuencias proteicas en UniRef. ESMFold predice estructuras 3D completas a partir de una única secuencia (*single sequence*) en fracciones de segundo, sin requerir la costosa construcción previa de alineamientos múltiples (MSA).

Los modelos de lenguaje proteico (*pLMs*, ESMFold) aprenden la gramática evolutiva para predecir estructuras desde una única secuencia a gran velocidad sin necesidad de construir un MSA.

1.6 Responsabilidad bioinformática y auditoría ética (BC-C7)

En cumplimiento del resultado oficial de aprendizaje **BC-C7** (*Desarrollo responsable y sostenible de soluciones bioinformáticas*), el uso de modelos generativos y de aprendizaje profundo en biomedicina exige una rigurosa **auditoría de confianza y limitaciones**:

1. **Verificación obligatoria de pLDDT y PAE:** Ninguna conclusión biológica, hipótesis de mecanismo molecular o diseño de fármacos debe fundamentarse en regiones con $pLDDT < 70$ o conexiones con $PAE > 15$ Å sin validación experimental ortogonal.
2. **Comprensión del desorden intrínseco (IDPs):** Aproximadamente el 30% del proteoma eucariota corresponde a proteínas intrínsecamente desordenadas. Un valor $pLDDT < 50$ no indica que la IA "haya fallado", sino que la molécula carece de una conformación nativa rígida en solución libre.
3. **Naturaleza estática de la predicción:** Las redes neuronales actuales predicen un estado conformacional dominante; no simulan espontáneamente transiciones alostéricas ni dinámicas temporales en función de la temperatura o pH.

La bioinformática responsable y la auditoría de confianza (BC-C7) exigen verificar rigurosamente el pLDDT y la matriz PAE antes de basar decisiones biomédicas o farmacológicas en modelos predichos por IA.

1.7 Diseño computacional en Python

Presentamos un evaluador de confianza estructural:

Listing 1.1: Evaluador de bandas pLDDT y matrices PAE en Python.

```
def classify_plddt(score: float) -> str:
    if score < 0.0 or score > 100.0:
        raise ValueError("Score fuera de rango [0, 100]")
    if score >= 90.0:
        return "VERY_HIGH"
    elif score >= 70.0:
        return "CONFIDENT"
    elif score >= 50.0:
        return "LOW"
    return "VERY_LOW_OR_IDP"

def evaluate_interdomain_pae(submatrix: list[list[float]]) -> float:
    total = sum(val for row in submatrix for val in row)
    return total / (len(submatrix) * len(submatrix[0]))
```

1.8 Peligros computacionales y auditoría de limitaciones

- 1. **Interpretar regiones pLDDT < 50 como estructuras rígidas fiables:** Tratar bucles desordenados como si fueran sitios de unión fijos de fármacos conduce a cribados virtuales completamente erróneos.
- 2. **Ignorar la matriz PAE en proteínas multidominio:** Asumir que la posición relativa de dos dominios es fija basándose solo en su pLDDT interno individual sin comprobar el PAE interdominio.

Interpretar regiones de pLDDT bajo como fallos algorítmicos en lugar de desorden intrínseco (IDP) y asumir rigidez estática interdominio sin auditar el PAE constituyen errores críticos en biología estructural computacional.

1.9 Actividad de depuración: 3 errores en auditoría de predicciones

Localice los tres errores en la siguiente función de análisis de calidad:

Listing 1.2: Funcion con 3 errores de logica en evaluacion de pLDDT y PAE.

```
def audit_prediction_confidence(plddt_scores, pae_matrix):  
    # Error 1: no valida rango [0, 100] en scores de pLDDT  
    # Error 2: clasifica como rigida una matriz PAE con valores mayores de 15 A  
    # Error 3: calcula promedio sin comprobar division por lista vacia  
    mean_plddt = sum(plddt_scores) / len(plddt_scores)  
    is_rigid = pae_matrix[0][0] > 15.0  
    return mean_plddt, is_rigid
```

1.10 Síntesis operativa y tablas de diagnóstico

1.10.1 Tabla de diagnóstico y toma de decisiones según métricas de confianza

pLDDT Residuo	PAE Interdominio	Diagnóstico Estructural	Acción Bioinformática
≥ 90 (Muy alto)	< 5.0 Å (Bajo)	Dominio globular rígido con orientación fija	Apto para acoplamiento molecular y diseño
70–90 (Confiable)	< 5.0 Å (Bajo)	Topología fiable del esqueleto	Adecuado para análisis de plegamiento
≥ 90 (Muy alto)	> 15.0 Å (Alto)	Dos dominios rígidos con bisagra flexible	Analizar cada dominio por separado
< 50 (Muy bajo)	> 20.0 Å (Alto)	Región intrínsecamente desordenada (IDP)	No modelar como estructura rígida

1.10.2 Tabla comparativa de modelos modernos de predicción por IA

Herramienta	Entrada Requerida	Arquitectura Central	Capacidad de Complejos
AlphaFold2	Secuencia + MSA	Evoformer + IPA	Monómeros y oligómeros (Multimer)
AlphaFold3	Secuencia / MSA	Diffusion Module	Proteínas + ADN + ARN + Ligandos
RoseTTAFold	Secuencia + MSA	3-Track Network	Complejos proteicos y macromoléculas
ESMFold	Secuencia individual	ESM-2 pLM + Pair-former	Monómeros ultra-rápidos a escala genómica

1.11 Glosario conceptual

- **Evoformer:** transformador dual 1D/2D en AlphaFold2.
- **Triangle Update:** forzado de desigualdad triangular.
- **IPA:** Invariant Point Attention sobre marcos rígidos.
- **pLDDT:** métrica local de confianza por residuo.
- **PAE:** matriz de error posicional alineado interdominio.
- **IDP:** proteína intrínsecamente desordenada.
- **Modelo de difusión:** eliminación iterativa de ruido gaussiano.
- **pLM:** modelo de lenguaje proteico (ESM-2).
- **Coevolución:** correlación de mutaciones en el MSA.
- **Invarianza SE(3):** simetría bajo roto-traslaciones 3D.

1.12 Transición hacia BC-CH14: Dinámica molecular y diseño de fármacos

La comprensión de los modelos estáticos predichos por IA y sus métricas de confianza da paso en BC-CH14 a las simulaciones de dinámica molecular, el acoplamiento molecular (*docking*) y el cribado virtual de fármacos.

Ahora que disponemos de modelos estructurales predichos con precisión atómica y sabemos discriminar sus regiones de alta fiabilidad mediante pLDDT y PAE, estamos en condiciones de dar el paso definitivo en biología estructural computacional: **poner las moléculas en movimiento y evaluar su interacción con fármacos candidatos**. Esta integración cierra el libro en el siguiente capítulo (**BC-CH14: Dinámica molecular, docking y cribado virtual**).

1.13 Fuentes y reproducibilidad

Este capítulo se fundamenta en las diapositivas docentes (20251202_estprot_3.pptx, Álvaro Serrano Navarro), en Jumper et al. (2021), Baek et al. (2021), Lin et al. (2023) y Abramson et al. (2024). Todos los cálculos se reproducen mediante `verification/chapter_checks.py`.

Anexo práctico · Métricas de confianza pLDDT, matrices PAE y auditoría de modelos de IA

Pregunta, producto y separación de materiales

¿Puede implementar un módulo en Python que clasifique las bandas de calidad local pLDDT de AlphaFold, evalúe la confianza promedio del modelo, analice submatrices PAE para discriminar orientaciones interdominio rígidas de bisagras flexibles, y valide la consistencia geométrica euclidiana mediante la desigualdad triangular de forma determinista y sin dependencias externas? Este laboratorio responde afirmativamente implementando cada componente de auditoría bajo la competencia oficial **BC-C7**.

El producto individual contiene: el clasificador de bandas pLDDT, el calculador de confianza media, el analizador de submatrices PAE interdominio, la verificación de desigualdad triangular, la perturbación hacia desorden intrínseco (IDP), el control de excepciones de la guarda de dominio y la defensa conceptual escrita.

El anexo es autónomo e independiente: no requiere paquetes externos. Emplea `verification/practice_checker` como oráculo determinista.

Mapa de ruta, tiempos y dedicación

Bloque de trabajo	Minutos	Producto entregable
1 · Entorno y diagnóstico	5	Comprobación del intérprete Python 3.9
2 · Cálculo ancla (pLDDT, Media, PAE, Triángulo)	20–25	VERY_HIGH , Media 80.0, PAE 2.825 Å (RIGID), Triángulo válido
3 · Perturbación a desorden (IDP y Linker)	15–20	$pLDDT = 42.0 \implies IDP, PAE = 21.0 \text{ Å} \implies \text{LINKER}$
4 · Guarda de dominio	10–15	Captura de ValueError ante score 105.0
5 · Preguntas de control de IA estructural	5–10	Preguntas sobre Evoformer, PAE y ética BC-C7
6 · Verificación y empaquetado	5	Comprobación final y empaquetado

La ruta de este anexo suma 75–100 minutos y produce evidencia comprobable y verificable en cada bloque de trabajo sin paquetes externos.

1 · Entorno y diagnóstico

Verifique que su entorno dispone de Python 3.9 o superior:

Listing 1.3: Comprobacion de interprete y oraculo.

```
python3 --version
python3 verification/practice_checks.py --help
```

2 · Cálculo ancla: pLDDT, media, PAE y consistencia triangular

Dadas las condiciones estándar de auditoría:

1. Puntuación pLDDT de 92.50: clasifica en la banda VERY_HIGH.
2. Cuarteto de residuos [95.0, 92.0, 88.0, 45.0]: el pLDDT medio evalúa a **80.000000**.
3. Submatriz PAE de 2×2 ($\begin{bmatrix} 2.5 & 3.0 \\ 3.0 & 2.8 \end{bmatrix}$): media de **2.825000** Å clasificada como RIGID_ORIENTATION.
4. Triplete de distancias (3.0, 4.0, 5.0): la desigualdad triangular evalúa como Válida.

Listing 1.4: Ejecucion del calculo ancla.

```
python3 verification/practice_checks.py anchor
```

El modelo ancla valida la banda VERY_HIGH, el pLDDT medio de 80.000000, la media PAE de 2.825000 Å (RIGID_ORIENTATION) y la consistencia geométrica triangular. Se reproduce con `verification/practice_checks.py anchor`.

3 · Perturbación: auditoría de desorden intrínseco y bisagras flexibles

Compruebe la respuesta del clasificador ante una región de desorden intrínseco (pLDDT = 42.0) y una submatriz PAE interdominio de alta incertidumbre ($\begin{bmatrix} 18.0 & 22.0 \\ 20.0 & 24.0 \end{bmatrix}$, media 21.000000 Å):

Listing 1.5: Calculo de perturbacion de incertidumbre.

```
python3 verification/practice_checks.py perturbation
```

La perturbacion con score 42.0 (VERY_LOW_OR_IDP) y PAE medio de 21.000000 Å (FLEXIBLE_LINKER) verifica la auditoria de incertidumbre. Se reproduce con `verification/practice_checks.py perturbation`.

4 · Guarda de dominio y control de excepciones

Compruebe que el algoritmo rechaza puntuaciones pLDDT fuera del rango [0, 100]:

Listing 1.6: Guarda de dominio ante pLDDT fuera de rango.

```
python3 verification/practice_checks.py domain_guard --score 105.0
```

La guarda de dominio rechaza puntuaciones pLDDT fuera del intervalo [0, 100] lanzando un `ValueError`. Se reproduce con `verification/practice_checks.py domain_guard -score 105.0`.

5 · Verificación y entrega

La verificación de entrega confirma la ejecución autónoma bajo el intérprete estándar de Python 3.9 sin librerías externas opacas.

Rúbrica de calificación ponderada

La evaluación sobre 10 puntos se pondera según:

- **4.0 puntos (40%):** Ejecución correcta y reproducible de los scripts de comprobación (`chapter_checks.py` y `practice_checks.py`).
- **2.0 puntos (20%):** Implementación del clasificador de bandas pLDDT y el cálculo de pLDDT medio (Bloque 2).
- **2.0 puntos (20%):** Análisis de submatrices PAE, desigualdad triangular y control de excepciones en la guarda (Bloques 3 y 4).
- **2.0 puntos (20%):** Defensa conceptual escrita (100–150 palabras) sobre la auditoría ética de predicciones bajo la competencia **BC-C7**.

Lista de autocorrección

- Verifiqué que mi versión de Python es ≥ 3.9 .
- Score 92.5 clasificó en `VERY_HIGH`.
- La media pLDDT evaluó a 80.000000.
- La PAE media evaluó a 2.825000 Å (RIGID).
- La desigualdad triangular resultó válida.
- Perturbación evaluó a `VERY_LOW_OR_IDP` y `LINKER`.
- Score 105.0 lanzó `ValueError`.
- Redacté la defensa conceptual individual.

Defensa conceptual

En 100–150 palabras, justifique por qué un bioinformático responsable (**BC-C7**) nunca debe utilizar un modelo predicho por IA para diseño de fármacos basándose únicamente en el pLDDT global sin examinar la matriz PAE y el pLDDT local del sitio de unión, y explique por qué las regiones con $\text{pLDDT} < 50$ representan frecuentemente desorden funcional y no fallos de cálculo.

Fuentes y reproducibilidad

Este anexo se fundamenta en las diapositivas docentes (20251202_estprot_3.pptx), en Jumper et al. (2021), Baek et al. (2021) y Abramson et al. (2024), y se valida al 100% mediante `verification/practice_checks.py`.