

# Aprendizaje profundo, redes neuronales y AlphaFold en biología estructural

## BC-CH13 – Biología Computacional

Edición 2 · 2026-09-04

**Pregunta del tema.** AlphaFold devuelve coordenadas atómicas completas para cualquier secuencia que se le dé, incluidas las que no se pliegan. El modelo nunca dice «no lo sé»: lo dice el pLDDT y lo dice la matriz PAE, en otro sitio y en otra escala. ¿Cómo se lee una predicción para saber qué parte de ella es una afirmación y qué parte es una conjetura?

**Producto final.** Un módulo propio que clasifique las bandas de pLDDT, calcule la confianza media, distinga por la matriz PAE una orientación rígida entre dominios de una bisagra flexible y compruebe la consistencia geométrica del modelo, con un informe que dictamine cuatro modelos predichos y diga para qué sirve cada uno.

### Mapa del tema

|                                                                  |   |
|------------------------------------------------------------------|---|
| 1. Qué cambió con el aprendizaje profundo                        | 1 |
| 2. Coevolución molecular en alineamientos múltiples (MSAs)       | 2 |
| 3. Arquitectura de AlphaFold2: Del Evoformer al Structure Module | 2 |
| 4. Métricas de confianza: pLDDT y matrices PAE                   | 3 |
| 5. Fronteras emergentes: AlphaFold3 y Modelos de Lenguaje        | 6 |
| 6. Diseño computacional en Python: Clasificador pLDDT y PAE      | 6 |
| 7. Peligros computacionales y actividad de depuración            | 7 |
| 8. Ética y auditoría de las predicciones                         | 7 |
| 9. Síntesis operativa y tablas de diagnóstico                    | 8 |
| 10. Glosario conceptual                                          | 8 |
| 11. Conexiones y mapa del curso                                  | 8 |
| 12. Fuentes y reproducibilidad                                   | 8 |

## Cómo usar este tema

Este capítulo cierra la parte estructural y es el único donde el método que se estudia no se puede reproducir: entrenar AlphaFold está fuera del alcance de cualquier asignatura. Lo que sí está a su alcance, y es lo que de verdad se usa a diario, es leer bien lo que el sistema devuelve.

Por eso el capítulo se organiza en dos mitades desiguales. La primera explica de dónde sale la información: la coevolución en un alineamiento múltiple, y cómo el Evoformer la convierte en una geometría. La segunda, más larga en tiempo de trabajo, es la que enseña a auditar el resultado con el pLDDT y la matriz PAE.

Al terminar sabrá: explicar por qué dos residuos que mutan de forma correlacionada están probablemente en contacto; leer un pLDDT por residuo y decir qué banda admite qué uso; leer una matriz PAE y distinguir un empaquetamiento rígido de una bisagra; y reconocer cuándo una región de baja confianza es desorden funcional y no un fallo del método.

La ruta **esencial** son la coevolución en un alineamiento múltiple, la arquitectura de AlphaFold2, las dos métricas de confianza y la auditoría de una predicción. La ruta de **estudio** añade las fronteras con difusión y modelos de lenguaje, la actividad de depuración y el anexo práctico.

## 1 Qué cambió con el aprendizaje profundo

### ESENCIAL

**ESENCIAL** El capítulo anterior terminaba con métodos que necesitan una plantilla o pagan el precio de explorar un espacio enorme. Este trata de lo que los sustituyó en la práctica: **redes neuronales geométricas entrenadas de extremo a extremo**, reconocidas con el Premio Nobel de Química de 2024.

Durante más de cinco décadas, la predicción estructural dependió de simulaciones biofísicas costosas y funciones de energía empíricas aproximadas. Lo que AlphaFold cambió no fue acelerar una simulación física molecular paso a paso, sino en **reformular el plegamiento como un problema de inferencia geométrica directa y reconocimiento de patrones espaciales sobre la información evolutiva acumulada en millones de años**:

La predicción estructural mediante aprendizaje profundo transforma la simulación física en un aprendizaje de patrones geométricos de extremo a extremo a través de datos de coevolución evolutiva.

## 2 Coevolución molecular en alineamientos múltiples (MSAs)

ESENCIAL

El motor biológico fundamental que alimenta los modelos neuronales de predicción estructural es el fenómeno de la **coevolución molecular**:

- Cuando dos aminoácidos alejados en la secuencia primaria se encuentran en íntimo contacto físico espacial en el interior de la estructura nativa, una mutación perjudicial en uno de ellos (p. ej., una sustitución de un residuo cargado positivamente Lys por uno voluminoso o cargado negativamente Glu) desestabiliza el núcleo proteico.
- Para preservar la viabilidad celular, la selección natural favorece una **mutación compensatoria** en el residuo en contacto espacial (p. ej., mutando una pareja previa a una carga positiva que restablezca el puente salino o adaptando el volumen estérico).
- Al analizar estadísticamente un alineamiento múltiple de secuencias (MSA) con miles de homólogos mediante **Análisis de Acoplamiento Directo (DCA)**, las correlaciones mutacionales revelan con precisión la matriz de contactos tridimensionales de la proteína.

La coevolución molecular en alineamientos múltiples de secuencias captura restricciones de contacto espacial que preservan la estabilidad estructural nativa.

## 3 Arquitectura de AlphaFold2: Del Evoformer al Structure Module

ESENCIAL

Diseñado por DeepMind [3], AlphaFold2 supera a los métodos anteriores al integrar dos bloques neuronales acoplados que refinan iterativamente la geometría molecular:

### 3.1 El bloque Evoformer y las actualizaciones triangulares

ESENCIAL

El **Evoformer** procesa simultáneamente dos representaciones acopladas mediante mecanismos de atención axial (*Axial Attention*):

1. **Representación 1D del MSA** ( $N_{\text{seq}} \times N_{\text{res}}$ ): Codifica las secuencias homólogas y sus perfiles evolutivos.
2. **Representación 2D de pares de residuos** ( $N_{\text{res}} \times N_{\text{res}}$ ): Codifica la matriz de relaciones espaciales y distancias relativas entre cada par de aminoácidos ( $i, j$ ).

Para garantizar que la matriz de pares represente una geometría tridimensional físicamente coherente, el Evoformer incorpora las **Actualizaciones Triangulares** (*Triangle Multiplicative Update* y *Triangle Self-Attention*). Cada trío de residuos ( $i, j, k$ ) debe satisfacer la **desigualdad triangular euclídea**:

$$d_{ik} \leq d_{ij} + d_{jk}$$

### Traza manual de consistencia triangular:

Para tres distancias predichas  $d_{ij} = 3.0 \text{ \AA}$ ,  $d_{jk} = 4.0 \text{ \AA}$ ,  $d_{ik} = 5.0 \text{ \AA}$ :

$$d_{ik} \leq d_{ij} + d_{jk} \iff 5.0 \leq 3.0 + 4.0 = 7.0 \quad (\text{Válido})$$

$$d_{ij} \leq d_{jk} + d_{ik} \iff 3.0 \leq 4.0 + 5.0 = 9.0 \quad (\text{Válido})$$

$$d_{jk} \leq d_{ij} + d_{ik} \iff 4.0 \leq 3.0 + 5.0 = 8.0 \quad (\text{Válido})$$

El trío conforma un triángulo euclídeo consistente en  $\mathbb{R}^3$ .

`check_triangle_inequality` valida la consistencia geométrica triangular asegurando que las distancias predichas satisfagan  $d_{ik} \leq d_{ij} + d_{jk}$ , evaluando (3, 4, 5) como válido.

Se reproduce con `verification/chapter_checks.py triangle --d12 3.0 --d23 4.0 --d13 5.0`.

El Evoformer de AlphaFold2 combina representaciones 1D de MSA y 2D de pares de residuos mediante atención dual y Actualizaciones Triangulares.

## Arquitectura de Aprendizaje Profundo de AlphaFold2




Figura 1: Arquitectura de extremo a extremo de AlphaFold2: procesamiento conjunto de MSA y matriz de pares en el Evoformer y generación de coordenadas 3D en el Structure Module. Figura original generada por `verification/make_figures.py`.

### 3.2 El Módulo Estructural y la Atención de Puntos Invariante (IPA)

ESTUDIO

A diferencia de los métodos clásicos que reconstruían coordenadas a partir de matrices de distancia ruidosas, el **Módulo Estructural** (*Structure Module*) predice directamente las coordenadas 3D cartesianas en un solo paso:

- Modela la cadena polipeptídica como un “gas de marcos rígidos 3D” (*residue gas*), donde cada residuo posee una orientación y posición en el grupo especial euclídeo  $SE(3) = SO(3) \times \mathbb{R}^3$ .
- Aplica el mecanismo de **Atención de Puntos Invariante** (*Invariant Point Attention, IPA*), garantizando invariancia estricta frente a traslaciones y rotaciones globales en el espacio 3D.
- Predice simultáneamente los ángulos de torsión ( $\phi, \psi, \omega$ ) y los rotámetros de cadenas laterales ( $\chi_1, \chi_2, \chi_3, \chi_4$ ) sin choques estéricos.

El Módulo Estructural emplea Atención de Puntos Invariante (IPA) operando sobre marcos de referencia locales rígidos  $SE(3)$  para posicionar coordenadas atómicas del esqueleto.

## 4 Métricas de confianza: pLDDT y matrices PAE

ESENCIAL

Una contribución metodológica crucial de AlphaFold2 es que **predice su propia incertidumbre para cada residuo y par de dominios**, evitando la sobreinterpretación errónea de modelos:

#### 4.1 La métrica local pLDDT (predicted Local Distance Difference Test)

ESENCIAL

La puntuación **pLDDT** cuantifica la confianza del modelo a nivel de residuo individual en una escala de 0 a 100:

| Rango pLDDT          | Categoría       | Significado e interpretación biológica                                                                                            |
|----------------------|-----------------|-----------------------------------------------------------------------------------------------------------------------------------|
| $pLDDT \geq 90$      | VERY_HIGH       | Confianza muy alta; precisión atómica en cadenas laterales y esqueleto ( $RMSD < 1 \text{ \AA}$ ). Ideal para diseño de fármacos. |
| $70 \leq pLDDT < 90$ | CONFIDENT       | Confianza buena; esqueleto polipeptídico modelado con alta fidelidad.                                                             |
| $50 \leq pLDDT < 70$ | LOW             | Confianza baja; bucles expuestos o conformaciones móviles. Debe interpretarse con cautela.                                        |
| $pLDDT < 50$         | VERY_LOW_OR_IDP | Confianza muy baja; fuerte predictor de <b>regiones intrínsecamente desordenadas (IDPs)</b> o ausencia de parejas de interacción. |

pLDDT cuantifica la confianza local por residuo en una escala 0-100: muy alta ( $\geq 90$ ), confiable (70-90), baja (50-70) y muy baja ( $< 50$ , intrínsecamente desordenada).

#### Escala Oficial de Confianza Local pLDDT (AlphaFold)




Figura 2: Métrica de confianza local pLDDT de AlphaFold: bandas de fiabilidad y discriminación de regiones intrínsecamente desordenadas (IDPs). Figura original generada por `verification/make_figures.py`.

#### Traza manual para pLDDT = 92.50:

El clasificador de bandas asigna la puntuación 92.50 a la banda de confianza muy alta.

Se reproduce con `verification/chapter_checks.py plddt --score 92.50`.

#### Traza manual de pLDDT medio global:

Para las puntuaciones de residuos [95, 92, 88, 45]:

$$\text{Media} = \frac{95 + 92 + 88 + 45}{4} = \frac{320}{4} = 80.000000$$

`calculate_mean_plddt` calcula la confianza media de todo el modelo evaluando las puntuaciones [95, 92, 88, 45] exactamente a 80.000000.

Se reproduce con `verification/chapter_checks.py mean_plddt --scores 95.0,92.0,88.0,45.0`.

### Control defensivo de rango de puntuación:

`classify_plddt` lanza `ValueError` cuando la puntuación está fuera del rango válido  $[0, 100]$ .

Se reproduce con `verification/chapter_checks.py plddt --score 105.0`.

## 4.2 La matriz PAE (Predicted Aligned Error) y empaquetamiento entre dominios

### ESENCIAL

El pLDDT mide la calidad local de cada residuo, pero no indica si dos dominios globulares mantienen una orientación espacial fija entre sí. Para ello, AlphaFold produce la matriz **PAE (Predicted Aligned Error, en Ångströms)** de tamaño  $N_{\text{res}} \times N_{\text{res}}$ :

- $\text{PAE}(x, y)$  estima el error esperado en la posición del residuo  $y$  cuando el modelo se superpone sobre el residuo  $x$ .
- **PAE interdominio baja** ( $< 5 \text{ Å}$ ): Los dominios presentan una orientación rígida bien definida en el espacio (`RIGID_ORIENTATION`).
- **PAE interdominio alta**, por encima de 15 a 20 ángstrom: los dominios están unidos por un conector flexible; cada uno se pliega bien por separado, pero su orientación relativa queda indeterminada.

La matriz N-por-N de Error Alineado Predicho (PAE) cuantifica la incertidumbre de posicionamiento espacial inter-residuo para discriminar empaquetamiento rígido de dominios frente a conectores flexibles.

### Traza manual de evaluación PAE interdominio:

Dada la submatriz PAE  $2 \times 2$  entre dos dominios con valores  $[[2.5, 3.0], [2.8, 3.0]]$ :

$$\text{PAE media} = \frac{2.5 + 3.0 + 2.8 + 3.0}{4} = \frac{11.3}{4} = 2.825000 \text{ Å} < 5.0 \text{ Å} \Rightarrow \text{RIGID\_ORIENTATION}$$

`evaluate_interdomain_pae` evalúa la matriz modelo PAE  $2 \times 2$  con media 2.825000 Å clasificando el empaquetamiento de dominios como `RIGID_ORIENTATION`.

Se reproduce con `verification/chapter_checks.py pae --matrix 2.5,3.0:3.0,2.8`.




Figura 3: Matriz de Error Alineado Predicho (PAE): identificación de empaquetamientos globulares rígidos frente a conectores inter-dominio flexibles. Figura original generada por `verification/make_figures.py`.

## 5 Fronteras emergentes: AlphaFold3 y Modelos de Lenguaje

ESTUDIO

1. **Modelos generativos de difusión** (AlphaFold3 [1] y RoseTTAFold All-Atom [2]): Abandonan el Structure Module determinista y emplean modelos de difusión generativa para desruirar coordenadas atómicas, prediciendo complejos heterogéneos de proteínas, ADN, ARN, iones metálicos y ligandos químicos.
2. **Modelos de lenguaje de proteínas** (pLM, ESMFold [4]): Entrenados sobre cientos de millones de secuencias de UniRef, aprenden la gramática evolutiva del plegamiento, permitiendo predecir estructuras 3D en milisegundos directamente a partir de una única secuencia individual sin necesidad de computar MSAs.

Los modelos generativos de difusión en AlphaFold3 y RoseTTAFold All-Atom predicen ensamblajes heterogéneos de proteínas, ácidos nucleicos, iones y ligandos mediante desruído iterativo.

Los Modelos de Lenguaje de Proteínas (pLMs, ESMFold) aprenden la gramática evolutiva a través de miles de millones de secuencias para predecir estructuras a partir de secuencias únicas sin cálculo de MSA.

## 6 Diseño computacional en Python: Clasificador pLDDT y PAE

ESTUDIO

A continuación se presenta la implementación modular del procesador en Python 3.9:

```
from typing import List, Tuple

def check_triangle_inequality(d_ij: float, d_jk: float, d_ik: float) -> bool:
    """Valida si tres distancias satisfacen la desigualdad triangular euclidea."""
    if d_ij <= 0 or d_jk <= 0 or d_ik <= 0:
        raise ValueError("Las distancias deben ser estrictamente positivas")
    return (d_ik <= d_ij + d_jk) and (d_ij <= d_jk + d_ik) and (d_jk <= d_ij + d_ik)

def classify_plddt(score: float) -> str:
    """Asigna la categoria de confianza cualitativa segun el valor pLDDT."""
    if score < 0.0 or score > 100.0:
        raise ValueError(f"Puntuacion pLDDT fuera de rango [0, 100]: {score}")
    if score >= 90.0:
        return "VERY_HIGH"
    elif score >= 70.0:
        return "CONFIDENT"
    elif score >= 50.0:
        return "LOW"
    else:
        return "VERY_LOW_OR_IDP"

def calculate_mean_plddt(scores: List[float]) -> float:
    """Calcula el pLDDT medio de una lista de residuos."""
    if not scores:
        raise ValueError("Lista de puntuaciones vacia")
    for s in scores:
        if s < 0.0 or s > 100.0:
            raise ValueError(f"Puntuacion fuera de rango: {s}")
    return round(sum(scores) / len(scores), 6)

def evaluate_interdomain_pae(pae_matrix: List[List[float]]) -> Tuple[float, str]:
    """Calcula la PAE media entre dominios y clasifica la flexibilidad."""
    if not pae_matrix or not pae_matrix[0]:
        raise ValueError("Matriz PAE vacia")
    total_val = 0.0
    count = 0
    for row in pae_matrix:
        for val in row:
            if val < 0.0:
                raise ValueError("Valores PAE no pueden ser negativos")
            total_val += val
```

```
count += 1
mean_pae = round(total_val / count, 6)
classification = "RIGID_ORIENTATION" if mean_pae < 5.0 else "FLEXIBLE_LINKER"
return mean_pae, classification
```

## 7 Peligros computacionales y actividad de depuración

ESTUDIO

Malinterpretar regiones con pLDDT < 50 como fallos del modelo en lugar de proteínas intrínsecamente desordenadas (IDPs) y asumir rigidez estática representan errores críticos.

### 7.1 Tres errores críticos en el uso de predicciones de IA

ESTUDIO

Localice y corrija los tres errores en la siguiente función:

```
def interpret_alphafold_prediction(plddt_per_residue, pae_matrix):
    # Error 1: Descarta un modelo completo porque su cola N-terminal tiene pLDDT = 35,
    # ignorando que se trata de un segmento intrínsecamente desordenado (IDP) fisiológico

    # Error 2: Realiza acoplamiento molecular de fármacos (docking) sobre residuos
    # con pLDDT = 48, asumiendo que la conformación estática dibujada es rígida

    # Error 3: Asume que dos dominios forman una interfaz fija basándose solo en que
    # ambos tienen pLDDT > 90 individualmente, ignorando que su PAE cruzada es de 25 Å
    pass
```

**Diagnóstico de causa raíz (Protocolo 5 Whys):**

1. **Fallo 1 (Confundir desorden con fallo del algoritmo):** pLDDT < 50 en bucles o extremos predice con > 80% de precisión regiones IDP que carecen de estructura secundaria fija en disolución.
2. **Fallo 2 (Docking en regiones de baja confianza):** Realizar cribado en bolsas con pLDDT < 70 genera falsos positivos masivos.
3. **Fallo 3 (Ignorar la matriz PAE en arquitecturas multidominio):** Dos dominios pueden estar impecablemente plegados de forma individual pero conectados por una bisagra flexible que hace impredecible su posición relativa.

## 8 Ética y auditoría de las predicciones

ESENCIAL

Una predicción de AlphaFold llega con aspecto de resultado terminado: coordenadas atómicas completas, sin huecos, con la misma pinta que una estructura resuelta experimentalmente. Esa apariencia es el problema. El modelo siempre devuelve algo, incluso para una secuencia que no se pliega, y no distingue entre «esto es así» y «esto es lo mejor que puedo proponer con lo que he visto».

De ahí que el uso responsable de estas predicciones se reduzca a una disciplina que no cueste nada y casi nadie aplica: mirar el pLDDT y la matriz PAE antes que las coordenadas, y decir en el texto qué se ha mirado. Tres consecuencias prácticas.

- **Una región de pLDDT bajo no es un error de la predicción.** A menudo es la respuesta correcta: hay proteínas cuyas regiones intrínsecamente desordenadas no tienen una estructura única que predecir. Borrarlas del modelo para que quede más limpio es falsear el resultado.
- **Un pLDDT alto no valida el empaquetamiento entre dominios.** Dos dominios pueden estar bien predichos por separado y colocados uno respecto del otro de cualquier manera. Eso lo dice la matriz PAE, no el pLDDT.

- **Una predicción no sustituye a un experimento cuando la decisión tiene consecuencias.** Sirve para generar hipótesis, priorizar dianas y diseñar experimentos. Orientar una decisión clínica o el desarrollo de un fármaco sobre coordenadas predichas sin contrastarlas es un salto que hay que declarar explícitamente, no dar por descontado.

El uso responsable de una predicción estructural exige consultar el pLDDT por residuo y la matriz PAE entre dominios antes de interpretar las coordenadas, y declarar esa comprobación al comunicar el resultado.

## 9 Síntesis operativa y tablas de diagnóstico

REFERENCIA

### 9.1 Tabla de interpretación de métricas de AlphaFold

REFERENCIA

| Métrica / Rango             | Calificación cualitativa | Fiabilidad del modelo                       | Aplicación recomendada          |
|-----------------------------|--------------------------|---------------------------------------------|---------------------------------|
| pLDDT $\geq 90$             | VERY_HIGH                | Precisión atómica (RMSD $< 1 \text{ \AA}$ ) | Docking y diseño de fármacos    |
| $70 \leq \text{pLDDT} < 90$ | CONFIDENT                | Esqueleto fiable                            | Mutagénesis y topología         |
| $50 \leq \text{pLDDT} < 70$ | LOW                      | Bucles / baja certeza                       | Hipótesis orientativas          |
| pLDDT $< 50$                | VERY_LOW_OR_IDP          | Región desordenada                          | Predicción de IDPs              |
| PAE $< 5 \text{ \AA}$       | RIGID_ORIENTATION        | Interfaz de dominios rígida                 | Ensamblaje cuaternario          |
| PAE $> 15 \text{ \AA}$      | FLEXIBLE_LINKER          | Conector flexible interdominio              | No usar para orientación global |

## 10 Glosario conceptual

REFERENCIA

- **Coevolución:** Mutaciones compensatorias que revelan contactos 3D.
- **DCA:** Análisis de acoplamiento directo en alineamientos múltiples.
- **Evoformer:** Bloque neuronal de atención axial sobre MSA y pares 2D.
- **Triangle Update:** Restricción de desigualdad triangular en pares.
- **Structure Module:** Predicción 3D cartesiana directa en SE(3).
- **IPA:** Mecanismo de Atención de Puntos Invariante espacial.
- **pLDDT:** Métrica local de confianza por residuo (0–100).
- **PAE:** Matriz de error esperado de alineamiento interdominio ( $\text{\AA}$ ).
- **IDP:** Proteína intrínsecamente desordenada (pLDDT  $< 50$ ).
- **ESMFold:** Predicción ultrarrápida mediante modelos de lenguaje.

## 11 Conexiones y mapa del curso

ESENCIAL

La comprensión de las predicciones estáticas de IA transita directamente hacia simulaciones de dinámica molecular, docking y cribado virtual en BC-CH14.

## 12 Fuentes y reproducibilidad

REFERENCIA



Este capítulo se apoya en el material docente de la asignatura y en los cuatro artículos que describen los sistemas tratados: Jumper y sus colaboradores [3] para AlphaFold2, Baek y sus colaboradores [2] para RoseTTAFold, Abramson y sus colaboradores [1] para AlphaFold3 y Lin y sus colaboradores [4] para ESMFold. Todos los cálculos numéricos del texto se reproducen con las órdenes impresas junto a ellos.

## Anexo práctico · Métricas de confianza pLDDT, matrices PAE y auditoría de modelos de IA

### Pregunta, producto y separación de materiales

¿Puede implementar un módulo en Python que clasifique las bandas de calidad local pLDDT de AlphaFold, evalúe la confianza promedio del modelo, analice submatrices PAE para discriminar orientaciones interdominio rígidas de bisagras flexibles, y valide la consistencia geométrica euclidiana mediante la desigualdad triangular de forma determinista y sin dependencias externas? Este laboratorio pide justamente eso, y luego pide algo más: usar el módulo para dictaminar cuatro modelos predichos y decir para qué sirve cada uno.

El producto individual contiene: el clasificador de bandas pLDDT, el calculador de confianza media, el analizador de submatrices PAE interdominio, la verificación de desigualdad triangular, la perturbación hacia desorden intrínseco (IDP), el control de excepciones de la guarda de dominio y la defensa conceptual escrita.

Lo que se entrega es un módulo escrito por usted, el dictamen razonado de los cuatro modelos y una defensa breve. Lo que se le da hecho es distinto y conviene tenerlo separado desde el principio: los cuatro modelos con su manifiesto, el oráculo del capítulo y un comprobador público que dice si su módulo cumple el contrato. El anexo funciona sin red y sin más dependencia que Python 3.9.

### Mapa de ruta y productos entregables

| Bloque de trabajo         | Producto entregable                                 |
|---------------------------|-----------------------------------------------------|
| 1 · Entorno y diagnóstico | Espacio de trabajo creado y manifiesto verificado   |
| 1b · Módulo de auditoría  | mi_auditoria.py con las cuatro funciones            |
| 2 · Cálculo ancla         | Banda, media, dictamen PAE y triángulo del capítulo |
| 3 · Perturbación          | El mismo análisis sobre un modelo desordenado       |
| 4 · Guarda de dominio     | Rechazo razonado de un pLDDT fuera de rango         |
| 5 · Dictamen y entrega    | Los cuatro modelos dictaminados, defensa y paquete  |

Este anexo deja evidencia comprobable en cada bloque sin recurrir a paquetes externos.

### 1 · Entorno y diagnóstico

Python 3.9 o superior, sin paquetes externos. Antes de empezar:

```
python3 --version
./practice_assets/create_workspace.sh BC13_entrega
cd BC13_entrega
(cd data && sha256sum --check --strict manifest.sha256)
python3 verification/practice_checks.py domain_guard --score 105.0
```

El generador deja mi\_auditoria.py con su contrato documentado y sin implementación, copia los cuatro modelos con su manifiesto y el comprobador público, y crea notas/dictamen.tsv con solo la cabecera.

La última orden debe imprimir GUARD\_SCORE:105.0 STATUS:REJECTED seguido del mensaje de error. Si no lo hace, el intérprete no es el esperado o los ficheros no coinciden con el manifiesto; resuélvalo antes de continuar.

## 1b • Escribir el módulo de auditoría

**Tarea.** Implemente las cuatro funciones de `mi_auditoria.py`: la banda de pLDDT, la confianza media, el dictamen de una submatriz PAE y la desigualdad triangular. El contrato está en la documentación de la plantilla.

Las tres primeras son cortas y la cuarta parece trivial hasta que se mira el caso degenerado. Tres puntos alineados dan distancias como 2, 3 y 5, donde el lado largo iguala exactamente la suma de los otros dos. Eso es realizable: es un segmento. Si su comprobación usa la desigualdad estricta lo declarará imposible, y estará rechazando geometrías que el modelo puede producir legítimamente cuando tres residuos quedan casi en línea.

```
bash check_auditoria.sh
```

## 2 • Cálculo ancla: pLDDT, media, PAE y consistencia triangular

Dadas las condiciones estándar de auditoría:

1. Puntuación pLDDT de 92.50: clasifica en la banda VERY\_HIGH.
2. Cuarteto de residuos [95.0, 92.0, 88.0, 45.0]: el pLDDT medio evalúa a 80.000000.
3. Submatriz PAE de  $2 \times 2$  con los valores 2,5 y 3,0 en la primera fila y 3,0 y 2,8 en la segunda: media de 2,825 ángstrom, es decir, orientación rígida.
4. Triplete de distancias (3.0, 4.0, 5.0): la desigualdad triangular evalúa como Válida.

```
python3 verification/practice_checks.py anchor
```

El modelo ancla valida la banda VERY\_HIGH, el pLDDT medio de 80.000000, la media PAE de 2.825000 Å (RIGID\_ORIENTATION) y la consistencia geométrica triangular.

Se reproduce con `verification/practice_checks.py anchor`.

## 3 • Perturbación: auditoría de desorden intrínseco y bisagras flexibles

Compruebe la respuesta del clasificador ante una región de desorden intrínseco (pLDDT = 42.0) y una submatriz PAE interdominio de alta incertidumbre ([[18.0, 22.0], [20.0, 24.0]], media 21.000000 Å):

```
python3 verification/practice_checks.py perturbation
```

La perturbacion con score 42.0 (VERY\_LOW\_OR\_IDP) y PAE medio de 21.000000 Å (FLEXIBLE\_LINKER) verifica la auditoria de incertidumbre.

Se reproduce con `verification/practice_checks.py perturbation`.

## 4 • Guarda de dominio y control de excepciones

Compruebe que el algoritmo rechaza puntuaciones pLDDT fuera del rango [0, 100]:

```
python3 verification/practice_checks.py domain_guard --score 105.0
```

La guarda de dominio rechaza puntuaciones pLDDT fuera del intervalo [0, 100] lanzando un `ValueError`.

Se reproduce con `verification/practice_checks.py domain_guard --score 105.0`.

## 5 • Dictamen de los cuatro modelos y entrega

data/bc13\_modelos.json contiene cuatro predicciones con su vector de pLDDT por residuo y una submatriz PAE entre dominios. Los nombres describen lo que pretende ser cada una; el ejercicio es comprobar si el nombre se sostiene.

Antes de ejecutar nada, anote en notas/dictamen.tsv qué espera de cada modelo: en qué banda caerá su pLDDT medio y si la submatriz PAE dará una orientación rígida o flexible. Después ejecute su módulo sobre los cuatro, guarde las salidas en resultados/ y complete las columnas de resultado.

La columna uso\_admisible es el dictamen y es lo que se corrige: para qué sirve cada modelo. Al menos uno de los cuatro tiene un pLDDT medio alto y una matriz PAE que desaconseja usarlo tal cual, y ese es el caso que el capítulo entero prepara.

Escriba en notas/defensa.md entre 100 y 150 palabras justificando el dictamen de ese modelo en concreto. Después:

```
cd ..
tar -czf BC13_entrega.tar.gz BC13_entrega
sha256sum BC13_entrega.tar.gz
./practice_assets/check_delivery.sh BC13_entrega BC13_entrega.tar.gz
```

El verificador comprueba que su módulo compila y cumple el contrato, que los datos de partida no se han tocado, que los cuatro modelos están dictaminados y que existe la defensa con la extensión pedida. Rechaza la entrega vacía y el espacio recién generado. No puntúa.

El verificador de entrega comprueba el contrato del módulo, la integridad de los datos de partida, el dictamen de los cuatro modelos y la defensa escrita; rechaza el espacio de trabajo recién generado y no emite calificación.

## Rúbrica de calificación ponderada

La evaluación sobre 10 puntos se pondera según:

- **4.0 puntos (40%):** El módulo mi\_auditoria.py cumple el contrato: el comprobador público imprime AUDITORIA\_OK.
- **2.0 puntos (20%):** La columna de uso admisible de notas/dictamen.tsv está razonada para los cuatro modelos.
- **2.0 puntos (20%):** Los bloques de cálculo ancla, perturbación y guarda de dominio están reproducidos con sus salidas guardadas.
- **2.0 puntos (20%):** Defensa escrita de 100 a 150 palabras sobre el modelo de confianza alta y empaquetamiento dudoso.

## Lista de autocorrección

- |                                                      |                                                       |
|------------------------------------------------------|-------------------------------------------------------|
| ■ Verifiqué que mi versión de Python es $\geq 3.9$ . | ■ El pLDDT 105.0 fue rechazado por la guarda.         |
| ■ Score 92.5 clasificó en VERY_HIGH.                 | ■ bash check_auditoria.sh imprimió AUDITORIA_OK.      |
| ■ La media pLDDT evaluó a 80.000000.                 | ■ Anoté las predicciones antes de ejecutar el módulo. |
| ■ La PAE media evaluó a 2.825000 Å (RIGID).          | ■ Dictaminé los cuatro modelos y redacté la defensa.  |
| ■ La desigualdad triangular resultó válida.          |                                                       |
| ■ Perturbación evaluó a VERY_LOW_OR_IDP y LINKER.    |                                                       |

## Defensa conceptual

En 100–150 palabras, y sobre el modelo cuyo pLDDT medio es alto pero cuya submatriz PAE desaconseja el empaquetamiento: diga qué afirmación sobre esa proteína sí puede sostenerse con el modelo y cuál no. Añada por qué una región con pLDDT por debajo de 50 suele ser desorden funcional y no un fallo de cálculo, y qué consecuencia tiene eso para quien recorta esa región del modelo antes de enseñarlo.

## Fuentes y reproducibilidad

Este anexo se apoya en el material docente de la asignatura y en las mismas fuentes primarias que el capítulo: Jumper y sus colaboradores [3] para AlphaFold2, Baek y sus colaboradores [2] para RoseTTAFold y Abramson y sus colaboradores [1] para AlphaFold3. Todos los valores numéricos del enunciado se reproducen con las órdenes impresas junto a ellos.

## Bibliografía

- [1] Josh Abramson, Jonas Adler, Jack Dunger, Richard Evans, Tim Green, Alexander Pritzel, Olaf Ronneberger, Lindsay Willmore, Andrew J. Yim, Augustin Žídek, Peter Battaglia, Demis Hassabis, and John Jumper. Accurate structure prediction of biomolecular interactions with alphafold 3. *Nature*, 630:493–500, 2024. Artículo de AlphaFold 3 basado en modelos de difusión generativa para complejos biomoleculares.
- [2] Minkyung Baek, Frank DiMaio, Ivan Anishchenko, Justas Dauparas, Sergey Ovchinnikov, Gyu Rie Lee, Jue Wang, Qian Cong, Lisa N. Kinch, R. Dustin Schaeffer, Claudia Millán, Hahnbeom Park, Colin Adams, C. R. Glasscock, A. M. DeGiovanni, J. H. Pereira, A. V. Rodrigues, A. A. van Dijk, A. C. Ebrecht, D. J. Opperman, T. Sagendorf, A. Schresht, and David Baker. Accurate prediction of protein structures and interactions using a three-track neural network. *Science*, 373(6557):871–876, 2021. Artículo canónico de RoseTTAFold y arquitectura de red de 3 pistas (1D, 2D, 3D).
- [3] John Jumper, Richard Evans, Alexander Pritzel, Tim Green, Michael Figurnov, Olaf Ronneberger, Kathryn Tunyasuvunakool, Russ Bates, Augustin Žídek, Anna Potapenko, Alex Bridgland, Clemens Meyer, Simon A. A. Kohl, Andrew J. Ballard, Andrew Cowie, Bernardino Romera-Paredes, Stanislav Nikolov, Rishub Jain, Jonas Adler, Trevor Back, Stig Petersen, David Reiman, Ellen Clancy, Michal Zielinski, Martin Steinegger, Michalina Pacholska, Tamas Berghammer, Sebastian Bodenstern, David Silver, Oriol Vinyals, Andrew W. Senior, Koray Kavukcuoglu, Pushmeet Kohli, and Demis Hassabis. Highly accurate protein structure prediction with alphafold. *Nature*, 596(7873):583–589, 2021. Artículo canónico de AlphaFold2, arquitectura Evoformer y métricas pLDDT y PAE.
- [4] Zeming Lin, Halil Akin, Roshan Rao, Brian Hie, Zhongkai Zhu, Wenting Lu, Nikita Smetanin, Robert Verkuil, Ori Kabeli, Yaniv Shmueli, Allan dos Santos Costa, Maryam Fazel-Zarandi, Tom Sercu, Salvatore Candido, and Alexander Rives. Evolutionary-scale prediction of atomic-level protein structure with a language model. *Science*, 379(6637):1123–1130, 2023. Artículo de ESM-2 y ESMFold para predicción estructural basada en modelos de lenguaje proteico (pLM).